

합성 CAN 공격 데이터 증강의 신뢰성 검증을 위한 단계적 평가 프레임워크 설계 및 구현

졸업과제 착수보고서



팀명: InfoSec

분과 D (하드웨어/보안)

정보컴퓨터공학부 인공지능전공

졸업과제번호: 46

202355655 장현진

이메일: hyunjin@islab.re.kr

지도교수: 김호원

제출일: 2026년 8월 4일

부산대학교

요약

본 과제는 규칙 기반 합성 Controller Area Network(CAN) 공격 데이터로 학습한 침입탐지 시스템의 성능을 체계적으로 검증하는 단계적 평가 프레임워크를 설계하고 구현하는 것을 목표로 한다. 동일 데이터셋의 성능만으로는 합성 데이터가 공격의 일반화 가능한 특징을 제공했는지, 생성 규칙과 평가 조건이 공유하는 인공적 단서를 제공했는지 식별하기 어렵다. 본 연구는 이를 데이터 증강량, 학습량, 생성 규칙 및 분포 이동 수준을 분리한 실험 설계 문제로 정식화한다.

제안 프레임워크는 데이터 역할 관리, 규칙 기반 공격 생성, 학습 예산을 통제된 비교군, 단계적 분포 이동 평가, 외부 데이터셋 교차평가, marginal-matched placebo 대조 및 실험 근거 추적 모듈로 구성된다. Car-Hacking을 source 데이터로 사용하고 OTIDS, can-train-and-test 및 ROAD를 외부 평가 데이터로 사용하며, CNN과 Random Forest에서 반복 실험을 수행할 예정이다. 이를 통해 합성 증강의 효과가 유지되는 분포 범위를 정량화하고, 생성기에 구현된 관계 구조의 독립적 기여를 추정하며, 재현 가능한 CAN IDS 합성 데이터 평가 절차를 제시하고자 한다.

목차

요약	i
1 과제 개요 및 목표	1
1.1 연구 배경	1
1.2 선행연구	1
1.2.1 합성 데이터 기반 CAN 침입탐지	1
1.2.2 CAN IDS 데이터셋과 평가 조건	2
1.2.3 합성 데이터 품질 평가와 연구 공백	2
1.3 과제 목표	3
1.4 연구질문	4
1.5 연구가설	4
1.6 예상 학술적 기여	5
2 대상 문제 및 요구조건 분석서	6
2.1 대상 문제	6
2.2 기능 요구조건	6
2.3 비기능 요구조건	7
2.4 완료 기준	7
3 현실적 제약 사항 분석 및 대책	8
4 연구 방법 및 평가 시스템 설계	8
4.1 전체 아키텍처	8
4.2 컴포넌트 설계	10
4.3 데이터 역할과 인터페이스	10
4.3.1 위협 범위와 조작적 정의	11
4.4 실험 변수와 비교군	12
4.5 단계적 평가 조건	13
4.6 실험 절차	13
4.7 반복 단위와 통계 분석 계획	14
4.8 재현성 및 품질 관리	15
4.9 타당도 위협과 주장 범위	15
5 추진 체계, 일정 및 역할 분담	16
5.1 추진 체계	16
5.2 세부 일정	16
5.3 구성원별 역할 분담	17
5.4 기대 성과 및 결과물	17
5.4.1 기대 성과	17
5.4.2 최종 결과물	17

제1장 과제 개요 및 목표

1.1 연구 배경

CAN은 차량 내부 전자제어장치 사이의 통신에 널리 사용되지만, 전통적인 프로토콜은 메시지 송신자 인증과 payload 암호화를 기본적으로 제공하지 않는다. 따라서 차량 내부 네트워크에 접근한 공격자는 프레임을 주입하거나 재전송하고, 높은 빈도의 메시지로 통신을 방해할 수 있다[12]. 이러한 위협에 대응하기 위해 다양한 CAN 침입탐지시스템(IDS)이 제안되었으며, 공개 벤치마크에서는 매우 높은 정확도가 보고되기도 한다[20].

공격 표본 부족과 클래스 불균형을 보완하기 위해 GAN을 비롯한 합성 데이터 생성 기법이 CAN IDS에 적용되어 왔다[27, 26]. 그러나 합성 데이터의 품질은 표본의 외형적 유사성뿐 아니라 downstream 탐지 성능, 평가 분포, 대조 조건에 따라 달라질 수 있으므로 목적에 맞는 평가 설계가 필요하다 [1, 23].

그러나 동일 차량과 유사한 분포에서 얻은 높은 성능은 새로운 공격 변형이나 다른 차량 데이터에서도 같은 성능이 유지됨을 의미하지 않는다. 보안 머신러닝의 평가에서는 데이터 누수, 부적절한 baseline, 분포 이동과 재현성 통제가 결론을 크게 바꿀 수 있다[3]. 특히 합성 공격 데이터가 생성기와 평가 데이터 사이의 규칙을 공유하면, 탐지기가 공격의 일반적 의미가 아니라 생성 규칙의 흔적을 학습해도 성능이 향상될 수 있다.

본 과제는 이러한 문제를 단순한 모델 정확도 비교가 아니라 시스템 설계 문제로 다룬다. 합성 데이터 생성부터 학습 조건 통제, 단계적 평가, 실패 원인 진단과 근거 추적까지 연결된 평가 아키텍처를 구현함으로써, “합성 증강이 도움이 되는가”를 “증강 효과가 어떤 조건까지 유지되며 무엇이 그 효과를 설명하는가”라는 검증 가능한 질문으로 바꾼다.

1.2 선행연구

1.2.1 합성 데이터 기반 CAN 침입탐지

차량 내 네트워크의 공격 표본 부족을 보완하기 위해 생성모델을 탐지기 학습에 결합한 연구가 진행되어 왔다. GIDS는 GAN을 CAN 이상탐지에 도입하여 생성모델 기반 탐지의 가능성을 제시했다[20]. Yang 등은 비정상 CAN 표본을 생성하는 단일 GAN과 다중 클래스 탐지를 결합하여 복잡한 하이브리드 구조를 단순화했고 [26], Zhao 등은 ACGAN의 auxiliary classifier와 OOD 판정을 결합하여 정상, 알려진 공격 및 알려지지 않은 공격을 구분하는 2단계 구조를 제안했다 [27]. 최근에는 학습 데이터 증강 자체를 CAN IDS의 성능 개선 수단으로 다루는 연구도 이어지고 있다[25].

다수의 기존 연구는 생성 표본이 클래스 불균형과 미관측 공격 문제를 완화할 가능성을 보여주지만, 주된 평가는 생성기와 학습·시험 데이터가 유사한 데이터셋 내부에서 이루어진다. 생성형 IDS 연구에 대한 체계적 문헌고찰도 생성 방식과 탐지 모델의 조합은 빠르게 늘었지만 평가 기준이 연구마다 달라 직접 비교가 어렵다고 정리한다 [10]. 특히 차량 네트워크 합성 데이터에 관한 최근 고찰은 식별자 coverage, 시간 패턴, payload 분포와 차량 간 일반화를 함께 평가해야 한다고 제안한다[16]. 따라서 source test 정확도 외에 생성 규칙 변화와 외부 차량 분포를 포함한 평가가

필요하다.

CAN 이외의 침입탐지 증강 연구에서도 효과가 분류기와 증강 방식에 따라 달라질 수 있다. Melícias 등은 동일한 비합성 test set과 다섯 탐지기를 사용해 여러 증강법을 비교했으며, 특정 증강법이 모든 탐지기에 일관된 개선을 제공하지는 않음을 보였다 [18]. 이 결과는 합성 증강을 하나의 모델에서만 평가하지 않고 서로 다른 inductive bias를 가진 CNN과 Random Forest에서 반복할 근거가 된다.

1.2.2 CAN IDS 데이터셋과 평가 조건

CAN IDS 성능은 데이터셋의 차량, 공격 주입 방식, feature와 분할 정책에 크게 의존한다. Dupont 등은 서로 다른 CAN IDS를 같은 조건에서 비교하기 위한 평가 프레임워크를 제시하여 데이터셋과 평가 설정을 통제된 비교의 필요성을 보였다 [5]. Vahidi 등은 자동차 침입탐지 데이터셋을 체계적으로 평가하기 위한 품질 지표의 필요성을 제기했으며[22], ROAD는 실차를 다이내모미터에서 운행하며 수집한 공격과 후처리된 masquerade 변형을 제공하고, can-train-and-test는 known/unknown vehicle과 attack 조합을 평가하도록 설계되었다 [24, 14].

CAN-SLEUTH는 여러 자동차 IDS 데이터셋에서 timestamp, payload 표현과 시나리오 기반 분할이 모델 성능에 미치는 영향을 비교하여, 같은 모델이라도 데이터 구성과 전처리에 따라 측정 결과가 달라질 수 있음을 보였다[11]. 일반 네트워크 IDS의 cross-evaluation 연구 역시 한 데이터셋에서 선택한 모델과 설정이 다른 데이터셋에서 그대로 유지되지 않을 수 있음을 보고한다[2]. 본 과제는 이러한 문제를 반영하여 Car-Hacking만 학습·검증에 사용하고, OTIDS, can-train-and-test와 ROAD는 모델 선택에 관여하지 않는 외부 평가 자료로 분리한다.

1.2.3 합성 데이터 품질 평가와 연구 공백

합성 데이터의 품질은 실제 표본과의 단순 유사도만으로 충분히 평가하기 어렵다. Alaa 등은 fidelity, diversity와 training-data 복제 여부를 서로 다른 축으로 측정하는 sample-level audit를 제안했으며[1], van Breugel 등은 하나의 합성 데이터셋을 실제 데이터처럼 취급하면 생성 과정의 오차가 downstream 분석과 모델에 전파될 수 있음을 보였다[23]. 이는 합성 데이터 평가에서 분포 유사도와 실제 downstream utility를 분리해 측정해야 함을 뜻한다.

시계열 합성 데이터의 평가 지표를 정리한 Stenger 등의 조사에서는 통계적 유사성, 시간 의존성, 다양성과 downstream task 성능을 측정하는 지표가 병존하며, 모든 목적에 적용되는 단일 평가 절차는 아직 합의되지 않았다고 분석했다 [21]. 또한 합성 데이터로 학습하고 실제 데이터로 시험하는 TSTR 절차는 생성 표본의 유용성을 실제 표본에서의 예측 성능으로 측정하는 대표적 방법을 제공한다[6]. 본 과제는 이 원리를 실제 공격 보류 test와 외부 CAN 데이터셋 평가에 적용한다.

생성기와 평가 변형이 같은 규칙을 공유하면 탐지기는 공격의 일반화 가능한 구조보다 예측하기 쉬운 생성 흔적을 사용할 수 있다. 이러한 shortcut learning은 동일 분포의 높은 정확도가 의도한 개념 학습을 보장하지 않는 이유를 설명한다 [7]. 따라서 본 과제는 생성 관계만 선택적으로 교란하고 주변 노출 조건은 유지하는 marginal-matched placebo를 둔다. 이는 의도한 관계가 없어도 동일한 반응이 재현되는지 검사하는 negative control의 논리를 합성 증강 평가에 적용한 것이다[17]. 다만 placebo가 교란하지 않은 관계까지 제거했다고 가정하지 않으며, 해석 범위는 사전에 정의한 construction과 endpoint로 제한한다.

기존 CAN 합성 증강 연구, 자동차 IDS 데이터셋 평가 연구, 일반 합성 데이터 평가 연구는 각각 생성 방법, 데이터 조건, 품질 지표를 발전시켰다. 그러나 증강량과 학습량을 통제된 비교군, 생성 관계만 교란한 placebo, 생성 문법 내부에서 외부 차량까지 이어지는 단계적 분포 이동을 하나의 CAN IDS 실험 절차로 결합한 평가는 충분히 다뤄지지 않았다. 본 과제는 이 세 연구 흐름을 통합하여 합성 증강의 전체 효과, 단순 데이터 증가 효과와 구현된 관계 구조의 추가 효과를 분리해 측정하는 평가 시스템을 설계한다.

표 1.1: 선행연구의 평가 공백과 본 과제의 설계 대응

평가 공백	결론을 흐리는 대안 설명	본 과제의 설계 대응
동일 데이터셋 성능 중심	생성기와 시험 조건의 유사성이 일반화 성능으로 해석될 수 있음	L0-L5 단계에서 생성 문법 내부, 복합 이탈 및 외부 차량 평가를 분리
증강량과 학습량의 혼재	표본 수 또는 optimizer update 증가가 합성 규칙의 효과로 측정될 수 있음	real oversampling과 matched-update 대조군을 별도 구성
fidelity와 utility의 혼용	분포 유사성이 실제 탐지 성능을 보장한다고 가정할 수 있음	실제 보류 공격과 외부 데이터에서 downstream metric을 별도 산출
생성 규칙 공유	탐지기가 공격 의미보다 생성 흔적을 학습할 수 있음	marginal-matched placebo와 balance gate로 관계의 추가 반응을 분리
외부 recall 단독 보고	정상 표본을 공격으로 과다 판정해도 높은 recall이 나타날 수 있음	source threshold를 고정하고 데이터셋별 FPR-recall을 공동 판정

1.3 과제 목표

본 과제의 최종 목표는 규칙 기반 합성 CAN 공격 데이터 증강의 효과 범위와 한계를 재현 가능하게 검증하는 단계적 평가 프레임워크를 설계하고 구현하는 것이다. 세부 목표는 다음과 같다.

1. Car-Hacking 학습 데이터만을 사용하는 leakage-controlled 데이터 및 생성 파이프라인을 구축한다.
2. 실제 공격 데이터만 사용하는 조건, 실제 공격 oversampling 조건과 합성 증강 조건을 동일한 학습 정책 아래 비교한다.
3. 동일 분포, 생성 변형, 강도 변화, 생성 규칙 이탈, 외부 데이터셋으로 이어지는 단계적 평가를 구현한다.
4. binary attack detection과 exact attack-type recall을 분리하고, 외부 데이터에서는 FPR을 우선 보고한다.

5. marginal-matched placebo를 통해 구현된 공격 관계가 성능 변화에 추가로 기여하는지 검증한다.
6. 모든 결과를 원본 표, 실행 로그, seed, 모델과 코드 버전에 연결하는 provenance 체계를 제공한다.

1.4 연구질문

- RQ1** 규칙 기반 합성 증강의 controlled-variant 이득은 실제 공격 증량과 동일 학습 update 대조 이후에도 유지되는가?
- RQ2** 합성 증강 효과는 공격 강도, attack family와 생성 규칙 이탈에 따라 어떻게 달라지는가?
- RQ3** source에서 고정한 운영 정책이 외부 차량 데이터셋에서 FPR 악화 없이 attack recall을 개선하는가?
- RQ4** 여러 generator realization에서 생성기에 구현된 Gear/RPM 관계가 marginal-matched placebo를 넘어 추가적인 material increment를 제공하는가?

1.5 연구가설

연구질문을 검증 가능한 형태로 구체화하기 위해 다음 가설을 설정한다.

- H1** 규칙 기반 합성 증강은 동일한 source test 성능을 유지하면서 generated variant에 대한 탐지 성능을 real-only, real oversampling 및 matched-update 대조군보다 사전에 정한 최소 효과 이상 향상시킬 것이다.
- H2** L2 내부에서 Rule-control 증강 효과는 coupled severity가 증가할수록 감소하고, 그 기울기는 attack family에 따라 달라질 것이다. L3와 L4는 이 추세의 연장점이 아니라 별도의 robustness contrast로 분석한다.
- H3** compound grammar exit인 L4에서는 L1보다 binary recall과 exact attack-type recall 사이의 격차가 증가할 것이다.
- H4** 외부 데이터셋에서의 개선은 source에서 고정한 threshold 아래 FPR의 허용 한계를 만족하는 동시에 attack recall이 향상될 때에만 성립할 것이다.
- H5** balance gate를 통과한 marginal-matched placebo와 Rule 생성기를 비교할 때, generator-realization 평균 Gear/RPM 관계 increment $\bar{\theta}$ 는 사전에 정의한 material margin δ_{rel} 을 초과할 것이다.

가설을 사후적인 성능 설명이 아니라 사전 판정 가능한 분석 계약으로 만들기 위해 표 1.2와 같이 주 비교, endpoint와 판정 규칙을 고정한다.

표 1.2: 가설별 주 비교와 사전 판정 규칙

가설	주 비교 및 평가 단계	1차 estimand	지지 또는 판정 규칙
H1	L0 source 보존과 L1 Rule 대 대조군	source Macro-F1 변화와 L1 attack-recall paired difference	L0 하한이 $-\delta_{\text{source}}$ 보다 크고 L1의 사전 지정 contrast가 δ_{gain} 을 초과
H2	L2 severity 내 추세; L3와 L4 별도 contrast	attack family별 Rule-minus-control 효과 곡선	L2에서 사전 지정 방향의 추세를 확인하고 L3·L4는 단일 거리축으로 합치지 않고 별도 구간 보고
H3	L4 대 L1의 탐지 수준 격차	$G_r = R_{\text{binary},r} - R_{\text{exact},r}$ 와 $G_{L4} - G_{L1}$	격차 증가의 paired interval이 0 또는 사전 정의한 최소 격차를 초과
H4	데이터셋별 Rule 대 대조군의 외부 운영점	고정 source threshold 에서의 ΔFPR 과 ΔRecall	FPR과 recall의 paired interval 이 모두 사전 정의한 유리한 영역에 있을 때만 공동 개선으로 판정
H5	generator realization별 Rule 대 placebo	$\theta_g = M_g(\text{Rule}) - M_g(\text{Placebo})$	95% interval이 δ_{rel} 위이면 지지, 90% TOST가 equivalence band 안이면 기각, 그 외 inconclusive

δ_{source} , δ_{gain} 과 H5의 equivalence margin은 주 결과를 보기 전에 source baseline 변동, pilot 정밀도 및 실질적으로 의미 있는 성능 차이를 근거로 고정한다. 차이가 유의하지 않다는 사실만으로 동등성을 주장하지 않고, TOST의 90% interval과 material-difference용 95% interval을 분리해 사용한다 [13, 19].

1.6 예상 학술적 기여

본 과제의 예상 기여는 다음과 같다. 첫째, 합성 CAN 공격 데이터의 효과를 단일 source 성능이 아닌 단계적 분포 이동으로 평가하는 실험 프레임워크를 제안한다. 둘째, 데이터 양과 optimizer update를 통제된 비교군 및 marginal-matched placebo를 도입하여 증강 효과의 원인을 세분화한다. 셋째, binary 탐지, exact attack-type recall, 외부 FPR을 통합한 다층 지표 체계를 통해 분포 수준별 효과 지도를 구축한다. 넷째, 데이터 분할부터 표와 그림 생성까지의 provenance를 연결하여 실험 결과의 재현성과 검증 가능성을 높인다.

제2장 대상 문제 및 요구조건 분석서

2.1 대상 문제

대상 시스템은 합성 공격 데이터가 포함된 CAN IDS 학습 및 평가 파이프라인이다. 기존의 단일 benchmark 평가는 다음 네 문제를 가진다.

1. 동일 source split의 포화 성능이 공격 변형 대응 능력으로 오해될 수 있다.
2. 합성 데이터 양 증가, 학습 update 증가와 생성 규칙의 효과가 혼재할 수 있다.
3. binary attack 여부를 맞히는 능력과 정확한 attack type을 유지하는 능력이 혼용될 수 있다.
4. 외부 데이터에서 거의 모든 normal을 attack으로 분류해도 높은 attack recall만 강조될 수 있다.

따라서 시스템은 성능 수치를 생성하는 데 그치지 않고, 각 결과가 허용하는 claim의 범위를 자동으로 구분할 수 있어야 한다.

2.2 기능 요구조건

ID	기능	요구사항
FR-01	데이터 역할 분리	Car-Hacking은 train/validation/source test로 사용하고 OTIDS, can-train-and-test, ROAD는 evaluation-only로 유지한다.
FR-02	train-only 생성	합성 생성기는 Car-Hacking train split에서만 규칙 또는 분포 정보를 얻어야 한다.
FR-03	비교군 구성	real-only, 실제 공격 oversampling, Rule augmentation 조건을 구분하고 added-window 수와 optimizer update의 대안 설명을 검사한다.
FR-04	반복 가능한 학습	split, augmentation sampling, initialization과 minibatch order를 포함한 paired pipeline seed를 기록한다.
FR-05	단계적 평가	source test, generated variant, coupled severity, target-ID shift, compound grammar exit, external dataset 및 진단 단계를 분리해 평가한다.
FR-06	지표 분리	binary detection, exact attack-type recall, Macro-F1, FPR/normal recall을 목적에 맞게 별도 산출한다.

ID	기능	요구사항
FR-07	외부 평가 보호	외부 label은 진단적 ranking 계산 외에 학습, validation, checkpoint selection과 setting 선택에 사용하지 않는다.
FR-08	효과 귀속	marginal-matched placebo와 Rule 조건의 차이를 계산해 구현 관계의 추가 increment를 검증한다.
FR-09	근거 추적	표와 그림을 source CSV, 실행 script, log, model/scaler hash와 분석 계획에 연결한다.

2.3 비기능 요구조건

표 2.2: 비기능 요구조건과 검증 방법

속성	요구조건	검증 방법
재현성	동일 입력, seed와 버전에서 같은 평가 산출물을 생성해야 한다.	manifest hash, deterministic audit, clean build
추적성	보고서의 주요 수치가 원본 결과와 일대일로 연결되어야 한다.	claim-artifact ledger 대조
무결성	원시 데이터와 기준 실험 산출물을 덮어쓰지 않아야 한다.	읽기 전용 원본, versioned output 과 Git path audit
해석 가능성	평가 rung과 metric이 허용하는 결론을 명시해야 한다.	FPR-first, binary/exact 분리, diagnostic label
확장성	detector 또는 generator가 추가되어도 같은 평가 interface를 재사용해야 한다.	공통 입력 schema와 versioned output

2.4 완료 기준

시스템 구현 완료는 단일 정확도 목표가 아니라 다음 조건의 충족으로 정의한다.

- 각 데이터셋의 역할과 사용 시점이 manifest에 기록된다.
- 주요 비교가 seed별 결과와 mean/std 또는 사전 정의한 interval을 함께 제공한다.
- 외부 결과가 FPR과 attack recall의 공동 조건으로 판정된다.
- 모든 가설의 지지·기각 여부와 대응 근거가 최종 보고서에 포함된다.
- 보고서의 표와 그림을 코드와 source CSV에서 다시 생성할 수 있다.

제3장 현실적 제약 사항 분석 및 대책

제약 사항	연구 영향	대응 방안
공개 CAN 데이터의 차량별 support 차이	source 성능과 외부 차량 성능을 같은 분포의 반복 측정으로 볼 수 없다.	외부 데이터는 evaluation-only로 유지하고 FPR과 attack recall을 함께 보고한다.
생성기와 평가 변형의 문법 공유	생성 규칙에 정렬된 단서가 증강 효과로 측정될 수 있다.	문법 내부, 강도 변화, grammar exit를 분리하고 marginal-matched placebo를 둔다.
128-frame window의 중첩	window 수가 독립적인 정보량보다 크게 계산될 수 있다.	windowing 전에 split을 고정하고 raw-frame-disjoint sensitivity를 수행한다.
제한된 차량 의미 정보	Gear/RPM construction이 실제 DBC signal 의미로 해석될 수 있다.	변수명을 construction family로 정의하고 실차 의미와 구분한다.
1인 수행과 계산 자원	구현, 반복 실험과 문서화가 한 구성원에게 집중된다.	실험 우선순위를 고정하고 자동 실행과 versioned output으로 재작업을 줄인다.
데이터셋별 라벨 이질성	동일한 공격 명칭도 주입 방식과 라벨 단위가 다를 수 있다.	공통 binary endpoint와 dataset-native metric을 병행하고 label mapping을 문서화한다.
고정된 학사 일정	실험과 보고서 작성이 마감 직전에 집중될 수 있다.	중간·최종 마감별 산출물과 완료 조건을 일정표에 고정한다.

각 제약은 실험 설계 요소로 변환한다. 차량별 support 차이는 source test와 외부 교차평가를 분리하는 근거가 되며, 생성 문법 공유 문제는 grammar-exit 조건과 placebo 대조의 필요성을 제공한다. 중첩 window와 제한된 반복 단위는 frame-disjoint sensitivity 및 paired seed 설계로 관리한다. 이와 같이 제약 분석을 데이터 분할, 대조군, 지표 및 통계 단위의 선택에 직접 연결한다.

제4장 연구 방법 및 평가 시스템 설계

4.1 전체 아키텍처

제안 시스템은 학습, 모델 선택, 평가 및 외부 데이터 계층으로 구성된다. 그림 4.1의 푸른색 경로는 source 데이터와 탐지기, 녹색 경로는 합성 데이터, 분홍색 경로는 외부 데이터의 역할을 나타낸다. 생성기는 source train split만 사용하며, 외부 데이터가 주 학습이나 모델 선택으로 유입되는 경로는 차단한다.

각 컴포넌트의 공통 식별자는 dataset, split, construction, augmentation arm, pipeline seed,

Leakage-controlled data flow

Primary training and selection use source-side data; external data enter evaluation or declared diagnostics.




그림 4.1: 누수 통제형 합성 CAN 공격 증강 평가 프로토콜. 생성기는 source 학습 분할만 사용하며, 외부 데이터셋은 주 평가 또는 명시적 진단에만 사용하고 학습·모델 선택 경로에서는 차단한다.

checkpoint와 evaluator version이다. 결과 표는 이 식별자를 유지해야 하며, 집계 단계에서 seed 수나 평가 단위를 조용히 제거하지 않는다. 이러한 interface는 탐지기와 생성기 구현이 바뀌더라도 동일한 claim gate를 적용하기 위한 것이다.

4.2 컴포넌트 설계

표 4.1: 평가 프레임워크의 주요 컴포넌트

컴포넌트	입력	책임 및 출력
데이터 역할 관리자	원시 CAN frame, split manifest	source와 external 역할을 고정하고 window origin과 leakage 검사를 기록한다.
증강 생성기	train split, 생성 규칙, ratio/seed	Rule 공격 window, 실제 공격 oversampling과 placebo twin을 생성한다.
학습 제어기	조건별 train array, 공통 validation policy	동일 학습 예산으로 CNN/RF를 학습하고 checkpoint를 기록한다.
단계적 평가기	고정 checkpoint, 단계별 evaluation set	binary/exact metric, FPR과 단계별 효과 크기를 산출한다.
효과 귀속 분석기	Rule/placebo paired outcomes	전체 증강 반응과 구현 관계의 추가 반응을 분리한다.
근거 관리자	source table, log, config, hash	표 · 그림과 주장을 provenance manifest에 연결한다.

4.3 데이터 역할과 인터페이스

표 4.2: 데이터셋별 역할 계약

데이터	허용 역할	금지 또는 제한
Car-Hacking	train, validation, source test, train-normal 기반 생성	split 이후의 evaluation 정보를 생성기나 selection에 사용하지 않음
Constructed variants/stress	evaluation-only positive/control stress	독립적인 실제 공격 trace 또는 실차 의미로 표현하지 않음
OTIDS	external binary evaluation 및 명시적 diagnostic	train, validation, model/setting selection에 사용하지 않음
can-train-and-test	external binary evaluation 및 명시적 diagnostic	Car-Hacking attack-type label로 임의 변환하지 않음
ROAD	external evaluation 및 명시적 diagnostic	masquerade를 학습한 injection 공격과 동일한 조건으로 해석하지 않음

4.3.1 위협 범위와 조작적 정의

주 source인 Car-Hacking은 DoS, Fuzzy, Gear 및 RPM injection 공격의 학습 · 검증 · source 평가에 사용한다[9, 20]. OTIDS, can-train-and-test 및 ROAD는 차량, 수집 조건과 label semantics가 다른 외부 평가 자료로만 사용한다 [8, 15, 14, 24]. ROAD의 masquerade 공격은 정상 ECU 역제를 포함하므로 source injection 공격과 같은 메커니즘으로 간주하지 않는다. 본 과제의 controlled variant는 명시된 변환 법칙을 적용한 window-local stress test이며, 독립적으로 수집된 실제 공격이나 차량 동역학의 재현으로 표현하지 않는다.

generator grammar는 CAN ID, DLC, payload, timing 및 주입 위치에 적용하는 변환 규칙의 집합으로 정의한다. 표 4.3의 설정은 구현 전에 configuration과 split manifest로 고정하며, 변경이 필요한 경우 주 결과 확인 전에 변경 근거와 버전을 기록한다.

표 4.3: 주요 변수와 실험 설정의 조작적 정의

항목	계획된 정의	누수 및 해석 통제
Source split	공격 episode 순서와 정상 traffic의 연속 block을 기준으로 60/20/20 train/validation/test 분할	windowing 전에 분할하고 source file · row 기준 중복을 감사
입력과 window	128 frame, stride 32; CAN ID, DLC, 8 payload byte와 inter-arrival time Δt	split별 window origin과 raw-frame overlap을 기록
Label endpoint	한 개 이상의 공격 frame이 있으면 binary attack; exact label은 window의 최빈 공격 family와 결정적 tie rule로 정의	binary와 exact denominator 및 label mapping을 별도 보존
전처리	feature와 scaler 통계는 source train에서만 적합하고 validation, test 및 external에 고정 적용	외부 데이터로 normalization, threshold 또는 feature를 재적합하지 않음
증강량	주 비교는 real train 수의 +30%이며 +10%, +50%, +100%를 dose sensitivity로 평가	requested, drawn, unique와 replacement 여부를 arm별 기록
탐지기와 선택	CNN을 주 분석 탐지기, Random Forest를 상이한 inductive bias의 재현성 대조로 사용; source validation으로만 선택	detector family별 결과를 분리하고 외부 성능으로 설정을 선택하지 않음
운영 threshold	source validation의 사전 지정 metric으로 고정한 threshold를 source test와 external에 동일 적용	target-normal calibration, refit 또는 retraining은 명시적 diagnostic으로만 분리

4.4 실험 변수와 비교군

주요 독립변수는 학습 조건, 탐지기 구조, 평가 분포 단계, 공격 family 및 공격 강도다. 종속변수는 binary recall, exact attack-type recall, Macro-F1, FPR, AUROC 및 조건 간 paired performance difference로 정의한다. 데이터 분할, window 길이, feature schema, validation 규칙, optimizer 설정과 pipeline seed는 비교군 사이에서 동일하게 유지한다.

학습 조건	구성	통제하려는 설명
Real-only	원본 Car-Hacking train split 만 사용	합성 증강이 없는 기준 성능
Real oversampling	원본 공격 window를 증강량과 동일한 수만큼 재표집	단순 표본 수 및 class balance 효과
Matched-update	gradient-based 탐지기에서 real-only 데이터를 사용하되 optimizer update 수를 Rule 조건과 일치시킴	추가 학습량 효과
Rule augmentation	train split에서 추정된 규칙으로 공격 window 생성	전체 합성 증강 효과
Marginal-matched placebo	Rule과 주변 분포·주입 구조를 맞추고 변수 관계만 교란	구현된 관계 구조의 추가 효과

표 4.4: 학습 비교군과 인과적 통제 목적

Matched-update는 optimizer step이 정의되는 CNN의 학습량 대조다. Random Forest에는 같은 개념을 기계적으로 적용하지 않고 tree 수, feature schema와 학습 표본 수를 고정하며, real oversampling으로 표본량의 대안 설명을 점검한다. 따라서 detector family 사이의 절대 성능을 합쳐 하나의 효과로 추론하지 않고, 각 family에서 증강 contrast의 방향과 불확실성을 별도로 보고한다.

Rule과 placebo 조건은 source base window, attack label, synthetic sample 수, 주입 위치, CAN ID, DLC, timing, 비표적 payload channel 및 target-byte multiset을 일치시킨다. placebo는 target byte를 제약된 순열로 재배치하여 구현된 Gear/RPM 관계를 교란한다. 이는 의도한 관계를 선택적으로 제거하는 negative control의 설계 논리이며 [17], 두 arm의 sample count와 주변 노출이 일치하는지는 학습 전에 balance gate로 검증한다.

동일한 rung, endpoint, 평가 표본과 가중치를 사용할 때 $M_{a,g,p}$ 를 arm a , generator realization g , pipeline seed p 의 성능으로 정의한다. Real arm은 construction에 의존하지 않으므로 $M_{\text{Real},p}$ 로 쓴다. P 개 pipeline을 realization 안에서 먼저 평균하면 contrast는 다음과 같이 분해된다.

$$\begin{aligned}\Delta_g^{\text{total}} &= \frac{1}{P} \sum_{p=1}^P (M_{\text{Rule},g,p} - M_{\text{Real},p}), \\ \Delta_g^{\text{placebo}} &= \frac{1}{P} \sum_{p=1}^P (M_{\text{Placebo},g,p} - M_{\text{Real},p}), \\ \theta_g &= \frac{1}{P} \sum_{p=1}^P (M_{\text{Rule},g,p} - M_{\text{Placebo},g,p}),\end{aligned}$$

따라서 $\Delta_g^{\text{total}} = \Delta_g^{\text{placebo}} + \theta_g$ 가 성립한다. 첫 항은 전체 Rule 증강 반응, 둘째 항은 matched

placebo가 재현한 반응, θ_g 는 구현 관계의 construction-local 추가 반응을 나타낸다. 이 항등식은 placebo가 모든 가능한 관계를 제거했다는 증거나 탐지기의 내부 표현에 관한 주장이 아니며, 정의된 control과 endpoint에서의 성능 귀속만 허용한다.

4.5 단계적 평가 조건

평가 분포는 source와 가까운 조건에서 외부 차량 데이터로 순차적으로 확장한다. 각 단계는 하나의 연구가설과 주요 estimand에 대응하도록 표 4.5와 같이 구성한다.

단계	평가 조건	연구 목적	주요 지표/가설
L0	Source test	기본 탐지 성능과 증강 후 성능 보존 평가	Macro-F1, class recall / H1
L1	Generated variant	생성 문법 내부의 새로운 표본에 대한 증강 효과 측정	paired recall difference / H1
L2	Coupled severity	여러 생성 parameter가 함께 변할 때 효과의 강도 의존성 추정	severity별 effect curve / H2
L3	Target-ID shift	canonical ID가 달라질 때 ID 기억에 대한 의존성 점검	exact recall change / H2
L4	Compound grammar exit	payload 위치와 관계 구조가 동시에 변할 때 탐지 수준 분해	binary-exact gap / H2, H3
L5	External datasets	차량·수집 환경·라벨 체계가 다른 조건에서 source 정책 교차평가	FPR, normal recall, attack recall / H4
L6	Attribution diagnostics	외부 실패 양상에 대한 대안 설명을 주 결과와 분리해 점검	FPR 변화, source retention / H4

표 4.5: 단계적 평가 조건과 연구가설의 대응

L0은 source 분포에서의 성능 보존을 측정하고, L1은 생성 문법 내부의 positive-control 효과를 측정한다. L2에서는 여러 parameter가 함께 변하는 coupled severity 안에서만 순서형 효과 곡선을 추정한다. L3는 target ID 이동, L4는 burst, step, payload 위치, waveform 및 jitter가 함께 변하는 compound out-of-rule construction이다. 따라서 L1–L4를 보편적인 분포 거리로 간주하거나 L2와 L4를 단일 요인의 인과적 개입으로 해석하지 않는다.

L5에서는 source validation으로 고정한 threshold를 그대로 적용해 외부 FPR과 attack recall의 operating point를 데이터셋별로 측정한다. 침입탐지에서는 낮은 공격 base rate 때문에 작은 FPR도 다수의 오경보를 만들 수 있으므로 recall 단독 개선을 외부 성능 향상으로 판정하지 않는다[4]. L6의 calibration, refit 또는 retraining probe는 외부 실패 원인을 진단하기 위한 보조 분석으로만 수행하며 주 모델 선택에는 사용하지 않는다. AUROC와 average precision도 threshold-independent 보조 지표로 산출한다. 이 ladder는 각 단계가 허용하는 주장을 순서화한 protocol이며, 실제 도로 공격에 대한 연속적인 난이도 척도는 아니다.

4.6 실험 절차

1. 원시 frame 단위에서 Car-Hacking train, validation, test를 먼저 분할한 뒤 128-frame window를 구성하고 split 간 raw-frame overlap을 감사한다.

2. train split의 정상 및 공격 표본만 사용하여 Rule과 placebo 생성 pool을 구축하고, 생성 설정 · seed · source hash를 manifest에 기록한다.
3. 표 4.4의 다섯 학습 조건을 동일한 feature schema와 validation policy로 구성한다.
4. CNN과 Random Forest를 paired pipeline seed로 학습하고, source validation에서 checkpoint와 threshold를 확정한다. matched-update는 CNN의 gradient step에 적용하고 Random Forest는 고정된 tree 수와 feature schema로 평가한다.
5. 확정된 모델을 L0–L6 평가 데이터에 순서대로 적용하되, 외부 데이터의 label은 학습 · 모델 선택 · threshold 조정에 사용하지 않는다.
6. 학습 조건 간 paired effect, 공격 family별 효과, severity-response curve 및 Rule–Placebo contrast를 산출한다.
7. 사전 정의한 표 · 그림 schema로 결과를 집계하고 source CSV, 설정, log, checkpoint 및 분석 코드의 hash를 함께 기록한다.

4.7 반복 단위와 통계 분석 계획

본 과제는 학습 변동성과 생성 construction 변동성을 구분한다. H1–H4의 detector-arm 비교에서는 고정된 split manifest 아래 최소 5개의 paired pipeline seed를 사용한다. 동일 seed는 synthetic subset 선택, model initialization, minibatch order와 stopping trajectory를 함께 제어하지만, 표본 수가 다른 arm 사이에서 minibatch 경로가 완전히 같다는 뜻은 아니다. 표에는 seed 수, 개별 paired difference, 평균과 표본표준편차를 함께 제시한다.

H5의 관계 귀속에서는 generator realization을 주 추론 단위로 한다. 목표 20개의 서로 다른 prospective construction seed마다 정렬된 Rule/placebo twin을 생성하고, 각 realization 안에서 5개 pipeline seed와 평가 block을 먼저 동일 가중 집계한 뒤 realization-level θ_g 를 분석한다. 중첩 window와 변환된 평가 block은 표본 수와 metric을 계산하는 평가 realization이지 독립적인 추론 단위가 아니다. 이 계층을 통해 많은 window를 독립 표본으로 간주해 불확실성을 과소평가하는 오류를 방지한다.

일반적인 arm contrast는 같은 metric M 에 대해 $\Delta_{A,B} = M_A - M_B$ 로 정의한다. H1은 L0 source 보존과 L1의 Rule–Real, Rule–Oversampling 및 Rule–Matched-update 차이를 공동 평가한다. H2의 추세 분석은 L2 severity 내부에 한정하고 L3와 L4는 별도 contrast로 보고한다. H3은 $G_{L4} - G_{L1}$, H4는 데이터셋별 FPR–recall joint endpoint, H5는 realization-level θ_g 를 주 estimand로 사용한다.

각 가설은 하나의 1차 endpoint와 contrast family를 사전에 지정한다. 같은 가설 안의 attack family 또는 field contrast에는 Holm 보정을 적용하고, 나머지 metric과 detector는 secondary 또는 exploratory로 표시한다. 외부 데이터셋은 수집 조건과 label semantics가 다르므로 하나의 평균으로 합치지 않고 dataset-native denominator와 구간을 각각 보고한다. capture 또는 raw-frame-disjoint block 단위 resampling은 window 의존성에 대한 sensitivity로 제공한다.

효과 크기는 paired Student- t interval을 주 구간으로 사용하고, 표본 단위가 허용하는 경우 bootstrap을 sensitivity로 병기한다. practical-equivalence margin은 결과 확인 전에 source baseline 변동과 실질적 허용 한계로 고정한다[13]. H5의 동등성은 90% TOST interval이 $[-\delta_{rel}, +\delta_{rel}]$ 안에 있을 때, material difference는 95% interval이 사전 지정 영역에 있을 때 판정한다 [19]. 어느 조건도 충족하지 않으면 inconclusive로 남긴다.

실행 제외와 재실행 규칙도 분석 전에 고정한다. 입력 hash 불일치, 저장 오류 또는 비정상 종료처럼 결과와 무관한 기술적 실패만 같은 설정으로 재실행하며, 불리한 성능을 이유로 seed를 제거하지 않는다. 모든 시도와 실패 원인을 manifest에 남기고, 평가 대상이 없는 class의 metric은 0으로 대체하지 않고 denominator와 함께 not applicable로 기록한다.

4.8 재현성 및 품질 관리

각 실행은 dataset version, split hash, construction version, augmentation arm, pipeline seed, model configuration, checkpoint 및 evaluator version을 복합 식별자로 사용한다. 자동 검증은 split overlap, sample count, class mapping, requested/drawn/unique sample 수, metric denominator와 표 생성 입력을 확인한다. 최종 표와 그림은 수작업으로 전사하지 않고 versioned source CSV에서 생성하며, 가설-분석-산출물의 연결을 claim-artifact ledger에 기록한다.

실험 시작 전에 dataset checksum, seed 목록, 환경 lock file, hardware, library version, 가설 별 1차 분석과 margin을 analysis-plan snapshot으로 동결한다. 실행 행렬은 augmentation arm $\times$ detector $\times$ pipeline seed로 관리하고, H5는 별도의 construction $\times$ Rule/placebo $\times$ pipeline seed 행렬로 분리한다. 실행 command, 표준 출력, 소요 시간과 실패 상태를 보존하여 중간보고서에는 진행률을, 최종보고서에는 완료된 셀과 제외 사유를 동일한 manifest에서 산출한다.

4.9 타당도 위협과 주장 범위

보안 머신러닝에서는 데이터 분할, baseline, 분포 이동과 집계 단위가 결론의 범위를 크게 바꿀 수 있다[3]. 제약을 통제된 뒤에도 남는 한계를 숨기지 않기 위해 타당도 위협을 표 4.6와 같이 주장 범위에 연결한다. 대응 방안은 편향 가능성을 줄이지만 모든 위협을 제거하지 않으며, 최종 결론은 실제로 통과한 gate와 관측된 범위에 한정한다.

표 4.6: 타당도 위협, 대응 및 남는 주장 한계

타당도 유형	주요 위협	설계상 대응	남는 주장 한계
내적 타당도	인접 frame 중복, 전처리 · threshold 누수, 실패 seed 선택	windowing 전 split, train-only 적합, source-only 선택, 전 실행 이력 보존	동일 source capture 안의 시간 상관과 구현 의존성은 남음

타당도 유형	주요 위협	설계상 대응	남는 주장 한계
대조군 타당도	placebo가 일부 관계를 보존하거나 의도하지 않은 alignment를 바꿀 수 있음	source base, label, 주입 위치, 비표적 channel과 target-byte multiset balance gate	Rule-Placebo는 등록된 control 전체의 효과이며 유일한 byte 관계의 순수 인과효과가 아님
구성 타당도	L1-L4가 실차 공격이 아니고 L2·L4에서 여러 field가 함께 변함	transformation grammar 공개, coupled 및 compound construction 으로 명시	실제 차량 반응, 물리적 realism 또는 단일 parameter 메커니즘을 주장하지 않음
외적 타당도	한 source 차량과 이질적인 외부 label·수집 환경	외부 데이터 evaluation-only, dataset 별 FPR-recall 및 native label 보고	다른 차량·공격·CAN-FD 또는 배치 환경으로 일반화하지 않음
통계적 결론 타당도	제한된 pipeline seed, 중첩 window와 다중 endpoint	계층적 추론 단위, paired interval, 사전 endpoint 및 Holm family	선택한 seed, construction, detector와 margin에 조건부인 결론임
모델 범위	CNN과 Random Forest의 학습 예산 및 inductive bias가 다름	detector별 budget control 과 별도 effect profile	모든 CAN IDS architecture 에 공통된 증강 효과를 주장하지 않음

이 구분은 한계를 방어적으로 나열하기 위한 것이 아니라, 어떤 결과가 나와도 허용되는 결론을 사전에 정하기 위한 claim gate다. 가설의 판정 조건을 충족하지 못한 결과는 실패를 숨기거나 넓은 일반화로 대체하지 않고 unsupported 또는 inconclusive로 보고한다.

제5장 추진 체계, 일정 및 역할 분담

5.1 추진 체계

본 과제는 1인 체계로 수행한다. 요구사항과 설계 결정을 먼저 문서화하고, 구현과 실험은 versioned stage로 실행한다. 각 stage는 입력 hash, 실행 조건, 출력 검증 gate를 통과해야 다음 단계로 진행한다. 지도교수 검토에서는 연구 범위, 평가 타당성, 결과 해석과 최종 발표 방향을 점검한다.

연구 수행은 설계, 구현, 실험, 분석, 보고의 다섯 work package로 구분한다. 각 package의 입력과 완료 기준을 문서화하고, 코드·모델·실험 결과·보고서의 버전을 분리하여 관리한다. 지도교수 검토 결과는 다음 단계의 범위와 우선순위에 반영하며, 변경된 가설이나 실험 조건은 변경 이력과 함께 기록한다.

5.2 세부 일정

기간/마감	단계	주요 산출물
2026-04-09 - 05-15	착수 및 설계	목표, 연구가설, 요구조건, 제약 분석, 평가 아키텍처, 착수보고서
2026-05-16 - 07-17	핵심 구현 및 중간 검증	데이터 파이프라인, Rule/placebo 생성기, CNN/RF, 단계적 평가 모듈, 중간보고서
2026-07-18 - 09-18	본 실험 및 최종 통합	비교군 반복 실험, 외부 교차평가, 효과 귀속 분석, 최종보고서와 최종평가표
2026-09-19 - 10-01	발표심사 준비	발표 슬라이드, 결과 재현, 예상 질문과 답변
2026-10-02 - 10월 중순	결과물 정리	SW 등록, 공개 가능 코드, 사용 설명서, 최종 산출물 업로드

5.3 구성원별 역할 분담

졸업과제 구성원은 장현진 1명이다. 따라서 하위 모듈을 다른 팀원에게 분리하지 않고, 요구사항에서 보고서까지의 end-to-end 책임을 한 구성원이 수행한다.

구분	담당 내용
구성원	202355655 장현진
연구 설계	연구질문·가설 정의, 비교군 및 단계적 평가 아키텍처 설계
데이터·구현	CAN 전처리, Rule/placebo 생성기, CNN·Random Forest 학습 파이프라인 구현
실험·분석	반복 실험, 외부 데이터셋 평가, 통계 분석과 시각화
산출물 관리	provenance 관리, 착수·중간·최종보고서 및 발표 자료 작성

표 5.2: 구성원별 역할

5.4 기대 성과 및 결과물

5.4.1 기대 성과

첫째, 합성 CAN 공격 증강의 효과를 source부터 external 단계까지 연속적으로 측정하여 분포 이동 수준별 effect profile을 제공하는 평가 프레임워크를 구축한다.

둘째, real oversampling과 matched-update 조건으로 표본 수와 학습량을 통제하고, marginal-matched placebo로 주변 분포와 구현 관계의 영향을 분리하는 효과 귀속 방법을 제시한다.

셋째, 데이터 역할, 분할, 생성 설정, pipeline seed, checkpoint 및 metric denominator를 manifest에 연결하여 다른 generator와 detector에도 재사용 가능한 실험 기반을 제공한다.

5.4.2 최종 결과물

1. 부산대학교 양식의 착수보고서, 중간보고서, 최종보고서 PDF
2. 합성 CAN 공격 생성 및 CAN IDS 학습 코드

3. 단계적 분포 이동 및 placebo-controlled 평가 모듈
4. 재현 가능한 표 · 그림과 claim-artifact manifest
5. 졸업과제 발표 자료와 결과 재현 설명서
6. 라이선스가 허용하는 범위의 SW 등록 및 공개 결과물

참고문헌

- [1] Ahmed M. Alaa, Boris van Breugel, Evgeny Saveliev, and Mihaela van der Schaar. How faithful is your synthetic data? Sample-level metrics for evaluating and auditing generative models. In *Proceedings of the 39th International Conference on Machine Learning (ICML)*, volume 162 of *Proceedings of Machine Learning Research*, pages 290–306, 2022.
- [2] Giovanni Apruzzese, Luca Pajola, and Mauro Conti. The cross-evaluation of machine learning-based network intrusion detection systems. *IEEE Transactions on Network and Service Management*, 19(4):5152–5169, 2022.
- [3] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, and Konrad Rieck. Dos and don'ts of machine learning in computer security. In *Proceedings of the 31st USENIX Security Symposium*, pages 3971–3988, 2022.
- [4] Stefan Axelsson. The base-rate fallacy and the difficulty of intrusion detection. *ACM Transactions on Information and System Security*, 3(3):186–205, 2000.
- [5] Guillaume Dupont, Jerry den Hartog, Sandro Etalle, and Alexios Lekidis. Evaluation framework for network intrusion detection systems for in-vehicle CAN. In *Proceedings of the 2019 IEEE International Conference on Connected Vehicles and Expo*, pages 1–6, 2019.
- [6] Cristóbal Esteban, Stephanie L. Hyland, and Gunnar Rätsch. Real-valued (medical) time series generation with recurrent conditional GANs. arXiv:1706.02633, 2017.
- [7] Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2:665–673, 2020.
- [8] Hacking and Countermeasure Research Lab. CAN-intrusion dataset (OTIDS). <https://ocslab.hksecurity.net/Dataset/CAN-intrusion-dataset>, 2017. Accessed 2026-06-10.
- [9] Hacking and Countermeasure Research Lab. Car-hacking dataset. <https://ocslab.hksecurity.net/Datasets/car-hacking-dataset>, 2017. Accessed 2026-06-10.
- [10] James Halvorsen, Clemente Izurieta, Haipeng Cai, and Assefaw Gebremedhin. Applying generative machine learning to intrusion detection: A systematic mapping study and review. *ACM Computing Surveys*, 56(10):1–33, 2024.
- [11] Brooke Kidmose, Andreas Kidmose, and Weizhi Meng. CAN-SLEUTH: Sleuthing out the capabilities, limitations, and performance impacts of automotive intrusion detection datasets. *International Journal of Information Security*, 24(5):193, 2025.
- [12] Karl Koscher, Alexei Czeskis, Franziska Roesner, Shwetak Patel, Tadayoshi Kohno, Stephen Checkoway, Damon McCoy, Brian Kantor, Danny Anderson, Hovav Shacham, and Stefan Savage. Experimental security analysis of a modern automobile. In *Proceedings of the 2010 IEEE Symposium on Security and Privacy*, pages 447–462, 2010.
- [13] Daniël Lakens, Anne M. Scheel, and Peder M. Isager. Equivalence testing for psychological research: A tutorial. *Advances in Methods and Practices in Psychological Science*, 1(2):259–269, 2018.
- [14] Brooke Lampe and Weizhi Meng. can-train-and-test: A curated CAN dataset for automotive intrusion detection. *Computers & Security*, 140:103777, 2024.
- [15] Hyunsung Lee, Seong Hoon Jeong, and Huy Kang Kim. OTIDS: A novel intrusion detection system for in-vehicle network by using remote frame. In *Proceedings of the 15th Annual Conference on Privacy, Security and Trust*, 2017.
- [16] Junhui Li, Nikolaos Ersotelos, Michail-Antisthenis Tsompanas, and Gregory Epiphaniou. Challenges and opportunities of synthetic data generation for machine learning-based intrusion detection systems in in-vehicle networks. *Vehicular Communications*, 58:100998, 2026.
- [17] Marc Lipsitch, Eric Tchetgen Tchetgen, and Ted Cohen. Negative controls: A tool for detecting confounding and bias in observational studies. *Epidemiology*, 21(3):383–388, 2010.

- [18] Francisco S. Melícias, Tiago F. R. Ribeiro, Carlos Rabadão, Leonel Santos, and Rogério Luís de C. Costa. GPT and interpolation-based data augmentation for multiclass intrusion detection in IIoT. *IEEE Access*, 12:17945–17965, 2024.
- [19] Donald J. Schuirmann. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6):657–680, 1987.
- [20] Eunbi Seo, Hyun Min Song, and Huy Kang Kim. GIDS: GAN-based intrusion detection system for in-vehicle network. In *Proceedings of the 16th Annual Conference on Privacy, Security and Trust*, pages 1–6, 2018.
- [21] Michael Stenger, Robert Leppich, Ian Foster, Samuel Kounev, and André Bauer. Evaluation is key: A survey on evaluation measures for synthetic time series. *Journal of Big Data*, 11(1):66, 2024.
- [22] Arash Vahidi, Thomas Rosenstatter, and Nishat I. Mowla. Systematic evaluation of automotive intrusion detection datasets. In *Proceedings of the 6th ACM Computer Science in Cars Symposium*, pages 6:1–6:12, 2022.
- [23] Boris van Breugel, Zhaozhi Qian, and Mihaela van der Schaar. Synthetic data, real errors: How (not) to publish and use synthetic data. In *Proceedings of the 40th International Conference on Machine Learning (ICML)*, volume 202 of *Proceedings of Machine Learning Research*, pages 34793–34808, 2023.
- [24] Miki E. Verma, Robert A. Bridges, Michael D. Iannacone, Samuel C. Hollifield, Pablo Moriano, Steven C. Hespeler, Bill Kay, and Frank L. Combs. A comprehensive guide to CAN IDS data and introduction of the ROAD dataset. *PLOS ONE*, 19(1):e0296879, 2024.
- [25] Xiang Wang, Jian Zhao, Pengbo Liu, Nianmin Yao, and Zheng Xu. CAN bus intrusion detection based on deep learning with data augmentation for connected autonomous vehicles. *IEEE Transactions on Vehicular Technology*, 75(2):2253–2266, 2026.
- [26] Yuanda Yang, Guoqi Xie, Jilong Wang, Jia Zhou, Ze Xia, and Renfa Li. Intrusion detection for in-vehicle network by using single GAN in connected vehicles. *Journal of Circuits, Systems and Computers*, 30(1):2150007, 2021.
- [27] Qingling Zhao, Mingqiang Chen, Zonghua Gu, Siyu Luan, Haibo Zeng, and Samarjit Chakraborty. CAN bus intrusion detection based on auxiliary classifier GAN and out-of-distribution detection. *ACM Transactions on Embedded Computing Systems*, 21(4):1–30, 2022.