

합성 CAN 공격 데이터 증강의 신뢰성 검증을 위한 단계적 평가 프레임워크 설계 및 구현

졸업과제 최종보고서



InfoSec

분과 D (하드웨어/보안)
정보컴퓨터공학부 인공지능전공
졸업과제번호: 46
202355655 장현진
이메일: hyunjin@islab.re.kr

지도교수: 김호원

제출일: 2026년 9월 14일

부산대학교

요약

차량 내부 통신망인 Controller Area Network(CAN)의 침입탐지 모델을 학습하려면 다양한 공격 데이터가 필요하지만, 실제 차량에서 이를 충분히 수집하기는 어렵다. 본 과제는 규칙 기반 합성 공격 데이터가 탐지 성능에 미치는 영향을 평가하는 Shift Ladder 프레임워크를 설계하고 구현하였다. 학습량을 통제된 성능 비교에서 출발하여 공격 조건과 차량 환경의 변화, 생성 데이터의 관계 구조를 차례로 분석하였다.

시스템은 데이터 분리, 합성 공격 생성, 탐지기 학습, L0-L6 평가, 통계 분석 및 재현성 관리로 구성된다. Car-Hacking을 학습 데이터로 사용하고, 128개 CAN 메시지를 하나의 입력으로 묶어 1D-CNN과 Random Forest를 학습하였다. 실제 데이터만 사용한 모델, 실제 공격 복제 모델 및 합성 증강 모델을 비교하였으며, 학습 횟수 통제와 원시 메시지가 겹치지 않는 평가를 추가하였다. OTIDS, ROAD, can-train-and-test는 학습과 분리한 외부 평가에 사용하였다.

동일한 7,992회 학습 갱신 조건에서 실제 학습 자료의 30%에 해당하는 합성 표본을 추가한 Rule +30% 모델의 고정 변형 탐지율은 99.99%였다. 실제 데이터만 학습한 모델의 49.75%보다 50.25%p 높았으며, 공격 강도와 구조를 함께 바꾼 평가에서도 55.10%에서 72.00%로 16.90%p 향상되었다. 두 차이는 다섯 학습 반복에서 모두 양수였고 비중첩 평가에서도 유지되었다. 한편 생성 규칙을 벗어난 복합 변형에서는 공격 유형 재현율이 8.93%로 낮아졌으며, Rule +30% CNN의 외부 데이터 정상 오탐률은 거의 100%에 도달하였다.

성능 변화의 원인을 분석한 요인 교차 실험에서는 페이로드 위치의 영향이 가장 컸다. 이어 20개 생성 반복에서 주입 조건과 값 분포를 맞춘 대조군(placebo)을 구성하여 위치 이동 반응을 분해하였다. 학습 위치에서의 관계 활용도와 탐지 효용은 별도로 평가하였다. 100개 새 생성 반복과 1,000회 CNN 학습에서 관계 활용도는 +2.64%p였고 97.5% 신뢰구간은 [+2.51, +2.77]%p였다. 탐지 효용 차이는 +0.11%p로 추정되었으며 구간은 0을 포함하였다. 유용한 관계를 갖도록 설계한 별도 합성 양성 대조에서는 CNN과 관계 특징을 추가한 Random Forest 모두 약 35.7-35.9%p의 효용을 회복하였다.

본 과제는 데이터 생성, 탐지기 학습, 단계적 평가와 대조 실험을 하나의 시스템으로 통합하였다. 이를 통해 합성 증강의 탐지 효과와 모델이 활용한 생성 요소를 함께 분석하는 평가 절차를 제시하였다.

목차

요약	i
1 서론	1
1.1 연구 배경	1
1.2 문제 정의	1
1.3 과제 목표와 연구질문	1
1.4 주요 연구 기여	2
1.5 보고서 구성	2
2 배경 및 관련 연구	3
2.1 CAN 공격과 침입탐지	3
2.2 CAN IDS 데이터셋과 외부 평가	3
2.3 합성 데이터 증강과 평가 공백	3
2.4 주요 용어와 평가 단위	3
2.5 본 연구의 위치	4
3 시스템 설계와 구현	5
3.1 전체 구조	5
3.2 요구조건과 설계 대응	5
3.3 Shift Ladder의 평가 조건과 판정 규칙	6
3.4 공격 생성과 탐지 모듈	6
3.5 데이터 처리와 모듈 구현	7
3.6 소프트웨어 구성과 실행 절차	10
3.7 착수 이후의 설계 변경	10
4 데이터 및 실험 방법	12
4.1 데이터 역할과 전처리	12
4.2 학습군과 학습량 통제	12
4.3 공격 변형과 외부 데이터 평가	13
4.4 지표의 계산과 비교 원칙	13
4.5 요인 교차와 생성 반복 설계	13
4.6 분포를 맞춘 대조군의 반응 분해	13
4.7 실행 환경과 재현성	14
5 실험 결과	15
5.1 학습 도메인 내 합성 증강의 탐지 효용	15
5.2 원시 메시지 비중첩 평가	16
5.3 공격 강도와 유형 및 생성 규칙 변화에 따른 결과	17
5.4 요인별 효과와 생성 반복 검증	17
5.5 외부 데이터의 운영점과 점수 순위	18
5.6 맞춤 대조군을 통한 관계 효과 분석	20
6 관계 활용과 탐지 효용의 확장 검증	22
6.1 관계 활용도, 탐지 효용과 위치 이동 효과	22
6.2 입력 표현에 따른 관계 정보의 반영	23
6.3 관계 학습을 확인하는 양성 대조 실험	24
6.4 새로 생성한 자료를 이용한 100회 재현 실험	24
6.5 확장 검증의 시사점	26
6.6 연구질문과 착수 가설의 종합	26
7 연구 결과의 의미와 적용 범위	27
7.1 증강 효과와 관계 활용	27
7.2 외부 환경에서의 적용	27
7.3 적용 범위	27
8 시스템 산출물과 학술 성과	28
8.1 주요 산출물	28
8.2 학술 성과	28
9 결론	29

그림 목차

3.1	평가 시스템의 데이터 흐름과 Shift Ladder	5
5.1	동일 학습량 조건의 합성 증강 탐지 효용	16
5.2	E15 요인 교차 실험의 반응 비교	18
5.3	외부 데이터의 정상 오탐률과 공격 탐지율	19
5.4	E16 페이로드 위치 변경 반응의 분해	21
6.1	새 생성 반복의 재현율 곡선과 관계 평가량	25

표 목차

2.1	주요 용어와 평가 단위	4
3.1	착수 요구조건과 최종 구현·검증의 대응	6
3.2	Shift Ladder의 평가 조건과 분석 목적	7
3.3	CNN과 RF의 주요 명세	7
3.4	기본 합성 공격의 구성과 관찰 특성	8
3.5	CNN 계층별 배열 크기와 역할(배치 자원 제외)	9
3.6	소프트웨어 실행 단계와 입출력	10
3.7	착수·중간·최종 단계의 설계 변화	11
4.1	데이터셋별 역할과 평가 규모	12
5.1	주요 실험의 목적과 반복 단위	15
5.2	동일 7,992회 갱신 조건의 CNN 결과(다섯 학습 반복, 평균±표본표준편차)	16
5.3	원시 메시지 비증첩 평가의 공격 탐지율 대응 차이(다섯 학습 반복)	16
5.4	E15 기준 CAN ID의 Gear/RPM 평균 유형 재현율에 대한 요인 효과(Rule-실제 자료 기준군, $n = 4$)	17
5.5	Rule +30% 외부 점수 순위 분석(세 학습 반복, 평균±표본표준편차; Δ 는 실제 자료 기준군 대비 차이)	18
5.6	L6 진단: 입력 특성 제거에 따른 CNN의 외부 FPR / 공격 탐지율	19
5.7	E16 위치 이동 반응 분석($n = 20$ 생성 반복, 반복마다 다섯 학습 결과 평균)	20
6.1	관계 효과를 분석하는 세 평가량	22
6.2	입력 표현과 위치 이동 반응의 비교(같은 20개 생성 반복과 학습량)	23
6.3	유용한 관계의 합성 양성 대조 결과($n = 20$ 생성 반복)	24
6.4	새 생성 반복의 공동 주평가량($k = 8, n = 100$)	25
6.5	연구질문과 착수 가설별 종합 결과	26
8.1	과제의 주요 산출물	28

제1장 서론

1.1 연구 배경

차량의 엔진, 변속기, 제동 장치 등은 전자제어장치(ECU)가 처리하는 메시지를 통해 상태와 제어 정보를 교환한다. CAN은 이러한 차량 내부 통신에 널리 쓰이는 통신망이다. 침입탐지시스템(IDS)은 수집한 CAN 메시지의 식별자, 데이터 값, 길이와 시간 간격을 분석하여 정상 통신과 공격을 구분한다. 기존 CAN 프로토콜은 송신자 인증 기능을 기본 제공하지 않으므로, 통신망에 접근한 공격자는 정상 식별자를 재사용해 메시지를 주입·재생하거나 대량 전송으로 통신을 방해할 수 있다[8].

지도학습 CAN IDS는 공개 데이터셋에서 높은 성능을 보이지만, 수집된 공격의 종류가 제한적이고 차량·수집 장비·공격 구현에 따라 데이터 분포가 달라진다 [11]. 합성 데이터 증강은 부족한 공격 유형과 변형을 보충하는 방법이다. 다만 생성 자료와 평가 자료가 같은 규칙을 공유하면 탐지기가 특정 바이트 위치나 값 분포에 의존할 수 있다. 따라서 합성 표본을 추가한 효과와 그 효과가 유지되는 조건을 함께 평가할 필요가 있다.

1.2 문제 정의

증강 전후의 시험 점수를 비교할 때는 세 가지를 구분해야 한다. 첫째, 표본 수와 학습 횟수의 증가가 만든 효과와 합성 표본의 내용이 만든 효과다. 둘째, 공격의 존재를 탐지하는 성능과 공격 유형을 식별하는 성능이다. 셋째, 새로운 차량에서의 공격 탐지율과 정상 통신에 대한 오탐률이다. 이 구분이 있어야 성능 향상의 원인과 실제 적용 가능성을 판단할 수 있다.

본 과제는 학습량, 공격 변형, 유형 식별, 외부 분포, 생성 관계를 차례로 분석하는 평가 구조를 제안한다. 먼저 공정한 학습 조건에서 증강의 탐지 효과를 측정하고, 조건을 바꾼 평가로 효과의 분포를 파악한다. 이어 생성 표본의 주변 조건을 맞춘 대조군을 도입하여 성능 반응을 설명한다. 이 구조를 통해 탐지기의 성능 비교와 합성 데이터의 설계 요소 분석을 연결한다.

1.3 과제 목표와 연구질문

본 과제의 목표는 합성 증강의 탐지 효과와 생성 요소의 기여를 함께 평가하는 시스템을 구현하는 것이다. 이를 다음 네 연구질문으로 구체화하였다.

- RQ1. 규칙 기반 합성 증강의 탐지 이득은 같은 표본 수·같은 학습량의 대조와 비중첩 평가에서도 유지되는가?
- RQ2. 이득은 공격 강도, 공격 계열, 대상 CAN ID와 생성 문법의 변화에 따라 어떻게 달라지며, 어떤 입력 요소에서 큰 반응이 나타나는가?
- RQ3. 학습 도메인에서 정한 판정 기준과 점수 순위는 외부 차량 데이터에서 실제 자료만 학습한 모델보다 개선되는가?
- RQ4. 생성된 Gear/RPM 관계의 활용도, 탐지 효용 및 페이로드 위치 이동에 대한 반응은 맞춤 대조군과의 비교에서 어떻게 구분되는가?

착수 단계에서 설정한 가설은 다음과 같으며, 실험 결과에 따른 판정은 제6장에서 정리한다.

- H1** 규칙 기반 합성 증강은 학습 도메인 시험 성능을 유지하면서 고정 변형(L1)의 탐지율을 실제 자료만 학습한 모델, 실제 공격 복제 모델과 동일 학습량 대조군보다 사전에 정한 최소 효과 이상 높일 것이다.
- H2** 결합 변형(L2)에서 증강 효과는 공격 강도가 커질수록 줄어들고 그 기울기는 공격 계열에 따라 다를 것이다. L3와 L4는 별도 대비로 분석한다.
- H3** 생성 문법 밖 복합 변형(L4)에서는 L1보다 공격 탐지율과 정확한 유형 재현율의 격차가 커질 것이다.
- H4** 학습 도메인에서 고정한 판정 기준을 외부 데이터에 적용했을 때, 합성 증강은 FPR 허용 한계를 만족하면서 공격 탐지율을 높일 것이다.
- H5** 주변 조건을 맞춘 placebo와 Rule 생성기의 비교에서 생성 반복 평균의 Gear/RPM 관계 증분 $\bar{\theta}$ 는 사전에 정한 실질적 한계를 넘을 것이다.

1.4 주요 연구 기여

본 과제의 기여는 다음과 같다.

1. 학습 · 외부 데이터의 역할 분리와 L0-L6 Shift Ladder를 구현하여, 학습 도메인 성능, 공격 변형과 외부 운영점을 하나의 평가 절차로 연결하였다.
2. 실제 공격 복제와 동일 갱신 횟수 대조 및 원시 메시지 비중첩 평가를 결합하여, 공정한 학습 조건에서 합성 표본의 탐지 이득을 확인하였다.
3. 공격 탐지와 정확한 유형 식별을 분리하고, 외부 오염률 · 탐지율 · 점수 순위를 함께 분석하여 평가 조건별 성능을 해석하는 기준을 마련하였다.
4. 요인 교차 실험과 맞춤 대조군으로 전체 증강 반응을 분해하고 관계 활용도 · 탐지 효용 · 위치 이동 효과를 각각 추정하였다. 새 생성 반복의 재현 실험과 유용한 관계의 양성 대조로 평가 절차 자체의 검출 능력도 검증하였다.

1.5 보고서 구성

제2장은 관련 연구와 본 과제의 차별성을 정리한다. 제3장은 시스템과 상세 구현을, 제4장은 데이터 · 대조군 · 통계 방법을 설명한다. 제5장은 단계적 평가와 요인별 분석 결과를 제시한다. 제6장은 관계 활용도와 탐지 효용의 확장 검증 및 연구질문별 종합을 다룬다. 제7장은 결과의 의미와 적용 범위를, 제8장은 시스템 산출물과 학술 성과를 정리한다. 제9장은 핵심 결과와 후속 연구 방향을 제시한다.

제2장 배경 및 관련 연구

2.1 CAN 공격과 침입탐지

CAN IDS에는 메시지 주기와 시간 간격을 분석하는 통계적 방법 [13]과 메시지의 연속 패턴을 학습하는 신경망 기반 방법 [6]이 있다. 학습 기반 탐지기의 평가에서는 데이터 분리와 비교 조건이 중요하다. 공격 수집 과정에서 반복되는 주기나 식별자 구성이 모델의 학습 단서가 될 수 있기 때문이다[1].

본 연구에서 공격 탐지는 입력 구간에 공격 메시지가 있는지 판단하는 문제이며, 공격 유형 식별은 DoS, Fuzzy, Gear, RPM 중 해당 유형을 맞히는 문제다. 두 성능을 각각 계산하고, 외부 평가에서는 정상 자료에 대한 오탐률을 함께 측정한다.

2.2 CAN IDS 데이터셋과 외부 평가

Car-Hacking은 단일 차량에서 수집한 DoS, Fuzzy, Gear 및 RPM 공격을 포함한다 [5]. 본 과제는 이를 탐지기 학습과 내부 평가에 사용하였다. 외부 평가는 세 데이터셋으로 구성하였다. OTIDS는 원격 프레임과 차량 내부 공격을 제공하며[4], ROAD는 실제 차량에서 검증한 위장 공격과 정상 주행 자료를 포함한다[14]. can-train-and-test는 여러 차량과 수집 환경의 자료를 구분하여 제공한다[10].

차량과 수집 환경이 바뀌면 CAN ID의 구성, 페이로드 값, 메시지 간격과 공격 레이블도 달라진다. 본 과제는 학습 도메인에서 정한 판정 기준을 외부 데이터에 그대로 적용하여 오탐률과 탐지율을 측정한다. 점수의 구분 능력은 AUROC와 평균 정밀도(AP)로 분석한다.

2.3 합성 데이터 증강과 평가 공백

GIDS는 GAN 기반 CAN 침입탐지를 제안하였으며[12], 이후에는 보조 분류기 GAN을 이용한 공격 생성과 분포 밖 탐지가 연구되었다 [15]. 이러한 방법은 부족한 공격 표본을 보완하지만, 생성 과정의 특정 패턴에 의존하는 지름길 학습(shortcut learning)도 고려해야 한다 [3].

본 과제는 증강 효과를 세 종류의 대조로 분석한다. 실제 공격 복제 대조는 표본 수 증가의 효과를, 동일 학습량 대조는 갱신 횟수와 모델 선택 기회의 차이를 통제한다. 맞춤 대조군은 주입 조건과 값 분포를 유지하면서 목표 관계를 변경하여, 생성 관계가 모델의 반응과 성능에 미치는 영향을 측정한다.

2.4 주요 용어와 평가 단위

표 2.1는 설계와 결과 설명에 사용하는 용어를 정리한다.

용어	본 보고서에서의 의미
학습 도메인 / 외부 도메인	학습 · 검증 · 내부 평가에 사용하는 Car-Hacking / 별도 차량 · 수집 환경의 평가 데이터
프레임 / 원도	CAN 메시지 1개 / 연속된 128개 메시지로 구성된 탐지 입력
규칙 기반 증강	정해진 공격 생성 규칙으로 만든 표본을 실제 학습 자료에 추가하는 방법
Binary / exact recall	공격을 탐지한 비율 / 공격 유형까지 정확히 맞힌 비율
FPR	정상 자료를 공격으로 잘못 판정한 비율
학습 반복(시드)	표본 선택 · 초기화 · 학습 순서 등을 함께 정하는 난수 초기값에 따른 반복
생성 반복(realization)	동일 생성 규칙으로 새로 구성한 합성 데이터 묶음
Matched placebo	주입 조건과 채널별 값 분포를 맞추고 구현 관계를 교란한 대조군
학습군(arm)	같은 구조의 탐지기를 서로 다른 학습 자료 구성으로 학습한 비교 단위
학습량(update budget)	학습군에 공통으로 적용한 매개변수 갱신 횟수와 검증 간격
평가량(estimand)	실험 전에 정의한 추정 대상; 학습군 또는 생성 반복 사이의 대응 차이
기준 조건(anchor) / 조합 (cell)	요인 교차에서 모든 요인을 학습 조건에 둔 조건 / 요인 값의 한 조합에 해당하는 평가 조건
동등성 검정(TOST)	차이가 사전에 정한 한계 안에 있는지 90% 구간으로 판정하는 절차

표 2.1: 주요 용어와 평가 단위

2.5 본 연구의 위치

본 과제는 동일한 탐지기에서 학습 자료의 구성을 바꾸었을 때 나타나는 성능 차이를 분석한다. Shift Ladder로 평가 조건별 증강 효과를 측정하고, 요인 교차와 맞춤 대조군으로 그 차이를 생성 표본의 위치 · 값 분포 · 관계 구조와 연결한다.

평가 조건 r 의 성능을 M_r 라고 하면, 증강 효과는 다음 차이로 측정한다.

$$\Delta_r = M_r(\text{증강 학습}) - M_r(\text{실제 자료 학습}). \quad (2.1)$$

Shift Ladder는 공격 변형과 외부 데이터에서 이 차이를 비교한다. 탐지율과 유형별 재현율은 증가할수록, 정상 오탐률은 감소할수록 개선을 나타낸다. 실제 공격 복제와 학습량 통제로 추가 표본의 내용에 따른 효과를 확인하고, 맞춤 대조군으로 생성 규칙의 특정 관계가 성능에 기여하는지 분석한다.

제3장 시스템 설계와 구현

3.1 전체 구조

시스템은 데이터 분리, 합성 공격 생성, 탐지기 학습, 단계적 평가, 통계 분석과 재현성 검증의 여섯 모듈로 구성된다. 그림 3.1과 같이 생성기는 실제 학습 자료를 사용하고, 검증 자료는 모델 선택과 판정 기준 설정에 사용한다. 내부 시험 자료와 외부 데이터는 평가용으로 분리한다. 외부 정상 자료를 이용한 보정과 점수 순위 분석은 외부 성능 저하의 원인을 살펴보는 진단 절차다.

Leakage-controlled data flow

Primary training and selection use source-side data; external data enter evaluation or declared diagnostics.




그림 3.1: 평가 시스템의 데이터 흐름과 Shift Ladder. 파란색은 학습 자료와 탐지기, 초록색은 합성 자료, 분홍색은 외부 평가를 나타낸다. 점선은 학습·모델 선택과 분리한 진단 경로다.

3.2 요구조건과 설계 대응

착수 단계에서 정의한 기능 요구조건과 구현 내용은 표 3.1와 같다.

표 3.1: 착수 요구조건과 최종 구현·검증의 대응

ID	요구조건	최종 구현과 확인 근거
FR-01	데이터 역할 분리	학습·검증·시험 자료를 먼저 분할하고 원본 행의 중복 검사; 외부 데이터는 평가 전용으로 사용
FR-02	학습 자료 기반 생성	생성기와 표준화에 실제 학습 자료만 사용하고 생성 조건·표준화 통계 기록
FR-03	비교군 구성	실제 자료 학습, 실제 공격 복제, Rule 증강을 구성하고 7,992회 갱신 조건에서 비교
FR-04	반복 학습	다섯 학습 반복의 학습·선택 이력을 저장하고 반복별 대응 차이 산출
FR-05	단계적 평가	L0-L6의 조건별 평가와 독립 결과 표·그림 생성
FR-06	지표 분리	공격 탐지율, 유형 재현율, macro-F1과 정상 오탐률을 각각 산출
FR-07	외부 평가 분리	외부 레이블은 성능 측정에 사용하고 학습·모델 선택에서는 제외
FR-08	관계 효과 분석	맞춤 대조군과 Rule의 반응 차이 및 동등성 구간 계산
FR-09	근거 추적	입력 데이터, 선택 모델과 반복별 측정값을 연결하여 본문 수치 확인

실제 공격 표본의 부족에는 합성 증강을 적용하고, 차량별 분포 차이는 외부 평가로 분석하였다. 입력 구간의 중첩이 결과에 미치는 영향은 원시 메시지 비중첩 평가로 확인하였다. 반복 실험은 자동 실행하고 입력·모델·결과를 연결해 보존하였다.

3.3 Shift Ladder의 평가 조건과 판정 규칙

생성 문법은 CAN ID, DLC, 페이로드, 시간 간격과 배치의 변환 규칙을 뜻한다. Shift Ladder는 이러한 규칙과 평가 환경을 단계적으로 변화시키며 증강의 효과를 관찰하는 절차다. 표 3.2는 각 단계가 답하는 질문을 제시한다.

3.4 공격 생성과 탐지 모듈

규칙 생성기는 학습용 정상 구간에 DoS, Fuzzy, Gear 및 RPM 공격을 삽입한다. 각 유형은 주입 위치와 개수, CAN ID, 페이로드 값과 시간 간격으로 정의한다. 학습용 생성 자료와 평가용 변형은 정상 배경과 설정을 분리하여 구성한다.

주분석 탐지기는 메시지의 연속 패턴을 학습하는 1D-CNN이며, 채널별 요약 통계로 학습하는 Random Forest(RF)를 비교 모델로 사용하였다[2]. 외부 운영점 그림에는 기존 실험의 BiLSTM과 Transformer도 참고 결과로 제시한다. 제6장의 BiLSTM 비교는 E16과 같은 생성 반복·학습량에서 신경망 구조를 바꾼 별도 실험이다.

표 3.2: Shift Ladder의 평가 조건과 분석 목적

단계	평가 조건	분석 목적
L0	학습 도메인의 분리된 시험 자료	기본 탐지 성능과 증강 후 성능 유지 확인
L1	생성 규칙을 공유하는 고정 변형	같은 학습량에서 합성 표본이 추가한 탐지 범위 측정
L2	공격 강도 · 구조의 결합 변형	공격 계열과 설정별 증강 효과의 변화 분석
L3	공격 대상 CAN ID 이동	학습한 식별자와 다른 식별자에서 유형 인식 평가
L4	페이로드 위치 등을 바꾼 복합 변형	공격 탐지와 유형 식별의 차이 및 요인별 반응 분석
L5	외부 차량 · 수집 데이터	정상 오탐률과 공격 탐지율을 함께 고려한 전이 평가
L6	특성 제거와 보정 진단	분포 차이와 입력 특성이 결과에 미친 영향 분석

3.4.1 입출력과 탐지기 상세 명세

탐지기는 CAN ID, DLC, 8개 페이로드 바이트와 메시지 간 시간 간격으로 구성된 11개 채널을 입력으로 받는다. 연속된 128개 메시지를 묶은 CNN 입력의 크기는 11×128 이며, 출력은 정상 · DoS · Fuzzy · Gear · RPM 다섯 클래스의 점수다.

표 3.3: CNN과 RF의 주요 명세

구성	명세
CNN 특징 추출	1차원 합성곱 3층: 채널 $11 \rightarrow 64 \rightarrow 128 \rightarrow 128$, 커널 크기 5, 5, 3. 각 층에 배치 정규화와 ReLU 적용
CNN 집계 · 분류	앞 두 합성곱 뒤 최대 풀링, 마지막에 적응형 평균 풀링; 드롭아웃 0.2와 5 클래스 선형 출력층
CNN 학습	클래스 가중 교차엔트로피, AdamW, 학습률 10^{-3} , 가중치 감쇠 10^{-4} , 배치 크기 512
RF 입력	11개 채널마다 평균 · 표준편차 · 최솟값 · 최댓값 · 마지막 값과 첫 값의 차이를 계산한 55차원 특징
RF 모델	결정 트리 160개, 최대 깊이 제한 없음, 잎 노드 최소 표본 2, 클래스 가중 <code>balanced_subsample</code>
모델 선택	학습 도메인 검증 자료의 다중분류 macro-F1이 가장 높은 CNN 선택

3.5 데이터 처리와 모듈 구현

3.5.1 공통 메시지 표현과 입력 구성

데이터셋별 로그를 같은 형식으로 처리하기 위해 CAN 식별자를 정수로 변환하고, 페이로드를 8 바이트로 맞춘다. DLC가 8보다 작으면 나머지 바이트를 0으로 채운다. 여기에 인접 메시지의 시간

차이를 더해 메시지 i 를 다음과 같이 표현한다.

$$\mathbf{x}_i = [\text{ID}_i, \text{DLC}_i, b_{i,0}, \dots, b_{i,7}, \Delta t_i] \in \mathbb{R}^{11}. \quad (3.1)$$

연속된 128개 메시지를 묶어 128×11 크기의 윈도를 구성한다. CNN에는 이를 11×128 배열로 전달하고, RF에는 채널별 요약 통계를 전달한다.

CNN 입력은 실제 학습 자료의 채널별 평균 μ_c 와 표준편차 σ_c 를 사용해 $z_{i,c} = (x_{i,c} - \mu_c)/\sigma_c$ 로 표준화한다. 같은 통계를 검증·시험·합성·외부 자료에도 적용하여 입력의 기준을 일관되게 유지한다.

공격 자료는 시간 순서에 따라, 정상 자료는 연속 구간 단위로 분할한 뒤 각 분할 안에서 윈도를 구성한다. 원본 파일과 행 번호를 대조해 분할 간 메시지 중복을 검사하고, 시험 윈도 사이의 중첩이 결과에 미치는 영향은 비중첩 평가로 확인한다.

3.5.2 공격 생성기의 입력·출력과 구성 원리

생성기는 정상 윈도, 공격 계열, 생성 설정과 난수 초기값을 입력받아 공격을 삽입한 윈도와 유형 레이블을 출력한다. 먼저 주입 위치를 정하고, 해당 위치의 식별자, 페이로드와 시간 간격을 공격 계열별 규칙에 따라 바꾼다.

기본 합성 자료는 공격 계열마다 65,000개씩, 총 260,000개 윈도로 구성한다. 이 중 필요한 수를 계열별로 추출해 실제 학습 자료에 추가한다. 평가용 고정 변형과 강도·구조 변형은 학습 자료와 분리한 정상 배경에서 생성한다.

표 3.4: 기본 합성 공격의 구성과 관찰 특성

계열	학습용 생성의 주요 요소	탐지 입력에서의 변화
DoS	ID 0x000, 길이 32-90의 연속 주입 구간, 1-2 간격의 주입, 짧은 메시지 시간 간격	특정 식별자 집중과 반복 메시지 증가
Fuzzy	0-2047 범위의 식별자, DLC 2/5/8, 무작위 페이로드와 주입 설정	다양한 식별자·길이·값의 조합
Gear	ID 0x43F, 바이트 0/1의 계단식 값 변화와 역관계, 주입 위치·길이 변화	특정 바이트의 값 변화와 바이트 간 관계
RPM	ID 0x316, 바이트 0/1의 결합 값과 바이트 2의 교란	결합 값의 변화와 시간 패턴

생성 설정을 조절하면 같은 정상 배경과 공격 개수를 유지하면서 페이로드 위치나 값의 변화 규칙을 바꿀 수 있다. 이를 학습 자료 증강과 요인별 성능 분석에 활용하였다.

3.5.3 CNN의 계층별 정보 처리

CNN의 세 합성곱 층은 인접 메시지의 패턴을 추출하고, 풀링 층은 이를 더 넓은 시간 구간의 특징으로 통합한다. 표 3.5는 각 단계의 배열 크기와 역할을 보여준다.

표 3.5: CNN 계층별 배열 크기와 역할(배치 차원 제외)

처리 단계	출력 크기	역할
입력 원도	11×128	CAN 필드와 시간 간격
합성곱 1 · 정규화 · ReLU	64×128	5개 메시지 주변의 국소 패턴 추출
최대 풀링 1	64×64	시간축 요약
합성곱 2 · 최대 풀링 2	128×32	중간 특징 통합과 시간축 축소
합성곱 3 · 정규화 · ReLU	128×32	통합된 공격 패턴 추출
전역 평균 풀링	128×1	원도 전체의 특징 집계
Dropout · 선형 분류	5	정상 및 네 공격 유형의 점수

3.5.4 반복 실험의 실행과 결과 집계

실험은 데이터 선택, 모델 초기화, 학습, 검증, 시험 평가, 결과 집계 순서로 진행한다. 학습 반복의 난수 초기값은 표본 선택과 모델 학습에 적용하고, 생성 반복의 난수 초기값은 합성 자료 구성에 사용한다. 두 값을 별도로 관리해 학습 과정과 자료 생성에서 발생하는 변동을 각각 측정한다.

동일 학습량 비교에서는 다음 절차를 적용하였다.

1. 실제 학습 · 검증 자료를 고정하고 학습군별 추가 표본을 구성한다.
2. 같은 CNN 구조와 최적화 설정으로 세 학습군을 각각 7,992회 갱신한다.
3. 666회마다 동일한 검증 자료에서 다중분류 macro-F1을 계산한다.
4. 검증 점수가 가장 높은 모델을 선택하고, 동물이면 먼저 얻은 모델을 선택한다.
5. 선택한 모델로 학습 도메인의 시험 자료, 고정 변형과 결합 변형을 평가한다.
6. 같은 난수 초기값을 사용한 학습군끼리 성능 차이를 구하고, 다섯 반복의 평균과 표준편차를 산출한다.

선택한 모델의 학습 시점, 반복별 예측 건수와 성능, 학습군 간 차이를 저장한다. 공격 탐지율, 유형별 재현율, 정상 오탐률과 보고서의 표 · 그림은 이 기록에서 산출한다.

3.5.5 맞춤 대조군 생성과 검사

맞춤 대조군은 각 Rule 원도와 일대일로 대응한다. 정상 배경, 공격 레이블, 주입 위치 · 개수, CAN ID, DLC, 시간 간격과 변경 대상이 아닌 바이트를 보존한다. 대상 바이트는 원도 안에서 각 값의 출현 횟수를 유지하며 배치만 변경한다.

생성 후에는 보존 대상 필드와 값의 출현 횟수가 같은지, Gear 역관계와 RPM 결합 조건이 의도대로 바뀌었는지 검사한다. 두 학습군의 표본 선택과 학습 설정도 대조한다. 제6장에서는 이러한 조작이 모델의 입력 특징과 성능에 미친 영향을 분석한다.

3.6 소프트웨어 구성과 실행 절차

시스템은 Python 명령행 스크립트로 구현하였다. 설정 파일에 데이터 경로, 분할 정책, 입력 구간의 길이와 이동 간격을 지정하고, 실험별 실행 계획에 난수 초기값과 학습량을 기록한다. 각 스크립트는 이전 단계의 산출물을 읽어 다음 단계의 입력을 생성한다. 표 3.6는 실행 단계별 입력, 출력과 자동 검사를 정리한다.

표 3.6: 소프트웨어 실행 단계와 입출력

단계	입력	출력과 자동 검사
전처리 · 분할	공개 데이터셋의 원본 로그	공동 11채널 표현, 시간 순서 분할, 128-프레임 윈도우 배열; 분할 간 원본 행 중복 검사
합성 생성	학습용 정상 윈도우, 생성 설정, 생성 시드	계열별 합성 묶음과 레이블, 평가용 변형(L1-L4), 맞춤 대조군 쌍; 값 개수 · 관계 조건 검사
탐지기 학습	학습군 구성, 학습 시드, 갱신 횟수	선택 모델, 학습 이력, 검증 점수 기록; 학습군 간 동일 행 선택 검사
단계별 평가	선택 모델, 평가 윈도우	L0-L4 예측 건수와 정상 오탐률 · 공격 탐지율 · 유형 재현율
외부 평가 · 진단	선택 모델, 외부 데이터	고정 판정 기준의 운영점, AUROC/AP, 저-FPR TPR, ID 제거 · 보정 진단(L5-L6)
통계 · 그림	반복별 결과표	대응 차이, 신뢰구간, Holm 보정, TOST; 본문 표 · 그림과 입력 파일의 해시 기록

실험별 비교 조건과 분석 계획을 고정한 뒤 반복 실행을 자동화하였다. 결과표에는 버전을 부여하고, 지표 계산과 그림 생성 과정에는 자동 검사를 적용하였다.

3.7 착수 이후의 설계 변경

착수 단계의 평가 설계는 기본 비교군과 Shift Ladder 구현을 거쳐, 학습량 통제와 관계 분석으로 구체화되었다. 주요 변경 사항과 그 이유는 표 3.7과 같다.

표 3.7: 착수 · 중간 · 최종 단계의 설계 변화

설계 요소	착수 계획	중간 구현	최종 구현과 변경 이유
학습 대조군	실제 자료, 공격 복제, Rule 및 맞춤 대조군 비교	기본 비교군과 증강 비율별 CNN/RF 학습	갱신 횟수와 검증 간격을 통일하여 학습 기회의 차이 통제
평가 단위	공격 구간 · 시간 기반 분할과 비중첩 평가	길이 128, 이동 간격 32의 입력 구간 구성	원시 메시지가 겹치지 않는 부분집합에서 중첩의 영향 확인
외부 판정	정상 오탐률을 고려한 탐지 성능 평가	고정 판정 기준의 오탐률 · 탐지율 측정	AUROC · AP · 저오탐률 탐지율로 판정 기준과 점수 순위의 영향 구분
생성 규칙 변화	L4 복합 변형 평가	공격 탐지와 유형 식별의 차이 관찰	세 요인의 교차 실험과 네 생성 반복으로 위치 효과 · 상호작용 분석
관계 분석	20개 생성 반복의 맞춤 대조군과 동등성 검정	외부 ID 제거 · 보정 진단	생성 관계를 교란한 대조군으로 위치 이동 반응의 차이 추정
재현성	설정 · 수치 기록	실행 기록과 원본 측정표 연결	분석 계획, 입력 식별값, 모델별 이력과 검증 절차 확립

이후에는 관계가 유용하도록 설계한 양성 대조와 100개 새 생성 반복의 재현 실험을 추가하여, 관계 효과를 측정하는 절차와 결과의 일관성을 검증하였다.

제4장 데이터 및 실험 방법

4.1 데이터 역할과 전처리

표 4.1은 데이터셋별 역할과 규모를 요약한다. Car-Hacking의 공격 자료는 유형별 수집 로그 안에서 시간 순서에 따라 학습·검증·시험용으로 60/20/20 분할하였다. 정상 자료도 연속 구간을 먼저 나누는 뒤 입력 구간을 구성하였다. 약 1,756만 개 메시지의 원본 파일과 행 번호를 대조하여 분할 간 중복이 없음을 확인했으며, 학습·검증·시험용 입력은 각각 약 26.2만·8.5만·20.2만 개다.

표 4.1: 데이터셋별 역할과 평가 규모

데이터셋	역할	입력 구간 수	사용 원칙
Car-Hacking	학습·검증·내부 시험	26.2만/8.5만/20.2만	생성기 구성, 탐지기 학습·선택과 단계적 평가
OTIDS	외부 평가	약 14.4만	정상·공격별 오탐률·탐지율과 점수 순위 분석
can-train-and-test	외부 평가·진단	약 449만	고정 모델 평가와 별도 재학습 진단
ROAD	외부 평가	약 85.7만	정상 로그 12개와 공격 로그 29개의 운영점 평가

길이 128, 이동 간격 32의 입력 구간에 공격 메시지가 하나라도 있으면 공격으로 표시한다. 공격 유형은 해당 구간에서 가장 많이 나타난 공격 레이블로 정하고, 동물이면 미리 정한 유형 순서를 따른다. 외부 데이터셋은 공격 레이블 체계가 서로 달라 정상·공격을 구분하는 이진 오탐률과 탐지율로 평가한다.

4.2 학습군과 학습량 통제

학습군은 실제 데이터만 사용하는 기준군, 실제 공격을 복제하는 대조군, 규칙 기반 합성 표본을 추가하는 Rule 증강군으로 구성한다. 증강 비율은 실제 학습 원도 전체 개수에 대한 추가 합성 원도의 비율이다. 실제 학습 자료 262,149개에 대한 +30% 조건은 합성 표본 78,645개를 추가한다. 실제 공격 복제 대조군도 같은 수를 추가한다. 합성 비율을 높인 +100% 조건은 제5장의 결합 변형 보정 결과와 RF 외부 평가에 쓰는 확장 비교이며, 생성 묶음을 새로 구성하고 요청 수·추출 수·고유 표본 수를 일치시켜 비복원 추출을 적용하였다. 주분석의 Rule 대조는 +30%다.

실험 목적에 따라 두 학습량을 사용하였다. L1과 L2의 증강 효과 비교에서는 세 학습군을 각각 7,992회 갱신하고 666회마다 같은 검증 자료로 평가하였다. 요인 교차와 맞춤 대조군 실험(E14-E16)에서는 6,156회 갱신과 513회 간격의 검증을 공통 적용하였다. 각 실험에서 검증 점수가 가장 높은 모델을 선택하였다.

학습 난수 초기값은 {7, 42, 123, 2026, 3407}이다. 반복마다 합성 표본 선택, 모델 초기화와 학습 순서를 바꾸며, RF에서는 행 순서와 트리 구성의 무작위성도 포함한다. 다섯 반복의 차이는 이러한 학습 과정의 변동을 나타낸다.

4.3 공격 변형과 외부 데이터 평가

L1은 학습 생성기와 공격 유형·주요 필드를 공유하는 고정 변형이다. L2는 연속 주입 길이, 주입 간격, 값의 진폭과 Gear/RPM 바이트 위치를 함께 바꾼다. L3는 공격 대상 CAN ID를 학습용 정상 자료에 존재하는 다른 ID로 옮긴다. L4는 주입 범위·간격, 페이로드 위치, 파형과 시간 변동을 함께 바꾸어 학습 생성 규칙을 벗어나는 복합 변형을 구성한다.

외부 평가는 학습 도메인의 판정 기준을 고정한 채 정상 오탐률과 공격 탐지율을 계산한다. AU-ROC와 AP로 점수의 구분 능력을 분석하고, 오탐률 0.1%와 1% 이내에서 실제로 달성 가능한 탐지율 (TPR)을 구한다. 같은 점수를 가진 표본은 동일하게 판정한다. 외부 성능 개선은 오탐률 감소와 탐지율 증가를 함께 평가한다.

4.4 지표의 계산과 비교 원칙

공격 윈도를 공격으로 판정하면 TP, 공격을 정상으로 판정하면 FN, 정상을 공격으로 판정하면 FP, 정상을 정상으로 판정하면 TN으로 집계한다. 주요 운영 지표는 다음과 같다.

$$R_{\text{binary}} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}. \quad (4.1)$$

전체 유형 재현율(pooled exact recall)은 모든 공격 윈도 중 공격 유형까지 맞힌 비율이다. Gear/RPM 평균 유형 재현율(exact-macro)은 두 공격 유형의 재현율을 같은 가중치로 평균한다. L4는 전체 공격 표본, E16과 관계 확장 검증은 Gear/RPM 유형별 평균을 기준으로 평가한다.

평균과 표준편차는 각 실험에 명시한 시드 또는 생성 반복 단위에서 계산한다. 두 모델의 개선 폭은 동일 시드에서의 차이를 먼저 구한 뒤 평균한다. 재현율이 0.50에서 0.70으로 변하면 절대 차이는 0.20, 백분율점 차이는 20%p다. 동등성 검정은 “차이가 유의하지 않다”는 결과와 구분하며, 90% 구간이 사전 고정한 실질적 차이 범위 안에 포함되는지로 판정한다.

4.5 요인 교차와 생성 반복 설계

L3와 L4에 포함된 변화를 분리하기 위해 평가 전용 $2 \times 2 \times 2$ 요인 교차 실험을 구성하였다. P 는 Gear/RPM 값의 바이트 위치를 학습 조건에서 L4 조건으로 옮긴다. S 는 같은 시작 위치 범위에서 32개 메시지의 주입 마스크 간격을 2에서 3으로 바꾸고, D 는 페이로드 값의 변화 규칙을 학습 조건에서 L4 조건으로 바꾼다. 000은 길이와 공격 수를 맞추고 세 요인을 모두 학습 조건에 둔 기준 조합이며, 111은 세 요인을 모두 L4 조건으로 바꾼 조합이다.

E14는 한 생성 반복과 다섯 학습 반복에서 요인 효과를 추정한다. E15는 같은 생성 규칙으로 만든 네 개의 새 합성 묶음에 각각 다섯 학습 반복을 적용한다. 생성 반복마다 다섯 학습 결과와 세 원시 메시지 비중첩 평가 블록을 먼저 평균하고, 네 생성 평균을 추론 단위($n = 4$, $df = 3$)로 사용한다. 유형 재현율과 이진 탐지율의 일곱 요인 효과에는 각각 Holm 보정을 적용한다. 이전 생성 반복은 참고값으로 제시한다.

4.6 분포를 맞춘 대조군의 반응 분해

요인 교차에서 관찰한 페이로드 위치 반응을 생성 관계와 연결하기 위해, E16에서는 20개 Rule 생성 반복마다 대응하는 placebo를 만들었다. 두 자료는 정상 배경, 공격 레이블, 주입 위치·개수,

CAN ID, DLC, 시간 간격과 비대상 바이트를 공유한다. 대상 바이트의 값 개수와 행 순서·클래스별 표본 수도 보존한다. 값의 배치를 제약된 순열로 변경하여 Gear 역관계와 등록된 RPM 결합 조건을 교란한다. DoS와 Fuzzy 원도는 두 학습군에서 동일하다.

사전에 정한 주평가량은 기준 CAN ID에서 Gear/RPM 유형별 재현율을 동일 가중치로 평균한 exact-macro 재현율의 페이로드 위치 대비 C_P 이다. C_P 는 위치 이동 조건($P = 1$)과 학습 위치 조건($P = 0$)의 차이를 나머지 요인에 대해 평균한 값이다. 각 생성 반복에서 다음과 같이 분해한다.

$$C_P(\text{Rule} - \text{Real}) = C_P(\text{Placebo} - \text{Real}) + C_P(\text{Rule} - \text{Placebo}). \quad (4.2)$$

왼쪽은 실제 데이터 학습에 대한 전체 증강 반응, 오른쪽 첫 항은 placebo에서 재현된 성분, 마지막 항 θ 는 두 증강군 사이의 위치 이동 반응 차이이다. 20개 생성 반복의 θ_g 를 추론 단위($n = 20, df = 19$)로 사용한다. 초기 등록에서는 이전 전체 위치 반응의 15%인 $\delta = 0.133855625$ 를 동등성 한계로 정하고 TOST를 적용하였다[9]. 최종 해석에서는 절대 재현율과 95% 신뢰구간을 함께 제시하여 효과의 크기를 평가한다. 학습 위치에서의 효용과 관계 활용도는 제6장의 별도 평가량으로 측정한다.

4.7 실험 환경과 재현성

재현성은 실험 계획, 입력 데이터 식별값, 학습 이력, 선택 모델, 반복별 결과와 집계표를 연결하여 확보하였다. E16에서는 주분석의 200회 학습과 선행 결과의 연결 확인을 위한 20회 학습을 수행하였다. 동일 학습량 비교는 세 학습군과 다섯 시드의 15회 학습으로 구성하였다. 실험 환경은 Linux, NVIDIA GB10, Python 3.12.3, PyTorch 2.12.0/CUDA 13.0, scikit-learn 1.9.0, NumPy 2.4.6이다.

제5장 실험 결과

본 장은 동일 학습량의 탐지 효용, 비중첩 평가, 공격 변형별 반응과 외부 운영점을 순서대로 제시한다. WISA의 7,992회 갱신 비교와 후속 관계 분석의 학습 조건은 표 5.1에 정리하였다. 각 결과는 해당 실험 안에서 대응하는 학습군의 차이로 계산한다.

표 5.1: 주요 실험의 목적과 반복 단위

실험	비교 목적	반복 · 학습 조건
동일 학습량 대조	고정 · 결합 변형에서 합성 내용의 효용 확인	3개 학습군, 5개 학습 반복, 각 7,992회 갱신
비중첩 평가	입력 구간 중첩이 결과에 미치는 영향	같은 모델로 비중첩 부분집합 평가
L1-L4 기본 실험	생성 조건 변화에 따른 탐지 · 유형 식별 성능	기본 Rule 실험의 5개 학습 반복
외부 점수 순위	판정 기준과 점수 순위의 외부 성능	3개 데이터셋, 3개 학습 반복
E14 요인 교차	한 생성 반복에서 요인 효과의 방향 확인	1개 생성 반복; 내부 5개 학습 반복; 6,156회 갱신
E15 요인 교차	값의 위치 · 배치 · 동역학의 반응 분리	새로운 4개 생성 반복; 내부 5개 학습 반복 평균
E16 placebo	구현 관계의 위치 반응 비교	20개 생성 반복, 내부 5개 학습 반복; 6,156회 갱신
합성 양성 대조	알려진 관계 효용의 회복 확인	20개 생성 반복, 2개 모델 계열; 400회 학습
국소 관계 재현	학습 위치의 효용과 활용도 추정	100개 새 생성 반복; 1,000회 CNN 학습

5.1 학습 도메인 내 합성 증강의 탐지 효용

그림 5.1은 같은 학습량에서 확인한 합성 증강의 탐지 효과를 보여준다. 학습 도메인의 기본 성능이 높은 상태에서도 고정 공격 변형에서는 학습 자료의 구성에 따른 차이가 뚜렷하게 나타났다. 실제 자료, 실제 공격 복제와 합성 증강의 세 학습군을 같은 구조와 모델 선택 기준으로 비교하였다.

세 학습군에 7,992회의 공통 갱신 횟수를 적용한 결과, 표 5.2의 학습 도메인 이진 macro-F1은 모두 0.999 이상이였다. 고정 변형의 Rule-기준군 차이는 $+0.502481 \pm 0.015693$, 결합 변형은 $+0.169033 \pm 0.040607$ 였다. 실제 공격 복제 대비 차이도 각각 $+0.512525 \pm 0.016551$ 와 $+0.191856 \pm 0.026665$ 였다. 네 비교 모두 다섯 학습 반복에서 양수로 나타났다.

같은 표본 수의 공격 복제와 같은 갱신 횟수의 대조에서 모두 이득이 나타나, 합성 표본의 내용이 고정 · 결합 변형의 탐지에 기여함을 확인하였다. 유형별 분석에서는 차이가 있었다. 결합 변형의 Gear




그림 5.1: 동일 7,992회 갱신 조건의 CNN 공격 탐지율. 실제 데이터만 학습한 모델, 실제 공격 복제 및 Rule 증강을 같은 학습·선택 기준으로 비교하였다. 막대 높이는 다섯 학습 시드의 평균, 오차 막대는 표본표준편차다. 각 그래프의 세로축 범위는 동일하다.

표 5.2: 동일 7,992회 갱신 조건의 CNN 결과(다섯 학습 반복, 평균±표본표준편차)

학습군	내부 이진 macro-F1	고정 변형 탐지율	결합 변형 탐지율
Real-only	0.999172 ± 0.000207	0.497450 ± 0.015704	0.551000 ± 0.031373
Rule +30%	0.999449 ± 0.000071	0.999931 ± 0.000064	0.720033 ± 0.013211
실제 공격 복제 +30%	0.999414 ± 0.000040	0.487406 ± 0.016524	0.528178 ± 0.033527

유형 재현율은 Rule 0.534622 ± 0.155984 , 실제 자료 기준군 0.557111 ± 0.161456 이었다. Gear의 유형 식별에서는 전체 공격 탐지율과 같은 개선이 나타나지 않았다.

5.2 원시 메시지 비중첩 평가

길이 128, 이동 간격 32의 입력 구간은 인접 표본 사이에 원시 메시지를 공유한다. 중첩의 영향을 확인하기 위해 시작 인덱스가 128의 배수인 구간만 남겨 같은 모델을 평가하였다. 고정 변형은 64,000개 중 15,976개, 결합 변형은 30,000개 중 7,465개를 사용했으며, 각 평가 부분집합에서 원시 메시지의 중복은 없었다.

표 5.3: 원시 메시지 비중첩 평가의 공격 탐지율 대응 차이(다섯 학습 반복)

평가 조건	Rule-real-only	Rule-실제 공격 복제
고정 변형	+0.5002 ± 0.0165	+0.5115 ± 0.0169
결합 변형	+0.1715 ± 0.0399	+0.1951 ± 0.0257

네 비교의 차이는 다섯 학습 반복에서 모두 양수였고, 전체 평가와의 차이는 최대 0.0033이었다. 원시 메시지를 공유하지 않는 부분집합에서도 고정·결합 변형의 탐지 이득이 유지되어, 원도 구성 방식에 대한 결과의 안정성을 확인하였다.

5.3 공격 강도와 유형 및 생성 규칙 변화에 따른 결과

L2의 결합 변형에서 Rule 증가는 평균 공격 탐지율을 높였지만, 낮은 강도의 RPM 탐지와 일부 공격의 유형 식별은 어려웠다. +100%의 합성 자료를 새로 구성한 실험에서는 Rule과 실제 자료 기준군의 평가 블록별 평균 탐지율 차이가 +0.2117이었고, 95% 신뢰구간은 [0.1640, 0.2594]였다. 이 결과는 주입 길이·간격, 값의 진폭과 페이로드 위치를 함께 바꾼 평가에서 얻었다.

L4에서는 공격 탐지와 유형 식별의 차이가 더욱 뚜렷했다. Rule +30% CNN은 공격 탐지율 0.998을 유지했지만 전체 공격 표본의 유형 재현율은 0.0893 ± 0.1125 로 하락하였다. RF도 공격 탐지율 0.536과 유형 재현율 0.145로 같은 차이를 보였다. 생성 규칙을 벗어난 표본을 공격으로 탐지하더라도 해당 공격 유형을 정확하게 식별하지는 못한 것이다.

기본 Rule +30% 실험의 다섯 학습 반복에서 $G_r = R_{\text{binary},r} - R_{\text{exact},r}$ 로 계산한 L4-L1 격차 증가는 평균 0.9088이고 대응 95% 신뢰구간은 [0.7705, 1.0472]였다¹. 다섯 학습 반복에서 모두 양수로 나타나, L4에서 탐지와 유형 식별의 격차가 커질 것이라는 H3을 지지하였다.

대상 CAN ID를 이동한 평가에서는 Gear와 RPM의 유형 재현율 변화가 Rule +30% 기준 각각 +0.0032와 -0.0001이었다. 시험한 식별자 변형에서 유형 인식이 유지되는 반응을 보였으며, 이어지는 요인 분석에서는 페이로드의 위치·배치·값 변화로 분석 범위를 확장하였다.

5.4 요인별 효과와 생성 반복 검증

E14에서 Rule과 실제 자료 기준군의 페이로드 위치 효과 차이 P 는 -0.87996, 95% 신뢰구간은 [-1.11717, -0.64274]였다. 다섯 학습 반복에서 모두 음수였으며, Holm 보정 후 $p = 0.003509$ 로 위치 변화에 따른 큰 성능 차이가 나타났다.

E15에서는 네 개의 새 생성 반복으로 같은 요인 교차 실험을 수행하였다. 그림 5.2와 표 5.4의 일곱 유형 재현율 효과는 각 생성 반복에서 평균과 같은 방향이었고, Holm 보정 후 $p \leq 0.0391$ 이었다. 위치 효과 $P = -0.8924$ 가 가장 컸으며, 배치(S), 값 변화(D)와 네 상호작용도 관찰되었다. S 와 PS 의 크기는 Gear와 RPM에서 달랐고, SD 의 방향은 이진 탐지율과 유형 재현율에서 반대였다. 위치가 가장 큰 영향을 미치면서 다른 요인과의 결합한 결과다.

표 5.4: E15 기준 CAN ID의 Gear/RPM 평균 유형 재현율에 대한 요인 효과(Rule-실제 자료 기준군, $n = 4$)

효과	평균	해석
P	-0.8924	가장 큰 페이로드 위치 반응; 95% 구간 [-0.9432, -0.8415]
S	+0.0479	주입 배치의 효과; 공격 유형별 차이
D	-0.0596	페이로드 값 변화 규칙의 효과
PS	+0.0938	위치와 배치의 상호작용; 공격 유형별 차이
PD	-0.1182	위치와 값 변화의 상호작용
SD	-0.0261	유형 재현율과 이진 탐지율에서 방향이 달라짐
PSD	-0.0544	세 요인의 상호작용

¹유형 재현율은 이진 탐지율 이하이므로 G_r 는 0과 1 사이이고, L4-L1 격차 증가는 [-1, 1] 범위에 있다. 대응 t -구간은 이 범위로 절단하지 않아 상한이 1을 넘을 수 있다.




그림 5.2: 네 개의 새로운 생성 반복에서 반복한 요인 효과. (a)는 유형 재현율·이진 탐지율 효과의 생성 반복 평균과 보정 전 신뢰구간이며, 흰 마름모는 연속성 확인용 이전 생성 반복으로 추정에서 제외하였다. (b)는 Gear/RPM별 보조 요약이다. (c)는 각 효과의 격자 내 분산을 생성 반복(construction), 학습 반복(pipeline), 상호작용으로 나눈 실험 내 변동 비중이다. 학습 반복과 평가 블록은 각 생성 반복 내부에서 먼저 평균하였다.

5.5 외부 데이터의 운영점과 점수 순위

그림 5.3에서 대부분의 CNN 외부 운영점은 FPR 0.965–1.0 부근에 위치한다. 공격 탐지율은 높지만 정상 입력도 거의 모두 공격으로 분류한 결과다. RF의 OTIDS 결과도 실제 자료 기준군의 오탐률/탐지율 0.1216/0.5943에서 Rule +100%의 0.4268/0.7150으로 이동하였다. 탐지율은 증가했지만 FPR 차이 +0.3052의 95% 구간은 [0.2290, 0.3814]로, 오탐률도 뚜렷하게 증가하였다.

높은 오탐률이 임계값 선택에서 비롯되었는지 확인하기 위해 세 학습 반복의 외부 점수 순위를 분석하였다. 표 5.5에서 Rule +30%의 AUROC는 세 데이터셋 모두 약 0.5였고, 실제 자료 기준군 대비 AUROC와 AP 차이도 모두 음수였다. 데이터셋·설정·학습 반복을 조합한 54개 조건에서 FPR 0.1%와 1% 이내에 달성 가능한 TPR은 0이었다. 공격 점수 1.0을 받은 정상 표본 수가 허용 오탐수보다 많아, 이 점수를 공격으로 판정하면 오탐률 한계를 넘었기 때문이다.

표 5.5: Rule +30% 외부 점수 순위 분석(세 학습 반복, 평균±표본표준편차; Δ는 실제 자료 기준군 대비 차이)

데이터	FPR	탐지율	AUROC	AP	ΔAUROC	ΔAP
OTIDS	0.999973	0.999933	0.501117 ± 0.003514	0.486965 ± 0.001786	-0.048365	-0.045772
ROAD	1.000000	1.000000	0.500000 ± 0.000000	0.055744 ± 0.000000	-0.016688	-0.001935
can-train-and-test	0.999997	0.999850	0.499863 ± 0.000350	0.069898 ± 0.000046	-0.000155	-0.000020




그림 5.3: 외부 데이터의 FPR-공격 탐지율 운영점. 좌상단에 가까울수록 유용하며, 우상단은 정상·공격 입력에 모두 경보를 내는 상태다. 오차 막대는 각 학습군의 반복 간 변동을 나타낸다.

5.5.1 L6 진단: 입력 특성 제거와 보정

L6에서는 CAN ID 구성의 차이가 외부 오탐에 미치는 영향을 분석하였다. 표 5.6는 ID 입력을 가리거나, ID 없이 또는 ID만으로 다시 학습한 CNN의 결과다. 학습용 정상 자료에 존재하는 ID만 허용하는 규칙은 Car-Hacking 시험 자료에서 오탐이 없었지만 세 외부 데이터의 FPR은 1.0이었다. ID 불일치만으로도 높은 외부 오탐이 나타난 것이다. ID 없이 재학습한 모델의 FPR도 can-train-and-test에서 0.9989, OTIDS에서 0.9074로 높아, 다른 입력 특성의 분포 차이가 함께 남아 있었다. ID만 사용한 모델은 오탐률이 낮아졌으나 반복 간 표준편차가 0.24-0.44로 컸다.

표 5.6: L6 진단: 입력 특성 제거에 따른 CNN의 외부 FPR / 공격 탐지율

진단	데이터	실제 자료 기준군	Rule +30%	반복 수
전체 입력(기준)	can-train-and-test	0.99995 / 1.00000	1.00000 / 0.99985	3
입력에서 ID 채널 마스킹	can-train-and-test	0.99972 / 0.99887	0.99986 / 0.99996	3
ID 채널 없이 재학습	can-train-and-test	0.99885 / 0.99840	0.99999 / 1.00000	5
	OTIDS	0.90744 / 0.87279	0.99989 / 0.99998	5
	Car-Hacking 시험	0.00023 / 0.99759	0.00024 / 0.99832	5
ID 채널만으로 재학습	can-train-and-test	0.27672 / 0.54921	0.46509 / 0.71480	5
	OTIDS	0.44627 / 0.60835	0.67382 / 0.82797	5

보정 진단에서는 can-train-and-test의 정상 윈도 10만 개를 추가해 학습했을 때 FPR이 0.00034로 낮아졌으나 공격 탐지율은 0.090이었다. 외부 정상 자료를 배경으로 만든 합성 공격을 추가한 경우에도 탐지율 0.173, FPR 0.0012에 머물렀다. ROAD에서는 정상 주행 자료로 임계값을 보정한 뒤에도 FPR이 실제 자료 기준군 0.939 ± 0.103 , Rule 1.0이었다. 보정 효과는 데이터셋에 따라 달랐으며, 오탐률을 낮춘 조건에서도 공격 탐지율은 낮았다.

5.6 맞춤 대조군을 통한 관계 효과 분석

E16은 20개 생성 반복에서 Rule과 실제 자료 기준군의 위치 이동 반응 차이를 맞춤 대조군 성분과 Rule-placebo 차이로 분해하였다(그림 5.4). 생성 반복 평균은 다음과 같다.

$$-0.8811 = -0.8752 + (-0.0059) \quad (5.1)$$

위치 이동에 따른 증강 효과 변화(C_P)의 99.3%가 주입 조건과 값 분포를 맞추고 관계를 교란한 대조군에서도 재현되었다.

평균 위치 이동 반응 차이는 -0.005915 이며 95% 신뢰구간은 $[-0.024628, +0.012798]$ 이었다. 학습 반복을 하나씩 제외하는 jackknife로 학습 반복 단위($n = 5$)에서 다시 계산한 사후 민감도 분석의 90% 구간도 $[-0.026430, +0.014600]$ 으로 0을 포함하였다. L1에서도 placebo와 Rule의 이진 탐지율은 각각 0.99998과 1.00000으로 거의 같았고, $P = 1$ 의 위치 이동 조건에서 평균 유형 재현율은 Rule 0.1352, placebo 0.1411, 실제 자료 기준군 0.0184로, 두 증강군에서 비슷한 하락이 나타났다.

표 5.7: E16 위치 이동 반응 분석($n = 20$ 생성 반복, 반복마다 다섯 학습 결과 평균)

평가량/판정량	값	의미
전체 $C_P(\text{Rule} - \text{Real})$	-0.8811	증강 구성과 학습 변화가 결합된 전체 반응
Placebo $C_P(\text{Placebo} - \text{Real})$	-0.8752	주변 조건을 맞춘 대조군에서 재현된 성분
$\theta = C_P(\text{Rule} - \text{Placebo})$	-0.005915	두 증강군의 위치 반응 차이; 표준편차 0.039983
90% TOST 구간	$[-0.021375, +0.009544]$	사전 동등성 한계 ± 0.133856 안에 존재
95% 구간	$[-0.024628, +0.012798]$	평균 위치 반응 차이의 추정 불확실성
이질성 검사	한계 밖 0/20	양수 10개, 음수 10개; 부호 검정 $p = 1$

학습 위치에서 두 증강군의 평균 유형 재현율은 모두 약 0.9997로 포화되어, θ 에는 주로 이동 위치의 차이가 반영된다. TOST는 사전 한계 안에 들었지만, 이 한계는 이동 위치의 placebo 이득 0.1227보다 넓다. 따라서 효과의 크기는 평균 차이와 95% 신뢰구간으로 해석하고, 학습 위치의 관계 활용도와 효용은 다음 장에서 별도로 측정한다.




그림 5.4: 20개 생성 반복의 페이로드 위치 반응 분해. (a) 전체 반응, placebo 성분과 두 증강군 차이. (b) 반복별 두 증강군 차이와 평균의 95% 신뢰구간. (c) 이동 위치의 평균 유형 재현율. 각 생성 반복에서 다섯 학습 반복을 먼저 평균하였다.

제6장 관계 활용과 탐지 효용의 확장 검증

앞 장의 단계적 평가와 요인 교차 실험에서는 증강 효과가 나타나는 조건과 모델의 반응에 영향을 주는 입력 요소를 분석하였다. 본 장에서는 모델이 생성 관계를 활용하는지, 그 활용이 탐지 성능 향상으로 이어지는지 살펴본다. 이를 위해 입력 표현을 비교하고, 관계 정보가 분류에 유용하도록 설계한 양성 대조 실험과 새로 생성한 자료를 이용한 100회 재현 실험을 수행하였다.

6.1 관계 활용도, 탐지 효용과 위치 이동 효과

6.1.1 평가량의 정의

학습한 관계는 모델의 판단에 영향을 주더라도 재현율을 높이지 못할 수 있다. 관계의 활용과 성능 기여를 각각 측정하기 위해 학습 때 사용한 바이트 위치를 유지하면서 공격 주입 개수와 관계 상태를 조절하였다. 주입 개수를 k , 관계 상태 r 을 유지(intact)와 변경(broken)으로 나타내고, 학습군 a 의 공격 유형별 재현율 평균을 $R_a(k, r)$ 로 정의한다.

국소 탐지 효용 $U(k)$ 는 관계를 유지한 평가에서 Rule 학습군과 placebo 학습군의 재현율 차이이다.

$$U(k) = R_{\text{Rule}}(k, \text{intact}) - R_{\text{Placebo}}(k, \text{intact}). \quad (6.1)$$

관계 활용도 $L(k)$ 는 관계를 변경했을 때 나타나는 재현율 변화의 학습군 간 차이이다.

$$L(k) = [R_{\text{Rule}}(k, \text{intact}) - R_{\text{Rule}}(k, \text{broken})] - [R_{\text{Placebo}}(k, \text{intact}) - R_{\text{Placebo}}(k, \text{broken})]. \quad (6.2)$$

$U(k) > 0$ 이면 관계를 유지한 조건에서 Rule 학습군의 재현율이 더 높다. $L(k) > 0$ 이면 관계 유지·변경 조건 사이의 재현율 차이가 Rule 학습군에서 더 크다. 두 평가량은 각각 관계를 보존한 증강 학습의 성능 이점과 관계 변화에 대한 모델의 민감도를 나타낸다.

위치 이동 효과 θ 는 제5장의 C_P 대비로 계산하며, 바이트 값을 학습 때와 다른 위치로 옮겼을 때 나타나는 두 증강군의 반응 차이를 나타낸다. 세 평가량의 조건과 의미는 표 6.1와 같다.

표 6.1: 관계 효과를 분석하는 세 평가량

평가량	평가 조건	측정 내용
효용 $U(k)$	학습 위치, 관계 유지, 같은 주입 개수	관계 유지 조건에서 두 학습군의 재현율 차이
활용도 $L(k)$	학습 위치, 관계 유지·변경의 대응 비교	관계 변경에 따른 재현율 변화의 학습군 간 차이
위치 효과 θ	학습 위치와 이동 위치의 요인 대비	위치 이동에 따른 반응의 학습군 간 차이

6.1.2 주입 개수에 따른 평가 설계

공격 메시지가 많으면 두 증강군의 재현율이 모두 높아지고, 지나치게 적으면 탐지에 필요한 정보가 부족해 재현율이 함께 낮아진다. 이처럼 주입 개수에 따라 관계 효과가 달라질 수 있으므로, 학습 때의 바이트 위치에서 $k \in \{2, 4, 8, 16, 32\}$ 를 관계 유지·변경 조건에 각각 적용하여 재현율 곡선을 측정하였다.

앞선 탐색에서 $k = 8$ 의 관계 활용도가 뚜렷하게 나타나, 후속 실험에서는 $U(8)$ 와 $L(8)$ 를 공동 주평가량으로 정하였다. 실험 계획은 새로운 합성 자료를 생성하고 모델을 학습하기 전에 고정했으며, 전체 주입 개수의 결과도 함께 분석하였다.

6.2 입력 표현에 따른 관계 정보의 반영

6.2.1 집계 특징과 관계 특징의 비교

관계 조작이 모델 입력에 반영되는 정도는 특징 표현에 따라 달라진다. 기본 RF는 각 채널의 평균, 표준편차, 최솟값, 최댓값과 처음·마지막 값의 차이를 사용한다. 윈도 안에서 각 값의 개수를 유지한 채 순서를 바꾸면 평균과 표준편차 등의 집계량이 보존되므로, 수학적으로 총 55개 특징 중 54개는 변하지 않는다. 실제로 관계를 바꾼 윈도의 약 2.53%에서만 실질적인 특징 변화가 나타났다.

관계 특징을 추가한 RF는 페이로드의 여덟 바이트 사이에서 모든 쌍별 피어슨 상관계수를 계산한다. 바이트 쌍은 $\binom{8}{2} = 28$ 개이며, 기존 55개 특징에 추가하면 입력은 83차원이 된다. 이 표현에서는 20개 대조군 쌍에서 관계를 변경한 260만 윈도 모두에 특징 변화가 나타났다. 따라서 RF55와 RF83을 비교하면 관계 정보를 입력에 명시적으로 포함했을 때의 효과를 살펴볼 수 있다.

표 6.2: 입력 표현과 위치 이동 반응의 비교(같은 20개 생성 반복과 학습량)

모델	입력 표현의 특징	평균 θ	95% 신뢰구간
CNN	11개 채널의 시간 배열	-0.0059	[-0.0246, +0.0128]
RF55	채널별 집계 특징 55개	+0.0045	[-0.0078, +0.0168]
RF83	집계 특징과 바이트 간 상관 28개	-0.0043	[-0.0166, +0.0079]
BiLSTM	양방향 시간 순서 표현	-0.0055	[-0.0487, +0.0377]

표 6.2에서 네 모델의 평균 위치 이동 효과는 모두 0에 가까웠고, 95% 신뢰구간도 0을 포함하였다. 관계 특징을 추가한 RF83에서도 뚜렷한 위치 이동 효과는 나타나지 않았다. BiLSTM은 E16과 동일한 20개 생성 반복, 다섯 학습 반복과 학습량을 유지하면서 모델 구조만 바꾼 별도 등록 실험이며, 네 모델 중 추정 구간이 가장 넓었다.

6.2.2 시간축 패턴과 바이트 위치의 역할

CNN의 합성곱은 시간축에서 가중치를 공유하며 연속된 메시지의 패턴을 추출한다. 각 입력 채널은 CAN ID, DLC와 특정 페이로드 바이트에 대응하므로, 시간상 반복되는 패턴을 학습하는 능력과 바이트 위치가 바뀐 관계를 인식하는 능력은 다르다. RF의 상관 특징도 특정 바이트 쌍에 대응하며, BiLSTM 역시 각 시점의 채널 배열을 입력으로 받는다. 따라서 학습한 위치에서 관계를 활용하는지 확인한 뒤, 위치를 옮겨도 활용할 수 있는지를 별도로 평가하였다.

6.3 관계 학습을 확인하는 양성 대조 실험

6.3.1 관계에 의해 구분되는 합성 분류 문제

모델과 평가 절차가 유용한 관계를 포착하는지 확인하기 위해, 바이트 사이의 관계로 두 클래스를 구분하는 합성 분류 문제를 설계하였다. 같은 배경에서 서로 다른 정답 레이블을 갖는 원도 쌍을 만들되, 바이트별 값의 개수와 나머지 필드는 동일하게 유지하였다. 두 클래스의 차이는 바이트 0과 바이트 1이 같은 값을 갖는지, 또는 합이 255가 되는 상보 관계를 갖는지에 있다.

바이트 0은 {31, 95, 160, 224}의 각 값을 32개씩 포함한다. 이 값 집합은 $255 - b$ 변환에 대해 대칭이므로 관계를 바꾸어도 개별 바이트의 값 분포가 유지된다. 배경 단위로 15%의 레이블을 반전하여, 관계를 완전히 학습한 이상적인 분류기의 모집단 정확도가 0.85가 되도록 하였다. 이를 통해 관계 정보의 효용을 유지하면서 정확도가 1에 도달하는 포화를 피하였다.

Placebo에서는 바이트 1의 값 순서를 섞고, 그 배열을 서로 다른 레이블의 두 원도에 동일하게 적용하였다. 관계를 변경한 평가 쌍은 입력이 같고 정답이 반대이므로, 결정론적 분류기의 균형 재현율은 정확히 0.5가 된다.

6.3.2 CNN과 RF83의 관계 학습 결과

학습·검증·시험 자료의 난수 계열을 분리하고, 새로 생성한 자료 20세트에 다섯 학습 반복, 두 학습군과 두 모델을 조합하여 총 400회 학습하였다. CNN은 기존 특징 추출 구조에 두 클래스 출력층을 적용했고, RF83은 관계 특징을 포함한 83차원 입력을 사용하였다. 결과는 예비실험을 제외한 본 실험에서 집계하였다.

표 6.3: 유용한 관계의 합성 양성 대조 결과($n = 20$ 생성 반복)

모델	Rule 재현율	Placebo 재현율	효용 U	U 의 95% 구간
CNN	0.849932	0.490938	+0.358994	[+0.350702, +0.367286]
RF83	0.850098	0.493135	+0.356963	[+0.350104, +0.363822]

두 모델 모두 20개 생성 반복에서 효용이 양수였으며, 평균 효용은 CNN에서 35.90%p, RF83에서 35.70%p였다. 두 모델은 사전에 정한 관계 학습의 확인 기준인 평균 $U \geq 0.175$ 와 95% 신뢰구간 하한 > 0 을 모두 충족하였다. 이 결과는 합성한 두 클래스의 구분에 유용한 관계를 두 모델이 학습했으며, 평가 절차가 그 효과를 측정할 수 있음을 보여준다. 관계 변경 조건에서는 두 학습군의 재현율이 모두 0.5이므로 $L = U$ 가 성립한다.

6.4 새로 생성한 자료를 이용한 100회 재현 실험

6.4.1 설계와 추론 단위

후속 재현 실험에서는 기존 Car-Hacking 학습·검증 자료와 다섯 클래스 CNN을 유지하고, 100개의 새로운 Rule/placebo 생성 쌍을 구성하였다. 각 생성 반복에 고정된 다섯 학습 시도와 두 학습군을 적용하여 총 1,000회 학습하였다. 실제 학습 원도 262,149개에 합성 원도 78,645개를 추가했으며, 모든 학습에서 가중치를 6,156회 갱신하고 513회마다 검증하여 학습량과 모델 선택 기회를 맞췄다.

평가에는 앞선 실험의 정상 배경 6,000개와 세 평가 블록을 사용하였다. 각 블록에서 Gear와 RPM에 같은 가중치를 부여하고, 동일한 생성 자료로 학습한 다섯 결과를 먼저 평균하였다. 이로부터 얻은 100개 생성 반복의 평균값을 추론 단위로 삼아 표준편차와 신뢰구간을 계산하였다. 두 주평가량을 함께 고려하기 위해 $U(8)$ 와 $L(8)$ 에 각각 97.5% Student- t 신뢰구간을 적용하였다. 이 설계는 기존 학습·평가 자료를 고정한 상태에서 합성 자료를 새로 생성할 때의 변동을 측정한다.

6.4.2 관계 활용도와 탐지 효용의 결과

표 6.4: 새 생성 반복의 공동 주평가량($k = 8, n = 100$)

평가량	평균	표준편차	97.5% 신뢰구간	양의 반복
탐지 효용 $U(8)$	+0.001078	0.046539	$[-0.009514, +0.011670]$	53/100
관계 활용도 $L(8)$	+0.026400	0.005549	$[+0.025137, +0.027662]$	100/100

관계 활용도 $L(8)$ 는 100개 생성 반복에서 모두 양수였고, 평균은 2.64%p였다. 관계를 유지한 조건에서 Rule과 placebo의 재현율은 각각 0.823074와 0.821996, 관계를 변경한 조건에서는 0.790030과 0.815351이었다. 관계 변경에 따른 재현율 감소는 Rule에서 약 3.30%p, placebo에서 약 0.66%p로 나타났다.

탐지 효용 $U(8)$ 의 평균은 0.11%p였으며, 97.5% 신뢰구간은 $[-0.95, +1.17]$ p로 0을 포함하였다. Rule 학습군은 관계 변경에 더 민감하게 반응했지만, 관계 유지 조건에서의 재현율 향상은 통계적으로 뚜렷하지 않았다.




그림 6.1: 새로 생성한 자료를 이용한 100회 재현 실험 결과. 왼쪽은 주입 개수에 따른 Gear/RPM 유형별 재현율 평균 (exact-macro)이며, 오른쪽은 $k = 8$ 에서의 효용과 활용도 및 각각의 97.5% 신뢰구간이다. 각 생성 반복에서 다섯 학습 결과를 먼저 평균하였다.

6.4.3 주입 개수에 따른 변화와 재현 결과

그림 6.1에서 $k \geq 16$ 이면 유형별 재현율 평균이 다시 높아진다. 공격 메시지가 충분해지면 두 학습군 모두 높은 재현율에 도달하므로, 관계 활용도를 측정할 때에는 주입 개수도 함께 조절해야 한다. 같은 $k = 8$ 에서도 Gear와 RPM의 반응 크기는 달랐다.

6.5 확장 검증의 시사점

확장 검증의 결과는 생성 관계의 효과를 평가할 때 입력 표현, 관계의 분류 정보, 실제 탐지 성능을 차례로 살펴봐야 함을 보여준다. RF55와 RF83의 비교에서는 특징 표현에 따라 관계 변화의 반영 정도가 크게 달랐고, 양성 대조에서는 두 모델 모두 분류에 유용한 관계를 학습하였다. 기존 다섯 클래스 조건의 100회 재현 실험에서는 관계 활용이 일관되게 나타났으나 탐지 효용의 평균은 작았다. 이 결과를 종합하면, 합성 데이터의 가치는 생성한 관계의 존재뿐 아니라 그 관계가 모델 입력에 반영되고 재현을 향상으로 이어지는 과정까지 평가해야 파악할 수 있다.

6.6 연구질문과 착수 가설의 종합

표 6.5는 네 연구질문과 이에 대응하는 착수 가설의 결과를 정리한다. RQ2는 공격 강도에 따른 효과 변화(H2)와 탐지·유형 식별의 격차(H3)를 함께 다룬다. RQ4에서는 위치 이동 반응(H5)에 더해 학습 위치의 활용도와 효용을 확장 검증하였다.

표 6.5: 연구질문과 착수 가설별 종합 결과

항목	핵심 결과	판정
RQ1·H1	내부 성능을 유지하면서 공격 복제·동일 학습량 대조와 비중첩 평가에서도 고정·결합 변형의 탐지 이득 유지	증강 효과 확인, H1 지지
RQ2·H2	공격 강도와 유형별 차이는 있었으나 L2의 증강 효과가 일관되게 감소하지 않음	단순 감소 가설 미지지
RQ2·H3	L4-L1의 탐지·유형 식별 격차 증가 평균 0.9088, 95% 구간 [0.7705, 1.0472]; 다섯 반복 모두 양수	H3 지지
RQ3·H4	세 외부 데이터에서 정상 오탐률·공격 탐지율의 공동 개선과 점수 순위 개선이 나타나지 않음	외부 개선 가설 미지지
RQ4·H5	위치 반응 차이 -0.0059 의 구간이 사전 동등성 한계 안에 포함됨. 새 생성 반복의 관계 활용도는 $+2.64\%$ p, 효용은 $+0.11\%$ p이며 효용 구간은 0 포함	위치 대비 가설 미지지; 확장 검증에서 관계 활용 확인

제7장 연구 결과의 의미와 적용 범위

7.1 증강 효과와 관계 활용

실제 공격 복제와 동일 학습량 대조에서도 탐지율 차이가 유지되었다는 점은, 추가한 합성 표본의 내용이 고정·결합 변형의 탐지에 기여했음을 보여준다. 그러나 생성 규칙을 벗어난 조건에서는 공격 탐지와 유형 식별이 크게 달라졌다. 따라서 생성기를 평가할 때는 증강 전후의 평균 점수와 함께, 어떤 공격 조건에서 어떤 성능이 달라지는지 살펴보아야 한다.

관계 분석은 이 성능 차이를 설명하는 방법을 제시한다. 요인 교차 실험은 영향이 큰 입력 요소를 찾고, 맞춤 대조군은 그 반응을 공통 성분과 관계 조작에 따른 차이로 나눈다. 이어 관계 활용도와 탐지 효용을 각각 측정하면, 모델이 관계 정보에 반응하는 정도와 그 정보가 분류 성능에 기여하는 정도를 구분할 수 있다. 새 생성 반복에서 활용도는 일관되게 양수였지만 효용의 구간은 0을 포함한 결과가 이 구분의 필요성을 보여준다.

7.2 외부 환경에서의 적용

Rule +30% CNN은 세 외부 데이터셋에서 공격 탐지율과 정상 오탐률이 모두 높았고, 점수 순위의 개선도 나타나지 않았다. ID 채널을 제거한 뒤에도 오탐이 남아, ID 이외의 입력 특성에도 분포 차이가 있음을 확인하였다. 외부 적용을 위한 후속 설계에서는 차량별 입력 표현과 보정 방법을 함께 검토하고, 낮은 오탐률에서 확보할 수 있는 탐지율을 기준으로 비교할 필요가 있다.

7.3 적용 범위

학습 자료와 생성 규칙의 기반은 Car-Hacking이다. 학습 반복은 모델 학습 과정의 변동을, 생성 반복은 같은 규칙으로 새 합성 자료를 만들 때의 변동을 측정한다. 100개 생성 반복의 재현 실험도 같은 실제 자료와 정상 평가 배경을 공유하므로, 독립 차량과 수집 로그에서의 검증이 다음 과제다.

Gear/RPM은 본 구현의 공격 생성 유형을 뜻하며, 차량 신호 명세(DBC)로 확인한 실차 제어 의미를 나타내지는 않는다. 맞춤 대조군은 지정한 관계를 변경하면서 바이트별 값 분포를 보존하지만, RPM의 다른 결합 구조는 일부 남는다. 합성 양성 대조는 관계가 분류에 유용하도록 만든 두 클래스 문제이며, 실제 자료와 합성 자료를 함께 학습한 다섯 클래스 실험과 구분하여 해석한다.

제8장 시스템 산출물과 학술 성과

8.1 주요 산출물

데이터 처리부터 결과 집계까지 이어지는 평가 시스템을 구현하였다. 각 모듈은 공통 입력과 결과 형식을 사용하며, 저장된 설정·모델·예측 결과에서 보고서의 지표와 그림을 다시 생성할 수 있다.

표 8.1: 과제의 주요 산출물

산출물	주요 기능	결과 자료
데이터 처리 모듈	시간 구간 분할과 공통 입력 구성	원본 행 대응, 분할 검사와 표준화 통계
규칙 기반 생성기	네 공격 유형의 합성 자료와 맞춤 대조군 생성	생성 조건, 표본 수와 관계 조작 검사
탐지기 학습 모듈	CNN/RF 학습과 동일 학습량 비교	선택 모델, 학습 이력과 반복별 성능
Shift Ladder 평가기	L0-L6의 탐지·유형 식별·외부 성능 평가	단계별 결과표, 운영점과 점수 순위
요인·관계 분석기	요인 교차와 관계 활용도·효용 추정	반복별 대응 차이와 신뢰구간
확장 검증 자료	입력 표현 비교, 양성 대조와 새 생성 반복	모델별 비교와 100개 생성 반복의 재현 결과
보고서·발표 자료	연구 설계와 구현·실험 결과 정리	단계별 보고서, 최종 포스터와 발표 자료

8.2 학술 성과

Shift Ladder 평가 체계와 연구 결과를 정리한 논문 *The Shift Ladder: Locating the Gains and Failures of Rule-Based Synthetic CAN Attack Augmentation*은 WISA 2026 Paper 세션에 채택되어 Oral 세션에서 발표하였다[7]. 학술 검토 과정에서 동일 학습량 대조, 비중첩 평가와 외부 점수 순위 분석을 보강하였다.

후속 연구는 요인 교차, 맞춤 대조군과 관계 활용도·효용 분석으로 확장하였다. 확장 검증 결과는 본 보고서에 통합하였으며, Vehicular Communications 투고를 위한 원고로 정리하고 있다.

제9장 결론

본 과제는 합성 CAN 공격 데이터의 생성, 탐지기 학습, 단계적 평가와 관계 분석을 통합한 Shift Ladder 시스템을 구현하였다. 동일한 7,992회 갱신 조건에서 실제 자료 기준군과 비교한 Rule +30%의 고정 변형 탐지율은 49.75%에서 99.99%로, 결합 변형 탐지율은 55.10%에서 72.00%로 향상되었으며, 비중첩 평가에서도 이득이 유지되었다.

생성 규칙을 벗어난 복합 변형에서는 CNN의 공격 탐지율이 99.8%인 반면 유형 재현율은 8.93%로 낮아졌다. Rule +30% CNN은 세 외부 데이터에서 정상 오탐률이 거의 100%에 도달하고 점수 순위의 개선도 나타나지 않았다. 이러한 결과는 공격 탐지, 유형 식별과 외부 운영 성능을 각각 평가해야 함을 보여준다.

관계 분석에서는 페이로드 위치가 가장 큰 영향을 보였으며, 그 위치 이동 반응의 대부분이 맞춤 대조군에서도 재현되었다. 100개 새 생성 반복의 관계 활용도는 $+2.64\%_p(97.5\% \text{ 신뢰구간 } [+2.51, +2.77]\%_p)$ 였고, 유형 재현율로 측정한 탐지 효율 차이는 $+0.11\%_p([-0.95, +1.17]\%_p)$ 였다. 관계가 유용하도록 설계한 합성 양성 대조에서는 CNN과 관계 특징 RF가 각각 $35.90\%_p$ 와 $35.70\%_p$ 의 효율을 보였다.

이 평가 체계는 합성 증강의 성능 향상과 생성 요소의 기여를 함께 분석하는 기반을 제공한다. 후속 연구에서는 독립 차량 자료와 추가 생성기로 범위를 넓히고, 위치 변화에 대응하는 입력 표현과 낮은 오탐률에서의 탐지 성능을 검증할 계획이다.

참고문헌

- [1] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, and Konrad Rieck. Dos and don'ts of machine learning in computer security. In *Proceedings of the 31st USENIX Security Symposium*, pages 3971–3988, 2022.
- [2] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [3] Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2:665–673, 2020.
- [4] Hacking and Countermeasure Research Lab. CAN-intrusion dataset (OTIDS). <https://ocslab.hksecurity.net/Dataset/CAN-intrusion-dataset>, 2017. Accessed 2026-06-10.
- [5] Hacking and Countermeasure Research Lab. Car-hacking dataset. <https://ocslab.hksecurity.net/Datasets/car-hacking-dataset>, 2017. Accessed 2026-06-10.
- [6] Markus Hanselmann, Thilo Strauss, Katharina Dormann, and Holger Ulmer. CANet: An unsupervised intrusion detection system for high dimensional CAN bus data. *IEEE Access*, 8:58194–58205, 2020.
- [7] Hyunjin Jang, Dawit Shin, Upjun Ha, Thi-Thu-Huong Le, and Howon Kim. The shift ladder: Locating the gains and failures of rule-based synthetic CAN attack augmentation. In *27th World Conference on Information Security Applications (WISA 2026)*, 2026. Accepted in the Paper session and presented in the Oral session.
- [8] Karl Koscher, Alexei Czeskis, Franziska Roesner, Shwetak Patel, Tadayoshi Kohno, Stephen Checkoway, Damon McCoy, Brian Kantor, Danny Anderson, Hovav Shacham, and Stefan Savage. Experimental security analysis of a modern automobile. In *Proceedings of the 2010 IEEE Symposium on Security and Privacy*, pages 447–462, 2010.
- [9] Daniël Lakens, Anne M. Scheel, and Peder M. Isager. Equivalence testing for psychological research: A tutorial. *Advances in Methods and Practices in Psychological Science*, 1(2):259–269, 2018.
- [10] Brooke Lampe and Weizhi Meng. can-train-and-test: A curated CAN dataset for automotive intrusion detection. *Computers & Security*, 140:103777, 2024.
- [11] Sampath Rajapaksha, Harsha Kalutarage, M. Omar Al-Kadri, Andrei Petrovski, Garikayi Madzudzo, and Madeline Cheah. AI-based intrusion detection systems for in-vehicle networks: A survey. *ACM Computing Surveys*, 55(11):237:1–237:40, 2023.
- [12] Eunbi Seo, Hyun Min Song, and Huy Kang Kim. GIDS: GAN-based intrusion detection system for in-vehicle network. In *Proceedings of the 16th Annual Conference on Privacy, Security and Trust*, pages 1–6, 2018.
- [13] Hyun Min Song, Ha Rang Kim, and Huy Kang Kim. Intrusion detection system based on the analysis of time intervals of CAN messages for in-vehicle network. In *2016 International Conference on Information Networking (ICOIN)*, pages 63–68, 2016.
- [14] Miki E. Verma, Robert A. Bridges, Michael D. Iannaccone, Samuel C. Hollifield, Pablo Moriano, Steven C. Hespeler, Bill Kay, and Frank L. Combs. A comprehensive guide to CAN IDS data and introduction of the ROAD dataset. *PLOS ONE*, 19(1):e0296879, 2024.
- [15] Qingling Zhao, Mingqiang Chen, Zonghua Gu, Siyu Luan, Haibo Zeng, and Samarjit Chakraborty. CAN bus intrusion detection based on auxiliary classifier GAN and out-of-distribution detection. *ACM Transactions on Embedded Computing Systems*, 21(4):1–30, 2022.