

합성 CAN 공격 데이터 증강의 신뢰성 검증을 위한 단계적 평가 프레임워크 설계 및 구현

졸업과제 중간보고서



팀명: InfoSec

분과 D (하드웨어/보안)

정보컴퓨터공학부 인공지능전공

졸업과제번호: 46

202355655 장현진

이메일: hyunjin@islab.re.kr

지도교수: 김호원

제출일: 2026년 9월 7일

부산대학교

요약

본 연구는 규칙 기반 합성 Controller Area Network(CAN) 공격 데이터 증강의 효과를 엄밀하게 검증하기 위한 단계적 평가 체계와 그 실증 결과를 제시한다. 핵심 질문은 합성 증강이 성능을 높이는가에 머물지 않고, 그 이득이 어떤 분포 변화까지 유지되며 관찰된 실패를 어떤 기제로 설명할 수 있는가이다. 이를 위해 데이터 누출을 통제한 파이프라인, 두 모델 계열, 동일 표본 budget 대조군, L0-L5 평가와 L6 외부 실패 진단으로 구성된 Shift Ladder를 구현하였다.

Car-Hacking을 주 탐지기의 유일한 학습 데이터로 사용하고 OTIDS, can-train-and-test 및 ROAD는 주 평가에서 외부 평가 전용으로 분리하였다. Target-normal 및 dataset-native 재학습은 실패 기제를 점검하는 진단으로만 수행하였다. 원시 CAN frame을 episode와 시간 block 기준으로 먼저 분할한 뒤 128-frame window를 stride 32로 구성했으며, 전처리 통계와 checkpoint 선택에는 source train과 validation 정보만 사용하였다. 규칙 기반 생성기는 DoS, Fuzzy, Gear 및 RPM family를 구현하고, 학습과 분리된 고정 변형, 강도 민감도, target-ID 이동, payload 문법 이탈 및 외부 domain 평가를 순서화한 Shift Ladder를 구현하였다.

Source test에서 real-only CNN은 binary Macro-F1 0.9992 ± 0.0001 로 포화되었지만, 고정 생성 변형의 attack recall은 0.4862 ± 0.0284 로 나타났다. Rule +10%부터 같은 변형의 recall이 1.0에 도달했고 Random Forest에서도 이득이 재현되었다. 결합 민감도 평가에서는 detection recall이 0.5481 ± 0.0326 에서 Rule +100%의 0.7800 ± 0.0307 로 증가하였다. 이는 규칙 기반 표본이 단순한 표본 수 증가를 넘어 생성 문법에 인접한 공격 변형의 탐지에 도움이 된다는 해석을 뒷받침한다. 다만 학습 update 수를 일치시킨 대조는 후속 검증 대상으로 남아 있다. Low-intensity RPM과 문법 밖 exact typing의 급격한 저하는 이 효과가 강도와 attack semantics에 따라 구조적으로 달라짐을 함께 보여준다.

외부 세 데이터에서는 CNN FPR이 거의 1에 도달하였다. Whitelist, channel ablation, OOD score, target-normal 재학습과 native/transfer 비교를 연결함으로써 CAN-ID vocabulary뿐 아니라 non-ID support와 운영점 변화까지 한 평가 체계에서 진단하였다. 개별 channel의 인과적 기여는 현재 분석만으로 식별되지 않는다. 본 연구의 기여는 합성 증강의 controlled-variant 이득, 문법 경계에서의 binary/exact 분화, 외부 support에서의 운영점 붕괴를 하나의 평가 계단에서 연결하고 효과의 적용 범위와 한계를 실증적으로 구분한 데 있다. 결과표와 그림은 원자료 및 재현 자료와 연결하였다.

목차

요약	i
1 연구 배경과 문제 정의	1
1.1 연구 목표	1
1.2 선행연구와 평가 공백	1
1.2.1 CAN IDS와 benchmark 포화	1
1.2.2 데이터셋, 분포 이동과 cross-dataset 연구	1
1.2.3 합성 데이터와 평가 공백	1
1.3 연구 범위와 자료 구성	2
1.4 용어와 평가 단위	2
1.5 연구질문과 실증 범위	3
1.6 학술적 기여	4
2 연구 설계와 분석 범위	4
2.1 시스템 기능과 분석 대응	4
2.2 재현성 및 검증 기준	5
2.3 평가 설계의 구체화	5
2.4 실험 제약과 분석 범위	6
2.5 연구가설과 관찰 결과	7
3 평가 방법론과 시스템 구현	8
3.1 전체 아키텍처	8
3.2 데이터 역할과 전처리	9
3.3 규칙 기반 생성기	10
3.4 탐지기와 비교군	11
3.5 Shift Ladder 평가 모듈	12
3.6 지표와 집계 규칙	13
3.7 구현 구조와 실험 파이프라인	13
3.8 재현성 및 결과 자료 관리	15
4 실험 설정과 분석 절차	15
4.1 Source baseline과 고정 변형 평가	15
4.2 결합 강도 민감도 평가	16
4.3 Target-ID 이동과 생성 문법 이탈 평가	16
4.4 생성 아티팩트와 표본 수 대조 실험	16
4.5 외부 교차평가와 오탐 기제 분석	16
5 실험 결과와 분석	17
5.1 Source 성능과 고정 변형 이득	17
5.2 강도 민감도와 잔여 취약 구간	18
5.3 ID 이동과 문법 이탈의 분리	20
5.4 생성 분포의 식별 가능성	21
5.5 외부 domain 성능	21
5.6 외부 FPR 포화의 원인 분해와 보정 진단	23
5.7 단계별 결과 종합	25
5.8 결과 종합 및 학술적 기여	25
6 타당도 위협과 추가 검증	26
6.1 구성 타당도	26
6.2 내적 타당도	26
6.3 외적 타당도	26
6.4 통계적 결론 타당도	27
6.5 결과의 적용 범위와 한계	27
6.6 추가 검증 설계	27
7 연구 수행 현황과 잔여 일정	29
7.1 연구 수행 범위	29
7.2 구현 및 분석 현황	29
7.3 기준일 이후 연구 계획과 제출 일정	30
7.4 일정 위협과 대응	31
7.5 연구 진행 요약	31

제1장 연구 배경과 문제 정의

1.1 연구 목표

본 연구는 합성 CAN 공격 데이터가 제공하는 성능 이득의 존재 여부뿐 아니라 그 이득이 어떤 분포 변화까지 유지되고 어디서 소멸하는지를 분석한다. CAN은 송신자 인증과 payload 암호화를 기본으로 제공하지 않아 bus 접근 권한을 획득한 공격자가 frame을 주입·재생·범람시킬 수 있다 [17, 5, 21]. 이러한 공격을 탐지하는 많은 CAN IDS가 공개 split에서 높은 성능을 보고하지만, source 내부의 포화된 점수는 새로운 공격 변형이나 차량 domain에서의 성능을 보장하지 않는다[2, 4].

합성 데이터는 희소 공격 class를 보완할 수 있으나, 생성기와 평가 자료가 규칙을 공유하면 모델이 공격의 일반적 특징보다 생성 artifact에 맞는 decision boundary를 학습할 수 있다[24, 35]. 이러한 지름길 학습은 평가 변형이 같은 생성 recipe를 공유하는 동안에는 드러나지 않는다[8]. 따라서 본 연구는 새로운 탐지기나 생성기 자체보다 평가 절차를 연구 대상으로 삼는다. 구체적으로는 (1) 증강 이득이 실제로 존재하는지, (2) 그 이득이 어떤 분포 변화까지 유지되는지, (3) 이득이 사라지는 지점의 실패 기제가 무엇인지를 하나의 재현 가능한 절차로 검증하는 평가 체계를 구성한다.

1.2 선행연구와 평가 공백

1.2.1 CAN IDS와 benchmark 포화

CAN IDS는 entropy와 message interval을 이용한 규칙 기반 방법 [22, 26, 29]에서 recurrent 분류기[30]와 심층 신경망 기반 탐지기 [14, 23]까지 발전해 왔다. 공개 benchmark의 점수는 Car-Hacking과 같은 source에서 거의 완벽에 가깝지만[27], 방법론 연구는 수집 차량, attack realism과 split 정책이 그 의미를 제한하며 배포 강건성을 직접 입증하지 않는다고 지적한다[4, 2]. 이에 본 연구는 source 성능을 결론이 아니라 더 엄격한 평가를 시작하는 기준선(L0)으로 사용한다.

1.2.2 데이터셋, 분포 이동과 cross-dataset 연구

ROAD는 물리적으로 검증한 공격과 기존 CAN dataset의 한계를 강조하고 [33], can-train-and-test와 CAN-Sleuth는 dataset 및 vehicle 축이 탐지 성능에 미치는 영향을 보여준다[18, 15]. 다중 dataset 연구에서도 cross-dataset 성능 저하가 반복적으로 관찰되었으며 [6, 31], 최근에는 일곱 개 공개 CAN capture를 하나의 benchmark로 통합해 다섯 종류의 탐지기를 교차평가한 결과 절대 점수와 모델 순위 모두 dataset을 바꾸면 유지되지 않는다는 보고가 있다[16]. Cross-dataset 전이가 어렵다는 관측 자체는 본 연구의 새로운 발견이 아니다. 차이는 추정 대상에 있다. 선행 연구가 실제 dataset 간 절대 성능을 비교한다면, 본 연구는 합성 증강이 만든 paired 변화량이 평가 조건이 엄격해질수록 어떻게 감소하는지를 추적하고, 그 결과 남는 실패를 충분조건·필요조건·복구 가능성으로 분해한다.

1.2.3 합성 데이터와 평가 공백

합성 보안 데이터는 class 불균형과 희소 pattern을 완화할 수 있지만, 그 가치는 sample의 외형보다 downstream behavior로 검증되어야 한다[24]. CAN 분야에서는 GIDS가 GAN 기반 탐지와 Car-Hacking data를 제시했고 [25], CANet은 SynCAN을 도입했으며[12], parameterized 공격 트

래픽 생성 도구[13]와 ACGAN · balanced augmentation [35, 34]이 탐색되었다. 완성차 업계에서도 탐지기 개발을 위해 DoS, fuzzing, spoofing 트래픽을 parameterized 방식으로 생성하는 사례가 보고된다[28]. 그러나 보고된 CAN 증강 결과의 대부분은 in-dataset 평가에 머물러 있으며, 합성 데이터의 품질과 cross-vehicle 검증을 강화해야 한다는 요구가 최근 제기되었다[20].

합성 데이터 연구 일반에서는 train-synthetic-test-real 절차[7], sample 수준의 fidelity · diversity 지표[1], 그리고 품질 지표가 downstream 성능을 예측하지 못한다는 증거[32]를 통해 fidelity와 utility를 분리해 왔다. 증강이 왜 도움이 되는지를 분포 이동과 다양성의 결합으로 설명한 연구도 있다[9]. 학습 생성기와 평가 변형이 같은 문법을 공유하면 평가는 순환이 된다. 본 연구는 동일 budget의 실제 표본 복제, real/synthetic separability, 강도 민감도, 생성 문법 이탈과 FPR-first 외부 평가를 결합하여 이 공백을 다룬다.

1.3 연구 범위와 자료 구성

연구 수행 및 실험 결과의 기준일은 2026년 7월 2일이며, 이 보고서의 제출본 정리일은 2026년 9월 7일이다. 본문의 완료 · 미완료 상태와 수치 · 그림은 연구 기준일에 확보된 결과를 기술한다. 이후 실험의 성과는 이 중간보고서에 포함하지 않으며, 제7장의 후속 실험 일정은 기준일 이후의 계획으로 구분한다.

1.4 용어와 평가 단위

본문은 실험 설정을 정확히 구분하기 위해 일부 용어를 영문 그대로 사용한다. 표 1.1는 반복해서 등장하는 용어의 의미를 본 연구의 분석 범위에서 정의한다.

표 1.1: 반복 사용 용어의 정의

용어	본 연구에서의 의미
Window	연속된 128개 CAN frame을 stride 32로 묶은 평가 단위. 각 frame은 11개 feature로 표현한다.
Rung (L0-L6)	Shift Ladder의 평가 단계. 각 단계의 결과는 해당 평가 조건의 범위에서 해석하며, 다음 단계에서는 더 넓은 분포 변화를 평가한다.
Arm (학습 조건)	Real-only, real oversampling, Rule +r% 등 서로 비교하는 학습 조건.
Budget	Arm 사이에서 맞추는 학습 표본 수. Equal-budget은 추가 표본 수를 동일하게 둔 비교를 뜻한다.
Generator grammar	규칙 생성기가 공개한 CAN-ID, DLC, payload, timing, 주입 위치의 변환 규칙.
Grammar exit	공개한 payload 위치 밖으로 변형을 옮긴 compound stress. 위치 하나의 인과 개입이 아니다.
Binary / exact recall	공격 여부 탐지 recall과 정확한 attack family 분류 recall. 두 지표를 구분하여 제시한다.
FPR-first	외부 결과에서 정상 window의 FPR을 먼저 확인하는 평가 방식. FPR이 1에 가까우면 attack recall만으로 탐지 성능을 판단하기 어렵다.

용어	본 연구에서의 의미
Support	특정 feature 값이 학습 분포에서 실제로 관측된 범위. Support shift는 외부 데이터가 이 범위를 벗어나는 현상이다.
Calibration	예측 점수와 실제 정답 빈도의 일치 정도. 외부 정상 입력의 attack score가 1에 포화되어 실제 정답 빈도와 어긋나면 운영점 calibration 붕괴로 표현한다.
Pipeline seed	Subset 추출, 초기화, batch 순서와 조기 종료를 함께 결정하는 seed. seed 반복은 같은 split 안의 pipeline 변동이다.
Construction	Gear/RPM처럼 생성기가 정의한 payload 조작 문법의 이름. DBC로 검증된 차량 물리 신호가 아니다.
보조 분석 (Diagnostic)	주요 모델의 학습과 선택에 관여하지 않고 실패 원인을 확인하는 분석. Target-normal 재학습, OOD score, native/transfer가 해당한다.

1.5 연구질문과 실증 범위

연구질문 RQ1-RQ4와 현재 분석이 제공하는 실증 범위를 표 1.2에 정리하였다. 외부 오탐 기제 분석은 RQ3의 보조 분석이며, matched-placebo를 이용한 RQ4의 생성 규칙 효과 분석과는 구분된다.

표 1.2: 연구질문과 현재 실증 범위

구분	연구질문	실증 범위
RQ1	규칙 기반 합성 증강의 controlled-variant 이득은 실제 공격 증량과 동일 학습 update 대조 이후에도 유지되는가?	CNN/RF의 real-only, real oversampling 및 Rule ratio sweep 결과를 분석하였다. Matched-update 대조는 현재 실증 범위에 포함되지 않는다.
RQ2	합성 증강 효과는 공격 강도, attack family와 생성 규칙 이탈에 따라 어떻게 달라지는가?	Low/medium/high 민감도, family별 분해, target-ID 이동과 out-of-generator payload stress를 분석하였다.
RQ3	Source에서 고정한 운영 정책이 외부 차량 데이터셋에서 FPR 악화 없이 attack recall을 개선하는가?	세 외부 데이터의 source-policy 교차평가를 수행했으며, whitelist, masking, target-normal 및 native/transfer 분석은 실패 기제 진단으로 분리하였다.
RQ4	여러 generator realization에서 생성기에 구현된 Gear/RPM 관계가 marginal-matched placebo를 넘어 추가적인 material increment를 제공하는가?	대조 논리와 endpoint를 정의하였다. Construction crossing과 TOST 결과는 현재 실증 범위에 포함되지 않는다.

1.6 학술적 기여

첫째, Shift Ladder는 합성 증강 효과를 source 성능, 문법 공유 변형, 결합 민감도, target-ID 이동, 문법 이탈, 외부 domain과 기제 진단의 순서로 검증한다. 이에 따라 단일 benchmark 점수를 분포 변화에 따른 결과와 한계로 재구성하였다. 둘째, equal-budget oversampling과 두 모델 계열을 사용하여 controlled-variant 이득이 단순 class count나 특정 neural architecture에서만 발생한 현상이 아님을 보였다. 셋째, binary detection과 exact typing, attack recall과 normal FPR을 분리함으로써 모델이 공격을 탐지한 경우와 모든 외부 입력을 공격으로 처리한 경우를 구별하였다. 넷째, whitelist, channel ablation, OOD score, target-normal 및 native/transfer 진단을 연결하여 외부 오탐을 복합 support shift의 문제로 구체화하였다.

모든 결과표와 그림은 원본 데이터, 생성 script 및 dataset 출처와 연결하였다. 이러한 자료 구성은 결과의 재현과 추가 검증에서의 직접 비교를 지원한다.

제2장 연구 설계와 분석 범위

연구 시스템은 기능 요구사항 FR-01~FR-09, 비기능 요구사항 다섯 항목, 검증 기준과 연구가설 H1~H5로 구성된다. 이 장은 각 요구사항을 현재 구현 및 실증 범위에 대응시키고, 평가 설계를 제약하는 조건과 그 방법론적 영향을 기술한다.

2.1 시스템 기능과 분석 대응

표 2.1: 시스템 기능과 구현 범위

ID	기능	구현 범위	구현 내용
FR-01	데이터 역할 분리	구현	Car-Hacking은 train/validation/source test, 외부 세 dataset은 evaluation-only로 설정 파일에 고정하였다.
FR-02	Train-only 생성	구현	규칙 생성기는 Car-Hacking train split의 normal window 만 base로 사용한다. 고정 · 민감도 변형은 held-out test normal에서 별도 생성한다.
FR-03	비교군 구성	부분 구현	Real-only, real oversampling +50%, Rule +10/30/50/100%를 CNN과 RF에 구현하였다. Optimizer update 수를 맞춘 matched-update 대조는 현재 실증 범위에 포함하지 않았다.
FR-04	반복 가능한 학습	구현	Pipeline seed 7/42/123(주 결과)과 2026/3407(민감도 · stress 추가), 생성기 seed 314159를 설정과 log에 기록하였다.
FR-05	단계적 평가	구현	L0 source, L1 fixed variant, L2 sensitivity, L3 target-ID, L4 grammar exit, L5 external과 L6 외부 실패 진단/repair 를 모듈로 구현하였다.

ID	기능	구현 범위	구현 내용
FR-06	지표 분리	구현	Binary detection recall, exact family recall, binary Macro-F1, FPR/normal recall, ECE를 별도 산출한다.
FR-07	외부 평가 보호	구현	외부 label은 학습 · validation · checkpoint 선택에 사용하지 않는다. Target-normal 재학습, oracle threshold, native/transfer는 보조 분석으로 구분하고 주요 평가 결과와 분리하여 저장한다.
FR-08	생성 규칙 효과 분석	설계	Marginal-matched placebo 생성기와 balance gate의 대조 구조를 정의하였다. 현재 결과에는 RQ3의 외부 실패 원인 분석만 포함한다.
FR-09	결과 추적	부분 구현	표 56개와 그림 33개를 원본 CSV와 생성 script에 연결하였다. Model과 scaler의 hash를 기록했으며, 개별 학습 실행까지 연결하는 세부 추적은 추가 구현 범위다.

2.2 재현성 및 검증 기준

표 2.2: 비기능 요구사항의 검증 결과

속성	검증 수준	근거
재현성	부분 검증	설정 파일과 seed에서 표 · 그림을 재생성하는 script를 확인하였다. 독립 환경 재현은 현재 검증 범위에 포함되지 않는다.
추적성	검증	본문의 모든 수치가 원본 CSV와 일대일로 연결된다.
무결성	검증	원시 dataset과 기준 실험 산출물은 읽기 전용으로 두고, 파생 결과는 versioned 경로에 기록한다.
해석 가능성	검증	Rung별 해석 범위, FPR-first, binary/exact 분리, 주 평가와 보조 분석의 구분을 본문과 표에 적용하였다.
확장성	부분 검증	RF를 같은 평가 interface에 추가하여 공통 schema를 확인하였다. Placebo 및 학습 기반 생성기는 현재 구현 범위에 포함되지 않는다.

현재 평가는 (1) dataset 역할과 사용 시점의 기록, (2) seed별 결과와 mean/std 제공, (3) 외부 결과의 FPR-recall 공동 평가, (4) 표 · 그림의 코드 재생성을 충족한다. 모든 가설의 확정적 검정에는 matched 대조와 사전 정의된 최소 효과 크기가 추가로 필요하다. 현재 결과는 mean/std와 paired 차이를 제시하며, paired interval은 추가 분석 대상으로 둔다.

2.3 평가 설계의 구체화

초기 설계의 데이터 역할 분리와 단계적 평가 원칙을 유지하면서 각 rung의 평가 목적과 해석 범위를 구체화하였다. 특히 외부 데이터의 attack recall은 정상 FPR과 결합하여 평가하며, 두 지표가 동시에 유효한 경우에만 탐지 성능으로 해석한다.

표 2.3: 초기 설계와 구현 설계의 대응

항목	초기 설계	구현 설계	방법론적 영향
평가 단계	Source, generated variant, external을 구분	L0 source, L1 fixed, L2 sensitivity, L3 target-ID, L4 grammar exit, L5 external, L6 외부 실패 진단/repair로 세분화	단계별 평가 목적과 해석 범위 구체화
학습 비교군	Real-only, real oversampling, matched-update, Rule 및 placebo 계획	Real-only, oversampling, Rule ratio sweep과 RF를 구현; matched-update와 placebo는 추가 검증	표본 수와 모델 계열의 영향을 우선 분석하고 학습 횟수와 생성 규칙의 영향은 추가 평가
외부 평가	Source threshold의 FPR/recall과 ranking 지표 계획	OTIDS, can-train, ROAD의 source-policy FPR/recall, threshold 정책 민감도 및 support 진단	Everything-is-attack 모드 식별; ranking 검증은 추가 분석
기제 분석	20개 construction의 marginal-matched placebo와 TOST 계획	Whitelist, ID masking, non-ID/ID-only 재학습, support-factor 및 OOD 분석	외부 실패 원인은 RQ3에서 분석하고, 생성 규칙의 고유 효과는 RQ4 추가 검증에서 평가
고전 baseline	계획에 없음	Entropy 및 per-ID timing 규칙 탐지기를 같은 ladder에 통과	외부 실패가 학습 모델에 국한되지 않음을 확인
통계 반복	주요 비교 5 paired pipeline과 20 construction 계획	Main은 3 seed, sensitivity/stress/channel ablation은 5 paired pipeline seed; construction 검정은 추가 범위	반복 단위와 추가 검증 범위를 분리
재현성	설정과 결과 저장	표·그림의 원본 자료, 생성 script와 checksum을 연결	결과의 추적 가능성 확보

2.4 실험 제약과 분석 범위

표 2.4는 실험 설계의 주요 제약과 관측된 영향을 정리한다. 제약은 데이터 역할, 통계적 반복 단위와 해석 범위를 결정하며, 일부는 외부 평가에서 예상보다 큰 분포 차이로 나타났다.

표 2.4: 실험 제약과 분석상 대응

제약 사항	관측 수준	분석상 대응
차량별 support 차이	확대	Source train 상위 20개 ID의 외부 정상 frame coverage는 OTIDS 0.5683, can-train 0.0392, ROAD 0.0287로 예상보다 낮았다. 외부 결과는 FPR-first로 보고하고 support 진단을 추가하였다.
생성기 · 평가 변형의 문법 공유	유지	문법 내부(L1), 강도 변화(L2), 문법 이탈(L4)을 분리하였다. Placebo 대조는 추가 검증 대상이다.
128-frame window 중첩	유지	Windowing 전에 split을 고정하였다. Seed 통계는 pipeline 변동으로만 해석하고 raw-frame-disjoint 민감도는 추가 검증 대상이다.
제한된 차량 의미 정보	유지	Gear/RPM은 construction family로만 지칭하며, 이 결과만으로 물리 신호의 의미를 직접 입증하지는 않는다.
계산 자원	제한	실험을 script 단위로 자동화하고 versioned output을 사용하였다. Main 3 seed, 민감도 5 seed로 반복 수를 제한하였다.
데이터셋별 라벨 이질성	확대	OTIDS는 scenario-level, can-train은 source stem, ROAD는 published interval 기반 label이다. 공통 binary endpoint로 통일하였으며, exact-type 결과는 차량 간 전이를 직접 나타내지 않는다.
평가 범위의 시점 제한	고정	7월 2일까지 확보된 결과만 본 분석에 포함하고 추가 실험은 별도 결과 집합으로 관리한다.

이 외에 구현 중 확인한 제약이 두 가지 있다. 첫째, source 내부 성능이 포화되어 Macro-F1만으로 증강 arm을 구분하기 어렵다. 따라서 고정 생성 변형, 강도 sweep과 문법 이탈을 별도 평가하였다. 둘째, 외부 normal traffic이 거의 모두 attack으로 분류되는 경우 attack recall은 유효한 성능 근거가 아니다. 모든 외부 결과는 FPR 또는 normal recall을 먼저 제시하고, calibration · retraining은 주 평가와 분리된 진단으로 표시하였다.

2.5 연구가설과 관찰 결과

가설 H1은 source 성능을 유지하면서 대조군보다 변형 탐지가 개선되는지, H2는 강도 증가에 따라 증강 이득이 감소하는지, H3은 L4에서 L1보다 binary-exact recall의 격차가 커지는지를 다룬다. H4는 외부 FPR의 허용 조건을 만족하면서 recall이 개선되는지, H5는 주변 분포를 맞춘 placebo보다 생성 규칙이 실질적인 추가 효과를 제공하는지를 검증한다.

표 2.5는 이 가설들에 대한 관찰 결과를 효과 방향과 paired seed 반복성에 근거해 요약한다. 확정적 가설 검정에는 최소 효과 크기 δ_{source} , δ_{gain} , H5의 equivalence margin, matched 대조와 불확실성 구간이 추가로 필요하다.

표 2.5: 연구가설별 관찰 결과

가설	관찰 결과	근거	추가 검증
H1	부분 지지	Rule +30%는 source Macro-F1 0.9994를 유지하면서 L1 attack recall을 real-only 0.4862, oversampling 0.4951 대비 1.0으로 높였다(3 seeds 모두 같은 방향).	Matched-update 대조군, 최소 효과 크기와 paired interval을 이용한 평가
H2	수정 필요	L2에서 Rule-control 효과는 강도에 따라 단조 감소하지 않았다. High에서는 real-only도 포화되었고, low에서는 특히 Fuzzy/RPM의 취약성이 남았다. Medium에서 대체로 이득이 컸으며, 효과 크기는 family마다 달랐다.	가설 문구를 ceiling/floor를 포함한 형태로 재정의하고 family 별 추세를 별도 보고
H3	지지 방향	L1의 Gear/RPM binary-exact 격차는 거의 0이었으나 L4에서는 binary ≈ 1.0 , exact Gear 0.1612 · RPM 0.0193으로 격차가 0.84 이상 증가하였다(5 paired seeds).	Paired interval과 최소 격차 기준 적용
H4	지지되지 않음	세 외부 dataset에서 Rule arm의 FPR이 0.99997 이상으로 real-only와 함께 1에 가까워 공동 개선 조건을 만족하지 못했다.	Ranking 지표와 저-FPR 운영점에서의 추가 평가
H5	미검증	Placebo twin, balance gate와 TOST의 대조 구조만 정의되었다.	Construction crossing 실행과 90%/95% interval 분석

제3장 평가 방법론과 시스템 구현

3.1 전체 아키텍처

그림 3.1는 데이터 준비, 생성기, detector 학습과 평가 suite를 연결한 전체 구조다. Car-Hacking train split에서만 synthetic augmentation을 만들고, validation은 checkpoint 선택, held-out test와 생성 변형은 평가에만 사용한다. 외부 dataset adapter는 OTIDS, can-train과 ROAD를 같은 evaluation-only 경계에 연결한다. 그림의 OTIDS 노드는 이 공통 외부 adapter를 대표하며, 구현에서는 세 dataset을 동일한 FPR-first 평가 interface로 처리한다.

전체 아키텍처는 데이터 역할 관리자, 증강 생성기, 학습 제어기, 단계적 평가기, 증강 효과 분석기와 결과 자료 관리자의 여섯 컴포넌트로 구성된다. 현재 구현은 placebo 생성 경로를 제외한 다섯 컴포넌트를 포함한다. 각 컴포넌트는 독립 script로 분리되어 하나의 설정 파일을 공유하며, 3.7절의 실행 파이프라인이 의존 순서를 정의한다.




그림 3.1: Leakage-controlled 데이터 흐름과 평가 구조. Parser와 episode split을 거쳐 학습, held-out 변형 및 외부 평가의 역할을 분리하고, 생성 변형부터 domain shift까지의 평가 suite를 연결한다.

3.2 데이터 역할과 전처리

Car-Hacking은 main training, validation, synthetic generation과 source test에만 사용하였다[11, 25]. 표 3.1는 전처리 단계에서 확인한 원시 frame 통계다. Car-Hacking 다섯 파일에서 파싱 오류는 정상 주행 파일의 1건뿐이었고, timestamp 역전은 없었다.

표 3.1: 원시 CAN frame 통계와 source split 구성

파일 또는 split	Frame 수	정상	공격	비고
Car-Hacking DoS	3,665,771	3,078,250	587,521	고유 ID 27개
Car-Hacking Fuzzy	3,838,860	3,347,013	491,847	고유 ID 2,048개
Car-Hacking Gear	4,443,142	3,845,890	597,252	고유 ID 26개
Car-Hacking RPM	4,621,702	3,966,805	654,897	고유 ID 26개
Car-Hacking normal run	988,871	988,871	0	정상 주행 전용
Source train	8,389,348	6,964,444	1,424,904	episode 기준 분할
Source validation	2,717,054	2,271,642	445,412	checkpoint 선택
Source test	6,451,944	5,990,743	461,201	held-out
OTIDS attack-free	2,369,398	2,369,398	0	고유 ID 45개
OTIDS DoS/- Fuzzy/Impersonation	2,244,041	0	2,244,041	scenario-level label

Chronological attack episode와 normal-only 연속 block을 기준으로 windowing 전에 train/validation/test를 나누었다. Attack episode는 frame 간격 1.0초를 경계로 정의하고 family별 capture 안에서 시간순으로 60/20/20 배분하였다. 이 비율은 분할 단위의 배분 기준이며, episode 길이가 달라 실제 frame 수의 비율과는 다르다. Source-file과 source-row 감사에서 train/validation/test 사이의 원시 frame 중복은 0건이었다. 이는 같은 capture 안의 시간 분리이며 capture 독립성은 아니다. 표 3.2은 평가 자료의 실제 window 수와 역할을 정리한다.

표 3.2: 데이터셋별 역할과 실제 window 수

데이터셋	역할	Window 수	사용 경계
Car-Hacking train	학습 · generator fitting	262,149 (normal 138,976 / attack 123,173)	학습과 scaler 적합
Car-Hacking validation	checkpoint 선택	84,890 (normal 46,224 / attack 38,666)	모델 선택 전용
Car-Hacking test	source held-out	201,606 (normal 161,666 / attack 39,940)	최종 source 평가
Fixed variant	L1 positive control	64,000 (normal 32,000 / attack 32,000)	test normal 기반, 평가 전용
Sensitivity set	L2 결합 민감도	30,000 (normal 12,000 / attack 18,000)	4개 family×3단계 강도, 12 cell
OTIDS	외부 binary 평가	144,156 (normal 74,040 / attack 70,116)	평가에만 사용
can-train-and-test	외부 binary 평가	4,490,896	주요 모델 선택에 사용하지 않음
ROAD	외부 binary 평가	856,605	12 ambient, 29 attack capture

OTIDS, can-train-and-test와 ROAD는 주요 모델의 외부 평가에만 사용하였다 [10, 19, 18, 33]. Target-normal 및 dataset-native 재학습은 주요 checkpoint의 학습 · 선택에 관여하지 않는 실패 원인 분석으로만 수행하였다. Accelerator capture는 injected frame이 없어 ROAD attack 평가에서 제외하였다. 모든 dataset은 timestamp, 16진수에서 정수로 변환한 CAN ID, DLC, 여덟 payload byte, Δt 의 동일 schema로 매핑한다.

각 frame은 numeric CAN ID, DLC, 여덟 payload byte와 시간차 Δt 의 11개 feature로 표현하였다. Payload는 DLC에 맞춰 zero-padding하고, 128-frame window를 stride 32로 생성하였다. Window는 split 경계를 넘지 않는다. 하나 이상의 attack frame이 있으면 binary Attack으로, exact label은 window 안의 majority attack family로 정하며 동률은 numeric label 순서로 결정한다. Standardizer는 real Car-Hacking train에만 적합하고 모든 생성 · stress · external 평가에 그대로 적용했다. 이 선택은 source에서 학습한 모델을 그대로 배포하는 조건을 보존하며, 외부 점수 포화를 target 정규화로 숨기지 않고 관측 가능하게 만든다.

3.3 규칙 기반 생성기

규칙 기반 생성기는 train-normal base window에 DoS, Fuzzy, Gear와 RPM construction을 주입한다. Train pool은 네 family 각각 65,000개, 총 260,000개 attack window로 구성하였다. 고정

변형과 민감도 변형은 held-out test normal에서 별도로 생성하고 학습에 사용하지 않았다. 생성 문법은 CAN-ID, DLC, payload, timing과 주입 위치의 변환 규칙으로 공개하며, 표 3.3는 학습 규칙과 고정 평가 변형의 차이를 정리한다.

표 3.3: 학습 합성 규칙과 고정 평가 변형

Family	학습 pool 규칙	고정 평가 변형
DoS	ID 0x000, burst 32–90, step 1–2, 주로 0 payload, 짧은 Δt	Burst 48–96, step 1–2, 0 payload, Δt 를 0.25 배로 축소
Fuzzy	ID 0–2047, DLC 2/5/8, burst 24–88, step 1–4, uniform payload	Burst 40–96, step 1–3, DLC 8, uniform payload와 짧은 random Δt
Gear	ID 0x43F, burst 32–90, step 1–3, byte 0/1 level 및 inverse-level 관계	ID 0x43F, burst 48–96, step 2, byte 2 ramp, byte 3 inverse ramp와 byte 4 perturbation
RPM	ID 0x316, burst 32–90, step 1–3, byte 0/1 RPM-derived 관계와 byte 2 perturbation	ID 0x316, burst 48–96, step 2, byte 2 sinusoid, byte 3 ramp와 byte 5 perturbation

평가 전용 변형은 세 종류다. 첫째, L2 민감도 변형은 고정 문법을 재사용하되 burst, step과 amplitude 등을 low/medium/high 수준으로 함께 바꾼다. Gear/RPM의 payload 위치는 각 family 안에서 강도와 무관하게 고정한다. 여러 축이 결합된 stress이므로 단일 intensity의 인과효과로 해석하지 않았다. 둘째, L3 target-ID 변형은 train-normal support에 존재하지만 Rule 학습의 target으로 쓰이지 않은 shifted ID에 같은 Gear/RPM payload grammar를 적용한다. 셋째, L4 out-of-generator 변형은 L3 대비 burst/span, step, payload 위치, waveform과 jitter를 함께 바꾸고 시간적 window 배치는 유지한다. 이 조건은 규칙 문법에 대한 payload 위치 이탈을 포함하지만 위치 하나만 바꾼 개입은 아니다.

3.4 탐지기와 비교군

주 탐지기는 128-by-11 input을 받는 1D-CNN이다. Conv1D 64–128–128 block, batch normalization, ReLU, pooling, dropout 0.2와 five-class head를 사용하였다. Class-weighted cross entropy, AdamW learning rate 10^{-3} , weight decay 10^{-4} , batch size 512를 적용하고 validation multiclass Macro-F1이 가장 높은 checkpoint를 선택하였다. Real-only는 최대 20 epoch와 patience 4, augmented와 oversampling은 최대 12 epoch와 patience 3을 사용하였다.

Random Forest는 11개 frame feature의 mean, standard deviation, minimum, maximum과 last-minus-first를 집계한 55차원 feature를 입력으로 받는다. 160 trees, minimum leaf 2와 balanced-subsample weighting을 사용하였다. RF는 frame의 세부 시간 순서를 직접 모델링하지 않는 집계 표현이므로 CNN과 inductive bias가 다르며, 같은 효과가 두 계열에서 반복되는지 점검하는 두 번째 모델 계열 역할을 한다.

학습 arm은 표 3.4와 같다. 증강 비율 $r\%$ 는 정상과 공격을 합친 실제 train window 262,149개의 $r\%$ 에 해당하는 합성 표본을 추가한다는 뜻이다. Rule +10/30/50/100%의 추가 표본은 각각 26,215/78,645/131,074/262,149개이며, 네 공격 family에 가능한 한 균등하게 배분한다. Rule +100%는 합성 pool의 260,000개를 초과하므로 복원 추출한다. Equal-budget real oversampling은

Rule +50%와 같은 131,074개의 실제 attack window를 복제하여 단순 표본 수 증가가 고정 변형 이득을 설명하는지 점검한다.

표 3.4: 구현한 학습 arm과 통제 목적

학습 arm	구성	통제하려는 대안 설명
Real-only	Car-Hacking train split만 사용	증강 없는 기준 성능
Real oversampling +50%	실제 attack window를 Rule +50%와 같은 수만큼 복제	표본 수 · class balance 효과
Rule +10/30/50/100%	전체 real train 수의 해당 비율만큼 규칙 생성 pool에서 추출해 추가	전체 합성 증강 효과와 증강량 의존성
Rule +30% RF	같은 Rule pool로 학습한 Random Forest	특정 neural architecture 의존성
Matched-update (추가 검증)	Real-only 데이터로 optimizer update 수를 Rule과 일치	추가 학습 기회 효과
Marginal-matched placebo (추가 검증)	주변 분포와 주입 구조를 맞추고 Gear/RPM 관계만 교란	구현 관계의 추가 효과

3.5 Shift Ladder 평가 모듈

표 3.5: Shift Ladder 단계별 평가 목적과 해석

Rung	평가 조건	평가로 확인하는 내용
L0	Source held-out test	해당 split 안의 성능과 FPR. 다른 분포에서의 성능을 직접 나타내지는 않는다.
L1	Fixed generated variant	생성 문법을 공유하는 positive control에서의 제한적 이득. 결과는 평가에 사용한 변형 범위에 적용된다.
L2	Sensitivity sweep	결합 parameter와 강도 변화에 대한 부분 강건성. 평균과 cell 별 recall을 함께 제시하며, 시험하지 않은 설정은 평가 범위에 포함하지 않는다.
L3	Target-ID shift	고정 canonical ID 암기만으로 이득이 설명되지 않음. Exact recall 변화를 함께 확인한다.
L4	Grammar exit	공개 문법 밖 binary anomaly boundary. Binary와 exact를 분리하고 여러 field가 함께 변한 결과로 해석한다.
L5	External datasets	FPR과 attack recall을 함께 이용한 domain-shift 성능. FPR이 1에 가까우면 attack recall만으로 탐지 성능을 판단하기 어렵다.
L6	Attribution/repair	오탐 원인 후보와 개선 방법의 한계를 확인하는 보조 분석. 주요 모델의 학습과 선택에는 사용하지 않는다.

각 rung은 평가 조건과 결과 해석의 범위를 연결하는 평가 단위다. L1은 생성 문법을 공유하는 변형의 이득을, L4는 binary anomaly boundary와 exact typing의 분리를, L5는 FPR과 recall의 공동 유효성을 측정한다. FPR이 1에 가까운 상태에서의 recall은 모든 입력을 공격으로 판정하는 everything-is-attack 모드이며, base-rate 관점에서 탐지 성능이 아니다[3]. 이 순서는 source 성능에서 구성된 변형을 거쳐 외부 운영점까지 평가 범위를 넓히는 단계적 구조이며, 보정된 분포 거리를

의미하지는 않는다. 그림 3.2는 이 순서에 따른 평가 결과를 요약한다.




그림 3.2: Shift Ladder 평가 결과. 생성 변형에서의 positive gain과 grammar-exit의 binary/exact 분리, 외부 FPR 증가를 한 흐름으로 나타낸다. Grammar-exit rung의 빈 marker는 exact recall이 이미 붕괴한 상태에서의 binary recall이다.

3.6 지표와 집계 규칙

정상 window는 binary 0, 모든 attack family는 binary 1이다. 평가 지표는 정상 window FPR, binary attack recall, binary Macro-F1, exact-type recall과 expected calibration error(ECE)다. FPR은 정상 window 중 공격으로 오분류한 비율이고, binary attack recall은 공격 window 중 공격으로 탐지한 비율이다. Binary Macro-F1은 정상 · 공격 두 class의 F1을 평균한 값이다. Exact recall은 공격 window 중 정확한 family까지 맞힌 비율이다. Exact recall의 집계는 별도 표기가 없으면 attack window 전체에 대한 pooled(exact-micro) 값이며, Gear/RPM family 평균은 exact-macro로 표기한다. 외부 결과는 FPR과 attack recall을 항상 한 쌍으로 보고하고, AUROC는 threshold와 무관한 점수 순서 진단에만 사용한다.

지표는 pipeline seed별로 계산한 뒤 mean과 sample standard deviation으로 요약한다. Main source/external CNN · RF는 seeds 7, 42, 123을, sensitivity, stress와 channel ablation은 2026과 3407을 더한 다섯 seed를 사용한다. Seed 통계는 하나의 고정 split과 generator construction 안에서 subset 추출, 초기화, batch 순서와 초기 종료가 함께 만드는 pipeline 변동이며, 독립 차량 반복이 아니다. Paired 비교는 같은 seed의 arm 차이를 사용하고, seed 수가 3-5이므로 통계 검정은 보조 근거로만 제시한다.

3.7 구현 구조와 실행 파이프라인

구현은 설정 파일 하나(config.yaml)와 54개의 Python script로 구성되며, 16개 실험 단계 폴더에 산출물을 기록한다. 실행 환경은 Linux(aarch64), 단일 NVIDIA GPU, Python 3.12, PyTorch(CUDA), scikit-learn, pandas, numpy이며 정확한 버전은 requirements.lock.txt에 고정하였다. 표 3.6은 여섯 단계 실행 파이프라인과 각 단계의 대표 script, 입력과 출력을 정리한다.

표 3.6: 실행 파이프라인 단계별 script와 산출물

단계	대표 script	입력 → 출력
1. 전처리 · 분할	preprocess_datasets validate_preprocessing split_datasets generate_windows profile_datasets	원시 CSV/TXT → 공통 schema frame, episode split, 128/32 window array, dataset profile
2. 생성	generate_rule_based_synthetic generate_variant_test generate_variant_sensitivity generate_target_id_shift_stress generate_out_of_generator_stress	train normal → 260k 학습 pool; test normal → 고정 변형 64k, 민감도 30k, L3/L4 stress set
3. 학습	train_real_only_baselines train_rule_synthetic_ratio_sweep train_oversampling_baseline train_rf_augmented train_channel_ablation	window array와 arm 설정 → seed별 checkpoint, 학습 이력, run config
4. Ladder 평가	evaluate_variant_baselines evaluate_variant_sensitivity evaluate_target_id_shift_stress evaluate_out_of_generator_stress run_cantt_tier1, preprocess_road evaluate_road_external run_seed_extension_stress	고정 checkpoint → L0-L5 지표 CSV(seed별 · 요약)
5. 추가 분석	profile_synthetic_quality evaluate_threshold_sensitivity run_cantt_lightweight_baseline run_cantt_id_ablation evaluate_published_baselines road_calibration_probe_logit train_target_normal_reinstantiation run_cantt_rf_native_transfer	checkpoint와 외부 data → JS/AUC, threshold 정책, whitelist, masking, baseline, OOD, target-normal, native/transfer 결과
6. 집계 · 산출	aggregate_baseline_results prepare_reinforcement_tables make_evaluation_ladder_figure prepare_paper_artifacts	단계별 CSV → 표 56개, 그림 33개, 재현 자료 목록

모든 script는 설정 파일을 읽어 결과 폴더와 실험 폴더에 기록하므로, 단계 사이의 인터페이스는 파일 경로와 CSV schema로 고정된다. 학습 단계는 seed마다 run config JSON을 남겨 input 표현, 모델 hyperparameter와 device를 기록한다. 외부 dataset은 평가 단계에서만 읽히며, 진단 단계의 target-normal 재학습은 별도 모델 폴더에 저장되어 주요 checkpoint를 덮어쓰지 않는다.

3.8 재현성 및 결과 자료 관리

Dataset 출처, preprocessing configuration, seed, model checkpoint, 결과표와 figure를 원본 자료에 연결하였다. 결과표 56개와 그림 33개를 별도 재현 자료로 정리하고, 각 항목의 원본 경로와 생성 script를 기록하였다. 재현 자료에는 실행 설정, 전처리·평가 script, 원본 결과표, figure와 dataset download/provenance 안내(SHA256 또는 MD5 checksum 포함)를 포함하고 raw dataset과 trained weight는 재배포하지 않았다. 표 3.7는 결과 재현에 필요한 주요 조건과 구현 위치를 정리한다.

표 3.7: Shift Ladder 재현을 위한 주요 조건과 구현 위치

번호	조건	이행 위치
(i)	생성기는 train-normal 데이터에만 적합하고 데이터 역할을 선언한다	3.2, 3.3절
(ii)	외부 dataset은 평가에만 사용하며 보조 분석은 주요 모델과 구분한다	3.2절, L5-L6
(iii)	학습 없는 ID whitelist 대조로 unseen-ID 행동을 별도 측정한다	5.6절
(iv)	Equal-budget real oversampling으로 증강 효과와 class count 효과를 분리한다	3.4, 5.1절
(v)	Real/synthetic separability로 합성 데이터와 실제 데이터의 차이를 확인한다	5.4절
(vi)	외부 결과는 FPR과 attack recall을 함께 평가하고 everything-is-attack 모드를 구분한다	5.5-5.6절

제4장 실험 설정과 분석 절차

4.1 Source baseline과 고정 변형 평가

먼저 Car-Hacking source test에서 real-only CNN과 RF의 기본 성능을 확인하였다. 이후 학습과 분리해 사전에 고정한 DoS, Fuzzy, Gear, RPM 변형에 동일 checkpoint를 적용하여 source 내부 성능과 생성 규칙에 인접한 변형 성능을 분리하였다. 증강 비율은 전체 real train window 수의 10%, 30%, 50%, 100%로 정의하고, 합성 표본을 각 공격 family에 가능한 한 균등하게 배분하였다. 비율 sweep은 추가 합성 표본량에 따른 성능 변화를 측정하며, 표본 수 효과는 Rule +50%와 oversampling +50%의 비교로 점검하였다.

단순히 attack 표본 수가 늘어난 효과와 규칙 기반 표본의 효과를 분리하기 위해 Rule +50%와 동일한 수의 실제 attack window를 복제하는 real oversampling +50%를 구성하였다. CNN과 구조적 가정이 다른 RF에서도 같은 비교를 반복하여 특정 neural architecture에만 의존하는 결과인지 평가하였다. Source test, 고정 변형, checkpoint 선택 기준은 모든 arm에서 동일하게 유지하였다. Arm 간 차이는 같은 seed의 paired difference로 계산하고, 3 seed에 대한 paired t-test와 Wilcoxon 검정을 보조 근거로 산출하였다.

4.2 결합 강도 민감도 평가

단일 고정 변형의 성능만으로는 규칙 기반 증강이 공격 강도의 연속적 변화에 대응한다고 볼 수 없다. 이에 Fuzzy byte 범위, Gear payload 변화량, RPM 변화량과 주입 간격을 low, medium, high 수준으로 조합한 sensitivity grid를 구성하였다. 각 window에 대해 binary detection과 exact attack-family classification을 동시에 기록하고, seeds 7, 42, 123, 2026, 3407의 paired pipeline으로 비교하였다.

평균 recall뿐 아니라 가장 어려운 low-intensity cell을 별도로 확인하였다. 이는 쉬운 고강도 표본이 평균을 지배하는 현상을 방지하고, 합성 학습분포의 support가 약한 경계에서 이득이 유지되는지를 검증하기 위함이다. Rule 비율 sweep에는 real-only, Rule +50%와 동일 budget의 real oversampling, Rule +10%부터 +100%까지를 포함하였다. 3 seed 결과로 4개 family×3단계 강도의 12 cell을 먼저 분해하고, 5 seed 확장으로 전체 평균과 low-intensity cell의 불확실성을 보장하였다.

4.3 Target-ID 이동과 생성 문법 이탈 평가

Target-ID stress에서는 Gear와 RPM 공격을 canonical ID와 Rule attack 학습에서 target으로 사용하지 않은 train-normal-supported shifted ID에 각각 주입하였다. Payload와 timing 조건을 유지한 채 ID만 바꾸어, 고정된 attack ID 암기가 Rule 증강의 이득을 설명하는지 확인하였다. Canonical과 shifted 조건의 exact recall 차이를 paired seed 단위로 비교하였다.

Grammar-exit stress에서는 burst/span, step, payload 위치, waveform 및 jitter를 함께 바꾼 compound 변형을 사용하였다. 이 조건은 payload 위치 이탈을 포함하지만 위치 하나의 인과 효과를 식별하는 개입은 아니다. Binary attack detection과 exact family recall을 분리하여 anomaly boundary의 반응과 attack semantics의 보존을 구별하였다.

4.4 생성 아티팩트와 표본 수 대조 실험

실제 attack window와 규칙 기반 합성 window의 차이를 feature channel별 Jensen-Shannon divergence로 측정하고, 동일 feature로 real/synthetic를 구분하는 discriminator를 학습하였다. 이 측정은 결합 특징공간에 남은 생성기 고유의 흔적을 정량화하여 controlled utility와 실제 공격분포 정합성을 서로 다른 평가 축으로 분리한다.

Equal-budget oversampling은 동일한 class count만 제공하고 새로운 규칙 변형은 제공하지 않는다. 이 비교에서 Rule arm만 고정 변형 성능을 높인 결과는 해당 construction에서 규칙 변형 정보가 단순 표본량 증가 이상의 기여를 했음을 뒷받침한다. 이와 별도로 validity와 artifact 기준의 단순 filtering이 합성 pool의 효과를 바꾸는지도 보조 분석으로 확인하였다.

4.5 외부 교차평가와 오탐 기제 분석

Source에서 선택한 checkpoint와 threshold를 변경하지 않고 OTIDS, can-train-and-test, ROAD에 적용하였다. 외부 정상 window의 FPR과 attack recall을 함께 측정하였다. 모든 입력을 attack으로 판단하는 정책도 recall은 높게 보일 수 있으므로, 높은 recall과 높은 FPR의 조합은 퇴화한 탐지 상태로 해석하였다. 또한 threshold 정책이 결과를 바꾸는지 보기 위해 validation FPR 0.001과 0.01을 목표로 한 threshold와, 외부 정상 표본을 직접 사용한 oracle threshold를 진단으로

비교하였다. 학습 모델과 별도로 source에 적합한 entropy 탐지기와 per-ID timing 규칙 탐지기를 같은 ladder에 통과시켜 실패가 학습 모델 고유 현상인지 확인하였다.

외부 오탐을 구성하는 요인을 분리하기 위해 다음 순서로 진단하였다. 먼저 source train의 상위 CAN-ID support와 외부 정상 ID의 coverage를 계산하고 단순 whitelist의 FPR을 측정하였다. 다음으로 ID channel masking, ID-only와 non-ID-only 재학습을 수행하여 ID vocabulary의 필요성과 충분성을 분리하였다. Max-logit 및 energy 기반 OOD score, 외부 정상 표본을 사용한 target-normal 재학습, channel group별 support-factor 분해, dataset-native RF와 cross-dataset transfer를 차례로 적용해 score separation, 제한된 repair 및 dataset mismatch를 분석하였다.

제5장 실험 결과와 분석

5.1 Source 성능과 고정 변형 이득

Real-only CNN은 source test에서 binary Macro-F1 0.999201 ± 0.000106 , FPR 0.000221 ± 0.000071 를 기록하였다. Family별 test recall도 DoS 0.9986, Fuzzy 0.9970, Gear 0.9982, RPM 0.9987로 모두 포화되었다. 그러나 학습에서 분리한 고정 생성 변형에 대한 attack recall은 0.486208 ± 0.028437 이었다. 표 5.1는 이 성능의 family별 차이를 제시한다. DoS와 Fuzzy 변형의 exact recall은 높았지만 Gear와 RPM의 exact recall은 거의 0이었다. 이는 변형에 대한 정확한 family 분류가 공격 종류에 따라 크게 달랐음을 보여준다. Family별 exact recall만으로 해당 변형이 정상과 다른 공격 family 중 어느 쪽으로 오분류되었는지는 구분할 수 없다. RF에서도 같은 family별 분화가 나타났다.

표 5.1: Real-only 모델의 고정 변형 binary attack recall과 family별 exact recall (3 seeds)

모델	전체 attack recall	DoS	Fuzzy	Gear	RPM
CNN	0.4862 ± 0.0284	0.9998	0.9230	0.0001	0.0000
RF	0.5000 ± 0.0000	1.0000	1.0000	0.0001	0.0000

표 5.2는 증강 비율에 따른 source test와 고정 변형 결과다. Rule +10%는 고정 변형 recall을 1.0으로 높였고, Rule +30%는 0.999958 ± 0.000072 를 기록하면서 source Macro-F1도 0.999438 ± 0.000145 로 유지하였다. 고정 변형의 ECE는 real-only 0.2444에서 Rule +10% 0.0010으로 감소하여 calibration도 함께 회복되었다. 이는 source 내부의 포화된 성능이 인접 변형 강건성을 대신하지 못하며, 규칙 기반 증강이 생성 construction 안에서는 유효한 boundary를 제공함을 보여준다.

Equal-budget 조건에서도 real oversampling +50%의 고정 변형 recall은 0.4951 ± 0.0046 이었으나 Rule +50%는 1.0이었다. 따라서 고정 변형에서의 증가는 공격 표본 수의 증가만으로 설명되지 않았다. 동일 추가 표본 수에서 단순 복제로 이득이 재현되지 않았다는 점은 규칙 기반 변형의 유용성을 뒷받침한다. 다만 실제 optimizer update 수와 조기 종료까지 일치시킨 대조가 아니므로 데이터 내용만의 인과 효과로 단정하지 않는다. Rule +50%와 oversampling +50%의 고정 변형 attack recall paired 차이는 0.5049였고, 3 seed paired t-test p 는 2.7×10^{-5} 였다. Wilcoxon 검정은 $n = 3$ 에서 최소 p 가 0.25이므로 방향 일치만 확인하며, 이 검정들은 모두 보조 근거다.

모델 계열 대조에서도 같은 효과가 관찰되었다. RF의 고정 변형 recall은 real-only 0.5000에서




그림 5.1: Real-only CNN과 RF의 고정 변형 성능. Binary Macro-F1은 각각 0.7247과 0.7333, attack recall은 약 0.5로 source test보다 낮지만 FPR은 낮게 유지된다.

표 5.2: 증강 비율별 source test와 고정 변형 결과 (CNN, 3 seeds)

학습 arm	Source Macro-F1	Source FPR	변형 attack recall	변형 ECE
Real-only	0.99920 ± 0.00011	0.000221	0.4862 ± 0.0284	0.2444
Real oversampling +50%	0.99927 ± 0.00028	0.000173	0.4951 ± 0.0046	0.2445
Rule +10%	0.99934 ± 0.00009	0.000142	1.0000 ± 0.0000	0.0010
Rule +30%	0.99944 ± 0.00014	0.000113	0.99996 ± 0.00007	0.0001
Rule +50%	0.99909 ± 0.00008	0.000148	1.0000 ± 0.0000	0.0007
Rule +100%	0.99941 ± 0.00011	0.000142	1.0000 ± 0.0000	0.0002

Rule +30%의 0.99997로 증가했고, Rule +30% RF의 결합 민감도 detection recall은 0.749 ± 0.020 이었다. CNN과 feature-aggregation RF에서 효과 방향이 일치하므로, controlled-variant 이득은 단일 neural architecture의 inductive bias에만 의존하지 않는다.

5.2 강도 민감도와 잔여 취약 구간

표 5.3: 결합 강도 민감도 전체 결과 (CNN, 5 seeds)

학습 arm	Macro-F1	Detection recall	FPR
Real-only	0.7273 ± 0.0203	0.5481 ± 0.0326	0.00032 ± 0.00007
Real oversampling +50%	0.7328 ± 0.0290	0.5572 ± 0.0467	0.00037 ± 0.00005
Rule +10%	0.8091 ± 0.0175	0.6822 ± 0.0292	0.00027 ± 0.00004
Rule +30%	0.8352 ± 0.0162	0.7258 ± 0.0273	0.00023 ± 0.00009
Rule +50%	0.8232 ± 0.0339	0.7059 ± 0.0571	0.00027 ± 0.00004
Rule +100%	0.8673 ± 0.0182	0.7800 ± 0.0307	0.00025 ± 0.00000

표 5.3에서 Rule arm은 모든 증강 비율에서 real-only와 real oversampling +50%보다 높은 평균 recall을 보였다. 이 중 Rule +50%와 oversampling +50%가 동일 추가 표본 수의 비교다. 증강량

에 따른 비단조성 및 +50%의 큰 seed 변동에도 각 paired seed의 이득 방향은 유지되었다. Rule +100%와 real-only의 3 seed paired 차이는 0.1988, paired t-test p 는 0.0056이었다. 이는 합성 표본의 양뿐 아니라 분포 구성과 학습 trajectory가 효과 크기를 좌우함을 시사한다. FPR 차이는 정상 window 12,000개 중 한두 개의 판정 차이에 해당하는 작은 규모이며, 이 결과만으로 arm 간 FPR의 동등성을 입증하지는 않는다.

표 5.4: Family×강도 cell별 detection recall과 exact recall (CNN, 3 seeds). 괄호 안은 exact recall이다.

Family	강도	Real-only	Rule +30%	Rule +100%
DoS	low	0.588 (0.564)	0.708 (0.708)	0.641 (0.637)
	medium	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
	high	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
Fuzzy	low	0.002 (0.002)	0.218 (0.185)	0.228 (0.149)
	medium	0.176 (0.164)	0.999 (0.992)	0.999 (0.987)
	high	1.000 (1.000)	1.000 (1.000)	1.000 (1.000)
Gear	low	0.133 (0.061)	0.151 (0.082)	0.506 (0.392)
	medium	0.850 (0.781)	0.999 (0.946)	1.000 (0.995)
	high	1.000 (1.000)	1.000 (0.697)	1.000 (1.000)
RPM	low	0.000 (0.000)	0.000 (0.000)	0.001 (0.001)
	medium	0.040 (0.007)	0.686 (0.676)	0.799 (0.749)
	high	1.000 (0.000)	1.000 (0.619)	1.000 (0.210)

표 5.4는 평균만으로 식별되지 않는 조건별 구조를 보여준다. 이득은 medium 강도에 집중된다. Fuzzy medium은 0.176에서 0.999로, RPM medium은 0.040에서 0.686 이상으로 증가하였다. High 강도는 real-only에서도 이미 binary로 포화되어 증강 효과가 나타날 여지가 없다. Low 강도에서는 특히 Fuzzy와 RPM의 recall이 낮았으며, Gear는 증강량에 따라 이득이 달랐다. 따라서 H2의 단조 감소 가설은 ceiling과 floor 효과를 포함하는 형태로 보완할 필요가 있다. 또한 RPM high에서 binary recall은 1.0이지만 exact recall은 0.0에서 0.62 사이로 불안정하여, 고강도 RPM 변형이 다른 family로 분류되는 경향이 있다.




그림 5.2: Family×강도 grid의 binary detection recall (3 seeds). Rule arm은 medium 조건의 recall을 높이지만 low-intensity Fuzzy, Gear, RPM 조건에서는 낮은 recall이 유지된다.

5 seed 확장에서도 Rule +100%의 low-intensity Fuzzy binary와 exact recall은 각각 0.2440과




그림 5.3: 같은 grid의 exact class recall. Binary로 탐지된 RPM high cell도 exact recall은 낮아 binary와 exact를 분리해 읽어야 한다.

0.1785, Gear는 0.5581과 0.3452였다. Low-intensity RPM은 binary 0.00227, exact 0.00213으로 사실상 탐지되지 않았다. 즉 평균 이득과 함께 가장 약한 공격 강도가 명확한 잔여 취약 구간으로 식별되었다. 이 한계는 생성기 기반 이득의 stealthy-variant 경계에 해당한다.

5.3 ID 이동과 문법 이탈의 분리

표 5.5: Target-ID 이동 및 생성 문법 이탈의 exact recall (5 seeds)

학습 arm	Family	Canonical-ID	Shifted-ID	Grammar-exit
Real-only	Gear	0.6889 ± 0.2616	0.6730 ± 0.2606	0.0000 ± 0.0000
Real-only	RPM	0.0324 ± 0.0232	0.0311 ± 0.0242	0.0297 ± 0.0358
Rule +30%	Gear	0.9227 ± 0.0472	0.9213 ± 0.0536	0.1612 ± 0.1839
Rule +30%	RPM	0.7128 ± 0.1615	0.7114 ± 0.1620	0.0193 ± 0.0263
Rule +100%	Gear	0.9325 ± 0.0840	0.9325 ± 0.0826	0.1561 ± 0.2918
Rule +100%	RPM	0.7255 ± 0.2257	0.7136 ± 0.2308	0.0238 ± 0.0318

Rule +30%에서 target-ID를 바꾸어도 Gear와 RPM exact recall의 평균 차이는 각각 0.0014로 작았다. 이 조건에서는 고정 canonical ID 암기가 주요 설명이 아님을 시사한다. 반면 grammar-exit에서 binary recall은 Gear 0.99995, RPM 1.0이었으나 exact recall은 표 5.5와 같이 급감하였다. 모델은 비정상적 변화 자체는 포착했지만 학습 문법 밖 변화의 family semantics를 안정적으로 일반화하지 못하였다. Real-only 행은 Rule 증강이 canonical과 shifted 조건 모두에서 exact recall을 높였음을 보여주며, 특히 RPM은 0.03에서 0.71로 증가하였다. 따라서 L3의 이득은 canonical ID 암기만으로 설명되지 않으며 payload와 timing을 포함한 non-ID 생성 규칙의 학습이 기여했음을 지지한다. L4는 이렇게 학습한 생성 문법의 경계를 보여준다.




그림 5.4: (좌) Target-ID 이동에서 canonical과 shifted ID의 exact recall이 거의 같다. (우) Payload 위치를 포함한 여러 생성 조건이 함께 바뀐 grammar-exit에서는 Gear/RPM의 exact recall이 크게 낮아진다.

5.4 생성 분포의 식별 가능성

Real attack과 synthetic attack 간 Jensen–Shannon divergence는 CAN-ID 0.00496, inter-arrival time 0.03481, payload 0.03909였다. 개별 marginal divergence가 작아도 결합 feature discriminator AUC는 0.999994에 도달하였다. 이는 생성 표본이 실제 공격과 거의 완전히 구분되는 joint artifact를 포함함을 뜻한다. 이 결과는 합성 데이터의 utility와 realism을 별도 축으로 평가해야 함을 보여주며, marginal similarity 만으로 controlled utility를 설명하기 어렵게 한다. Artifact-aligned decision boundary 형성은 남아 있는 경쟁 설명이며, 현재 분석만으로 효용의 인과 기제를 식별할 수 없다.

Validity와 artifact 기준으로 합성 pool을 filtering한 진단에서도 고정 변형 recall은 1.0으로 유지되었고 OTIDS FPR도 1.0 그대로였다. 따라서 시험한 filtering은 고정 변형 이득과 외부 오탐을 실질적으로 바꾸지 못했다. 이 지표만으로 filtering 이후 생성 artifact의 제거 여부나 위치를 판단할 수는 없다.

5.5 외부 domain 성능

표 5.6: Source policy를 고정한 외부 교차평가 (CNN, 3 seeds)

외부 데이터	학습 arm	정상 FPR	Attack recall
OTIDS	Real-only	0.99809 ± 0.00213	0.99082 ± 0.00843
	Rule +30%	0.99997 ± 0.00004	0.99993 ± 0.00009
can-train	Real-only	0.99995 ± 0.00005	1.00000 ± 0.00000
	Rule +30%	0.999997 ± 0.000004	0.99985 ± 0.00026
ROAD	Real-only	0.99962 ± 0.00061	1.00000 ± 0.00000
	Rule conditions	1.00000 ± 0.00000	1.00000 ± 0.00000

세 외부 데이터에서 attack recall은 높았지만 정상 FPR도 거의 1이었다. 이는 외부 attack을 구분해서 탐지한 것이 아니라 대부분의 외부 입력을 attack으로 판단한 결과다. Rule 증강 뒤에도 동일한 현상이 유지되었다. 이 결과는 attack recall 단독 평가가 domain shift에서 퇴화한 정책을 우수한 탐지기로 오인할 수 있음을 실증한다. 따라서 domain generalization은 외부 정상 support와의 호환성을 함께 평가해야 한다.

표 5.7에서는 검토한 threshold 조정만으로 외부 오탐이 해소되지 않았다. Validation FPR을 0.001 또는 0.01에 맞춘 threshold에서도 OTIDS FPR은 1에 가까웠다. 외부 정상 표본을 직접 보고

표 5.7: Threshold 정책에 따른 OTIDS FPR과 민감도 변형 detection recall (CNN, 3 seeds)

학습 arm	Threshold 정책	Threshold	OTIDS FPR	변형 detection recall
Real-only	Validation FPR 0.001	0.263	0.9995 ± 0.0005	0.606 ± 0.031
Real-only	Validation FPR 0.01	0.055	0.9999 ± 0.0001	0.684 ± 0.053
Real-only	OTIDS-normal oracle (진단)	1.000	0.5698 ± 0.2371	0.372 ± 0.086
Rule +30%	Validation FPR 0.001	0.030	1.0000 ± 0.0000	0.814 ± 0.014
Rule +30%	Validation FPR 0.01	0.003	1.0000 ± 0.0000	0.866 ± 0.017
Rule +30%	OTIDS-normal oracle (진단)	1.000	0.9778 ± 0.0202	0.532 ± 0.008

큰 oracle threshold(진단 전용)는 점수가 1.0으로 포화되어 threshold 자체가 1.0이 되었고, real-only의 FPR을 0.57로 낮추는 대신 변형 recall을 0.37로 떨어뜨렸다. Rule +30%는 oracle에서도 FPR 0.978이었다. 검토한 정책에서는 낮은 OTIDS 정상 FPR과 높은 민감도 변형 recall을 함께 확보하지 못했다. 외부 정상 점수의 포화는 이 정책들의 한계를 보여주지만, 가능한 모든 threshold의 성능이나 외부 정상·공격 점수의 순위 분리도까지 확정하지는 않는다.




그림 5.5: Car-Hacking test normal과 OTIDS normal의 attack score 분포. Real-only, Rule +30%, Rule +100% 모두에서 OTIDS normal 점수가 1.0 부근에 집중된다.

표 5.8: 고전 baseline과 RF의 외부 FPR / attack recall

탐지기	Source test	OTIDS	can-train	ROAD
Entropy (source 적합)	0.0005 / 0.987	1.000 / 0.880	0.993 / 0.906	0.990 / 1.000
Timing, unseen ID를 공격으로	0.000 / 0.993	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
Timing, unseen ID 무시	0.000 / 0.656	0.645 / 0.282	0.000 / 0.072	0.000 / 0.000
RF real-only	0.000006 / 0.997	0.179 / 0.604	0.368 / 0.488	0.9999 / 1.000
CNN real-only	0.0002 / 0.998	0.998 / 0.991	0.9999 / 1.000	0.9996 / 1.000

표 5.8는 외부 실패가 CNN에 국한되지 않음을 보여준다. Source에 적합한 entropy 탐지기는 외부 세 dataset에서 FPR 0.99–1.0이었고, per-ID timing 규칙은 unseen ID를 공격으로 처리하면 whitelist와 같은 전면 오탐이 발생하고, 무시하면 공격 민감도가 크게 감소하였다. RF는 OTIDS와 can-train에서 FPR 0.18과 0.37로 CNN보다 덜 포화되었지만 ROAD에서는 같은 ceiling에 도달하였다. 따라서 실패 양상은 architecture에 민감하지만 architecture 고유의 현상은 아니다.

5.6 외부 FPR 포화의 원인 분해와 보정 진단

표 5.9: 외부 FPR 포화의 원인 분해 및 보정 실험

진단	관측값	해석
Source top-20 ID coverage	Source 0.9701; OTIDS 0.5683; can-train 0.0392; ROAD 0.0287	외부 정상 ID support가 source와 크게 다름
CAN-ID whitelist FPR	Source 0.000000; OTIDS 1.000000; can-train 1.000000; ROAD 1.000000	ID mismatch만으로도 source-like false alarm 재현 가능(충분조건)
CAN-ID 입력 masking	can-train FPR 0.9997 이상 유지	ID channel을 평균으로 바꿔도 CNN 실패는 유지
Non-ID-only CNN 재학습 (5 seeds)	can-train FPR real-only 0.9989 ± 0.0013 , Rule +30% 0.999994 ± 0.000009 ; OTIDS 0.9074 ± 0.0905 / 0.9999	ID를 완전히 제거해도 실패가 남아 ID mismatch는 필요조건이 아님
ID-only CNN 재학습 (5 seeds)	can-train FPR 0.28 ± 0.24 / 0.47 ± 0.34	전면 오탐 모드는 피하지만 불안정하여 정성적으로만 해석
ROAD max-logit / energy score	Real-only FPR 0.080, recall 0.005, AUROC 0.312; Rule +30% FPR 0.073, AUROC 0.383	FPR 감소가 유용한 score separation을 뜻하지 않으며 attack이 ambient보다 더 in-distribution으로 보임
can-train target-normal 재학습	FPR 0.000336, recall 0.0895; ROAD FPR 0.973	외부 정상 표본으로 dataset-local FPR 적응은 가능하지만 attack boundary는 약함
can-train native RF	FPR 0.00297, recall 0.5774; Car-Hacking으로 transfer 시 recall 0.0304	동일 dataset 안에서는 학습 가능하나 cross-dataset attack semantics는 양방향 모두 약함

CAN-ID support 차이는 외부 false alarm을 재현했지만, ID를 제거한 모델에서도 높은 FPR이 유지되었다. Non-ID-only 모델의 source test FPR은 0.000226으로 real-only와 같았으므로, ID 제거가 source 성능을 해쳐서 생긴 결과가 아니다. 또한 threshold 또는 외부 정상 표본만으로 FPR을 낮추면 recall이 붕괴하였다. 이 결과는 외부 오탐이 ID vocabulary, payload와 timing 분포, label semantics 및 score calibration이 결합된 support shift라는 해석을 지지한다. 정상 운영경계의 적응과 attack semantics 평가는 서로 분리된 문제로 다루어야 한다.




그림 5.6: ID channel 진단과 channel ablation 재학습의 외부 FPR. 입력 masking과 non-ID-only 재학습은 FPR을 낮추지 못하고, ID-only 재학습만 부분적으로 낮추지만 seed 분산이 크다.

Support shift의 방향도 dataset마다 달랐다. OTIDS는 source ID coverage가 0.57로 가장 높았음에도 점수가 포화되었고, ID JS divergence 0.34, payload JS 0.12, log- Δt JS 0.04로 timing 이동은 작았다. can-train은 ID coverage 0.04에 Δt 표준화 편차의 중앙값 0.08로 timing 이동이 작았지만 FPR은 거의 1이었다. ROAD는 ID와 payload support 이동에 집중되었다. 즉 포화는 특정 channel 하나의 이동량과 정렬되지 않으며, 다중 channel support와 표현 실패라는 해석이 관측과 일치한다.

표 5.10: Target-normal 재구성과 support-factor 분해의 can-train held-out 결과 (진단, 3 seeds)

재학습 arm	can-train FPR	can-train recall	Source test FPR	ROAD FPR
Source real (기준)	0.99988	1.000	0.00010	0.9998
+Target normal	0.00034	0.090	0.00005	0.973
+Target synth only	0.99545	0.996	0.00014	1.000
+Target normal +synth	0.00121	0.173	0.00016	1.000
+Target normal +source rule	0.00074	0.124	0.00021	0.9997
Target-attack oracle (진단)	0.01422	0.303	0.00024	1.000
Payload only (support factor)	0.00017	0.054	0.00022	0.685
ID + payload (support factor)	0.00003	0.090	0.00014	0.969
DLC + timing (support factor)	0.00070	0.042	0.08457	0.014

표 5.10는 dataset-local adaptation의 효과와 한계를 구분한다. Can-train 정상 적응용 10만 window를 추가하면 held-out FPR은 0.9999 이상에서 0.00034로 떨어지고 source 성능도 유지되지만, attack recall은 0.090에 머문다. Target-normal 기반 합성 공격을 더해도 recall은 0.173이고, 실제 target attack을 사용하는 oracle 진단도 현재 학습 설정에서는 0.303이었다. 외부 정상 표본 없이 target 합성 공격만 추가하면 FPR 0.995로 포화가 그대로다. Support-factor 분해에서 DLC와 timing만 쓰는 arm은 ROAD FPR을 0.014까지 낮췄지만 recall이 0이었다. 즉 FPR 감소는 attack에 무감각해지는 방식으로 얻을 수 있으므로, 이 실험은 channel group 수준의 진단이지 deployment 절차가 아니다. RF로 같은 target-normal 재구성을 반복해도 동일한 경향이 관찰되었다.




그림 5.7: Channel group별 support-factor 분해의 외부 FPR. Payload를 포함한 arm은 can-train FPR을 낮추지만 ROAD에서는 여전히 높고, DLC+timing arm만 ROAD FPR을 낮춘다.

5.7 단계별 결과 종합

표 5.11는 각 rung의 핵심 결과와 해석 범위를 정리한다. 이를 통해 단계가 진행되면서 확인된 효과와 남아 있는 한계를 함께 비교할 수 있다.

표 5.11: Shift Ladder 단계별 결과와 해석

Rung	핵심 결과	해석 및 한계
L0 Source test	CNN binary Macro-F1 0.9992, FPR 0.00022	Benchmark는 포화되었고 강건성 근거가 아니다.
L1 Fixed variant	Rule recall 1.0 vs real-only 0.486, oversampling 0.495	Controlled same-family 이득이 존재한다.
L2 Sensitivity	Detection recall 0.548 → 0.780	이득은 parameter 변화를 부분적으로 견딘다.
L2 Low intensity	Rule +100% RPM detection 0.0023	Stealthy 변형은 해결되지 않았다.
L3 Target-ID	Gear 0.9227 → 0.9213, RPM 0.7128 → 0.7114	Canonical-ID 암기만의 효과가 아니다.
L4 Grammar exit	Binary ≈ 1.0 , exact Gear 0.16 · RPM 0.02	Boundary는 anomaly detection이 되고 attack semantics는 아니다.
L5 External	CNN FPR ≈ 1.0 on OTIDS/can-train/ROAD	Everything-is-attack 모드에서 attack recall은 무의미하다.
L6 Repair probes	Target-normal can-train FPR 0.00034, recall 0.090	Dataset-local FPR repair는 attack transfer가 아니다.

5.8 결과 종합 및 학술적 기여

실험 결과는 세 가지 결론으로 종합된다. 첫째, 규칙 기반 증강은 동일 budget의 실제 표본 복제보다 큰 변형 recall을 제공하여 생성 규칙이 controlled attack support를 확장한다는 해석을 지지한다. 둘째, 이득은 강도 변화와 target-ID 이동을 일부 수용하지만 문법 이탈에서 binary anomaly detection과 exact family typing으로 분화된다. Shift Ladder는 이 전환점을 정량화하여 합성 증강 효과라는 단일 명제를 분포 변화별 결과와 한계로 구체화한다. 셋째, 외부 domain의 높은

FPR은 CAN-ID mismatch만의 문제가 아니라 여러 feature support와 calibration이 결합된 현상과 일치한다. 정상 분포 적응과 공격 의미 평가는 서로 분리하여 검증해야 한다.

따라서 본 연구의 중심 기여는 특정 detector의 최고 점수가 아니라 합성 증강의 효용이 생성되는 범위, 약화되는 경계, 외부에서 붕괴하는 기제를 하나의 재현 가능한 평가 체계로 연결한 것이다. 이 체계는 후속 CAN 증강 연구가 성능 향상과 그 적용 범위 및 한계를 함께 검토할 수 있는 실험 설계 원칙을 제공한다. 각 단계의 결과는 해당 평가 조건의 범위에서 해석할 수 있다. 고정 변형 결과는 positive control로 유용하지만, 민감도, target-ID, grammar-exit와 외부 FPR 평가가 없으면 생성 문법을 공유하는 변형에서의 효과까지만 확인한다.

제6장 타당도 위협과 추가 검증

6.1 구성 타당도

Gear와 RPM label은 payload 조작 문법에 부여한 construction label이다. 따라서 exact recall은 정의한 family의 분류 성능을, binary recall은 정상 boundary를 벗어난 변화의 탐지 성능을 측정한다. 두 지표를 분리하여 물리 신호 의미 복원과 construction 분류를 혼동하지 않도록 하였다. 위협 범위는 classic CAN 2.0의 injection 공격이며 ECU suppression을 동반한 masquerade, diagnostic session 남용, error-frame과 bus-off 공격, CAN-FD는 통제된 rung에 포함하지 않는다. L1-L4는 held-out normal 위의 window-local stress이며 독립적으로 기록된 물리 공격이 아니다. L2와 L4는 여러 field 축을 함께 바꾸므로 cross-setting 변화는 결합된 constructed shift다. Discriminator AUC는 real/synthetic joint artifact의 존재를 측정하며, 추가 feature-interaction 분석의 출발점으로 사용한다.

6.2 내적 타당도

Episode와 시간 block을 windowing 전에 분리하여 직접 누출을 줄였으나, stride 32의 인접 window는 frame을 75% 공유한다. 현재 seed 반복은 같은 split과 생성 construction 안에서 학습·sampling 변동을 측정한다. 따라서 현재 결과는 pipeline 반복성을 정량화한다. 외부 dataset은 평가 조건의 범위를 넓히지만 독립 차량 모집단의 반복으로 간주하지 않는다. 증강 arm마다 달라질 수 있는 optimizer update 수와 인접 window 공유의 영향을 분리하기 위해 update-matched 대조와 raw-frame-disjoint split을 설계하였다. Rule과 real-only arm은 epoch 상한과 patience가 다르므로 현재 결과는 arm 수준 대조이며 데이터 내용만의 인과 효과가 아니다.

6.3 외적 타당도

Source는 Car-Hacking 하나이며 외부 데이터는 차량, 수집 장비, arbitration-ID vocabulary, timing, 공격 구현과 label granularity가 다르다. 고정 schedule의 source 공격은 L0을 거의 포화 시키므로 L0은 어려운 탐지 문제가 아니라 출발 조건이다. 세 외부 dataset에서 일관되게 나타난 FPR ceiling은 source-calibrated representation의 공통 전이 문제를 보여준다. 다만 non-ID support 연관은 channel 수준의 인과 결과가 아니다. 차량, 하드웨어, logger, timestamp, DLC/padding, 전

처리, windowing과 label 구성의 차이가 payload, DLC, timing 지표와 얽혀 있다. 추가 연구에서는 sample support와 label 정책을 정규화한 비교를 추가하여 dataset별 요인과 vehicle-domain 요인을 더 세분화한다.

6.4 통계적 결론 타당도

Main 결과는 3 seeds, stress 결과는 5 paired seeds로 반복하여 pipeline 변동을 측정하였다. Ratio 간 작은 차이보다 paired seed에서 반복되는 이득 방향과 효과 크기를 중심으로 해석하고, low-intensity와 grammar-exit처럼 cell별 support가 다른 경우 macro 평균과 조건별 결과를 함께 제시하였다. Paired t-test p 값은 $n = 3$ 또는 5에서 얻은 것이므로 통계적 확정 근거보다 방향 일치의 보조 근거로 사용한다. Window 단위 요약은 긴 capture에 더 큰 가중치를 두므로 capture 단위 집계는 추가로 필요하다. Paired effect와 불확실성 구간은 비교의 통계적 강도를 보완한다.

6.5 결과의 적용 범위와 한계

표 6.1는 실험으로 확인된 결과와 현재 설계로 식별되지 않는 요인을 구분한다. 이 구분은 결과의 적용 범위와 추가 검증이 필요한 불확실성을 명시한다.

표 6.1: 실험 결과의 적용 범위와 한계

구분	내용
확인된 결과	규칙 기반 합성 증강은 생성 문법을 공유하는 변형과 일부 강도 변화에서 탐지 성능을 높였다. 효과 크기는 공격 강도와 생성 문법의 범위에 따라 달라졌으며, 외부 dataset의 분포 이동 문제는 해결하지 못했다.
현재 확인되지 않은 사항	실제 미관측 공격에 대한 강건성, 차량 간 일반화, 합성 트래픽의 물리적 현실성 및 실제 공격 데이터의 대체 가능성은 현재 결과만으로 확인할 수 없다. 외부 dataset에서의 강건성 향상도 관찰되지 않았다.
해석 시 유의사항	외부 성능은 FPR과 attack recall을 함께 확인하며, binary detection과 exact typing을 구분한다. 보조 분석은 주요 평가 결과와 구분하고, 결과에는 사용한 seed 수를 함께 제시한다.

6.6 추가 검증 설계

표 6.2의 네 실험은 현재 결과의 주요 불확실성인 optimizer update 수, window 중첩, 외부 support · label 차이와 생성 규칙 고유 효과를 각각 분리하도록 설계하였다. 각 실험은 대조 조건, 평가 지표와 판단 기준을 사전에 고정하며, 결과는 현재 분석과 독립된 실행 단위로 비교한다.

표 6.2: 추가 검증 실험의 설계

실험	검증 목적	대조 설계	평가 지표와 판단 기준
Update-matched 대조	RQ1/H1에서 학습 횟수의 영향 분리	Real-only 데이터로 Rule arm과 같은 optimizer update 수를 사용하는 CNN arm	L1 attack recall과 L2 detection recall의 paired 차이. Rule이 update-matched를 사전 마진 이상 넘으면 지지
Raw-frame- disjoint split	Window 중첩의 영향 확인	원시 frame이 겹치지 않는 결정론적 subset 으로 L0-L2 재평가	효과 방향과 크기가 전체 window 결과와 일치하는지 확인. 부호 반전 시 결론의 강건성을 다시 평가
외부 support · label 정규화	RQ3/H4의 외부 평가	저-FPR 운영점의 TPR 과 AUROC/AP로 policy 실패와 ranking 실패를 분리	Paired 95% interval에서 ΔFPR < 0 과 $\Delta\text{Recall} > 0$ 이 동시에 성립할 때만 공동 개선
Matched- placebo 비교	RQ4/H5에서 생성 규칙의 고유 효과 확인	20개 construction의 Rule pool과 marginal-matched placebo twin, balance gate 통과 후 학습	Rule-placebo 평균 차이의 95% 구간이 최소 추가 효과를 초과하면 지지; 동등성 검정은 별도 수행

Placebo는 주변 분포와 주입 구조를 맞추고 Gear/RPM 관계를 교란한 대조군이며, balance gate는 두 pool의 비교 가능성을 확인하는 기준이다. 최소 효과와 동등성 한계는 후속 실험 전에 고정한다. 동등성은 두 단측검정(TOST)의 90% 신뢰구간으로 판단하며, 유의한 차이가 없다는 이유만으로 동등하다고 해석하지 않는다.

제7장 연구 수행 현황과 잔여 일정

7.1 연구 수행 범위

이 장의 수행 상태는 연구 기준일인 2026년 7월 2일을 기준으로 한다. 본 연구는 1인 개인과제로 수행되며, 표 7.1는 연구 설계부터 재현 자료 구성까지의 수행 범위를 제시한다.

표 7.1: 구성원 역할과 연구 수행 범위

구성원	담당 역할	수행 범위
장현진	연구 설계 및 전체 구현	문제 정의, 선행연구 조사, 데이터 provenance와 split 설계, 규칙 생성기·CNN·RF 구현, Shift Ladder 실험, 통계 집계, 오탐 원인 분석, 결과 해석, 재현 자료와 연구 결과 문서 구축

장현진은 데이터 역할과 출처 관리, 생성기·탐지기 구현, 전 단계 실험, 통계 집계와 재현 자료 구성을 수행하였다. 이 연구에서 파생된 WISA 투고는 공동저자와 작성한 별도 학술 산출물이며, 표의 수행 범위는 본 과제에서 직접 수행한 작업을 기준으로 한다.

7.2 구현 및 분석 현황

표 7.2: 연구 요소별 구현 및 분석 현황 (2026년 7월 2일 기준)

연구 요소	상태	완료 범위 및 남은 작업
문제 정의 및 평가 명세	정리 완료	연구질문, rung별 평가 기준과 결과 해석 범위, FR/NFR 대응 관계
데이터 파이프라인	구현 완료	Source/external 역할 분리, split/windowing 설정, split 감사, provenance 기록
생성·학습 시스템	부분 구현	4개 공격 family 생성기, CNN/RF, real-only와 equal-budget 비교군; matched-update와 placebo 생성기 미구현
핵심 단계적 평가	분석 완료	Source, fixed variant, sensitivity, target-ID, grammar-exit, external과 외부 실패 진단/repair 결과
통계 분석	부분 분석	Seed별 mean/std, paired t-test; paired interval, Holm 보정, capture 단위 집계 미완
결과·재현 자료 구성	구성 완료	연구 결과 문서, 결과표와 그림, 실험 설정과 재현 자료 목록; 부가 산출물로 WISA 투고
추가 타당도 분석	계획	연구 설계와 해석을 보완할 분석 항목
확장 검증 및 결과 통합	계획	타당도 위협별 추가 실험, 최종보고서, 발표·SW 결과물

핵심 구현과 L0–L6 분석은 완료하였다. 남은 matched-update 대조, 외부 ranking 평가, placebo 비교는 각각 학습량, 외부 점수 분리도, 생성 규칙의 고유 효과를 검증한다.

7.3 기준일 이후 연구 계획과 제출 일정

표 7.3의 7-8월 실험 항목은 연구 기준일 이후의 계획이며, 이 보고서에서 완료 실적으로 집계하지 않는다. 9월 7일은 이번 중간보고서의 제출본 정리일로 표시하고, 이후 실험의 실제 완료 범위와 일정 변경은 최종보고서에 반영한다.

표 7.3: 기준일 이후 연구 계획 및 제출본 정리 일정

기간/기한	수행 내용	산출물
2026.07.02	L0-L5 평가, L6 외부 실패 진단과 재현 자료 정리	기준 결과 자료
07.18-07.31	Update-matched 대조군 학습(CNN 3 seeds), raw-frame-disjoint 평가 subset 구성과 L0-L2 재평가	Matched-update 결과표, overlap 감사 보고
07.29 이후	기준 결과 검토에서 확인된 보완 사항을 연구질문·타당도 위협별로 정리	보완 항목 목록
08.01-08.14	외부 ranking 지표(AUROC/AP, 저-FPR TPR)와 support·label 정규화 비교	외부 평가 결과표
08.15-08.31	Marginal-matched placebo 생성기, balance gate, 20 construction crossing 학습과 TOST 분석	생성 규칙 효과 결과표와 분석 계획
2026.09.07	중간보고서 제출본 정리	중간보고서 PDF
09.01-09.11	현재·추가 결과 통합, 가설별 확정 검토, 최종보고서 초안	최종보고서 초안
09.12-09.18	지도교수 검토 반영, 최종보고서 제출	최종보고서 PDF
09.19-10.01	발표 자료, 시연 스크립트, 예상 질문 준비 및 발표심사	발표자료
10.02-10월 중순	SW 등록, 공개 가능한 코드·사용 설명서·재현 패키지 업로드	최종 산출물

7.4 일정 위험과 대응

표 7.4: 기준일 이후 일정의 주요 위험과 대응

위험	영향	대응
20 construction 학습의 계산 시간	Placebo 비교 일정 지연	학습 arm을 CNN 3 seeds로 제한하고 construction 수를 단계적으로 늘리며, 완료 범위와 미완료 범위를 구분하여 제시
Update-matched 대조에서 이득 소멸	H1 판정 변경	이득이 소멸하면 학습 횟수의 영향으로 해석하고 H1의 최종 판단에 반영
추가 분석 범위 확대	최종 일정 압박	핵심 연구질문에 필요한 항목을 우선 수행하고 나머지는 최종보고서의 한계와 향후 과제로 정리
외부 dataset 라이선스 · 재배포 제한	재현 패키지 범위 축소	Raw data와 weight는 재배포하지 않고 download 안내와 checksum으로 대체

7.5 연구 진행 요약

현재 연구 범위에는 데이터 역할을 분리한 파이프라인, 규칙 기반 생성기, 두 모델 계열, L0-L5 평가와 L6 외부 실패 분석이 포함된다. 이 실행 체계는 규칙 기반 합성 증강이 controlled attack support를 확장하는 효과를 확인하는 동시에, 그 효과가 유지되는 강도 · 문법 · domain 경계를 정량적으로 식별하였다. Binary detection과 exact typing, attack recall과 normal FPR을 분리한 설계는 단일 성능 점수로 보이지 않는 이득의 범위와 추가 검증 우선순위를 한 번의 일관된 평가 흐름에서 제시한다.

추가 연구는 update-matched 대조, 비중첩 평가, 외부 support 정규화와 matched-placebo 비교를 통해 현재 평가 체계의 원인 해석과 외부 타당도를 보강한다. 최종 분석은 기존 결과와 추가 실험을 연구질문별로 통합하여 효과의 범위와 한계를 정교화한다.

참고문헌

- [1] Ahmed M. Alaa, Boris van Breugel, Evgeny Saveliev, and Mihaela van der Schaar. How faithful is your synthetic data? Sample-level metrics for evaluating and auditing generative models. In *Proceedings of the 39th International Conference on Machine Learning (ICML)*, volume 162 of *Proceedings of Machine Learning Research*, pages 290–306, 2022.
- [2] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, and Konrad Rieck. Dos and don'ts of machine learning in computer security. In *Proceedings of the 31st USENIX Security Symposium*, pages 3971–3988, 2022.
- [3] Stefan Axelsson. The base-rate fallacy and the difficulty of intrusion detection. *ACM Transactions on Information and System Security*, 3(3):186–205, 2000.
- [4] Deborah H. Blevins, Pablo Moriano, Robert A. Bridges, Miki E. Verma, Michael D. Iannacone, and Samuel C. Hollifield. Time-based CAN intrusion detection benchmark. In *Proceedings of the 2021 Workshop on Automotive and Autonomous Vehicle Security*, 2021.
- [5] Stephen Checkoway, Damon McCoy, Brian Kantor, Danny Anderson, Hovav Shacham, Stefan Savage, Karl Koscher, Alexei Czeskis, Franziska Roesner, and Tadayoshi Kohno. Comprehensive experimental analyses of automotive attack surfaces. In *Proceedings of the 20th USENIX Security Symposium*, 2011.
- [6] Guillaume Dupont, Jerry den Hartog, Sandro Etalle, and Alexios Lekidis. Evaluation framework for network intrusion detection systems for in-vehicle CAN. In *Proceedings of the 2019 IEEE International Conference on Connected Vehicles and Expo*, pages 1–6, 2019.
- [7] Cristóbal Esteban, Stephanie L. Hyland, and Gunnar Rätsch. Real-valued (medical) time series generation with recurrent conditional GANs. arXiv:1706.02633, 2017.
- [8] Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2:665–673, 2020.
- [9] Raphael Gontijo-Lopes, Sylvia J. Smullin, Ekin D. Cubuk, and Ethan Dyer. Affinity and diversity: Quantifying mechanisms of data augmentation. arXiv:2002.08973, 2020.
- [10] Hacking and Countermeasure Research Lab. CAN-intrusion dataset (OTIDS). <https://ocslab.hksecurity.net/Dataset/CAN-intrusion-dataset>, 2017. Accessed 2026-06-10.
- [11] Hacking and Countermeasure Research Lab. Car-hacking dataset. <https://ocslab.hksecurity.net/Datasets/car-hacking-dataset>, 2017. Accessed 2026-06-10.
- [12] Markus Hanselmann, Thilo Strauss, Katharina Dormann, and Holger Ulmer. CANet: An unsupervised intrusion detection system for high dimensional CAN bus data. *IEEE Access*, 8:58194–58205, 2020.
- [13] Tianxiang Huang, Jianying Zhou, and Andrei Bytes. ATG: An attack traffic generation tool for security testing of in-vehicle CAN bus. In *Proceedings of the 13th International Conference on Availability, Reliability and Security (ARES)*, pages 32:1–32:6, 2018.
- [14] Min-Joo Kang and Je-Won Kang. Intrusion detection system using deep neural network for in-vehicle network security. *PLOS ONE*, 11(6):e0155781, 2016.
- [15] Brooke Kidmose, Andreas Kidmose, and Weizhi Meng. CAN-SLEUTH: Sleuthing out the capabilities, limitations, and performance impacts of automotive intrusion detection datasets. *International Journal of Information Security*, 24(5):193, 2025.
- [16] Beatrix Koltai, Gergely Ács, and András Gazdag. CAN we trust your results? A cross-dataset study of automotive IDS evaluation. arXiv:2606.30430, 2026. Accepted at ACSW'26 Workshop on Automotive Cyber Security.
- [17] Karl Koscher, Alexei Czeskis, Franziska Roesner, Shwetak Patel, Tadayoshi Kohno, Stephen Checkoway, Damon McCoy, Brian Kantor, Danny Anderson, Hovav Shacham, and Stefan Savage. Experimental security analysis of a modern automobile. In *Proceedings of the 2010 IEEE Symposium on Security and Privacy*, pages 447–462, 2010.
- [18] Brooke Lampe and Weizhi Meng. can-train-and-test: A curated CAN dataset for automotive intrusion detection. *Computers & Security*, 140:103777, 2024.
- [19] Hyunsung Lee, Seong Hoon Jeong, and Huy Kang Kim. OTIDS: A novel intrusion detection system for in-vehicle network by using remote frame. In *Proceedings of the 15th Annual Conference on Privacy, Security and Trust*, 2017.
- [20] Junhui Li, Nikolaos Ersotelos, Michail-Antisthenis Tsompanas, and Gregory Epiphaniou. Challenges and opportunities of synthetic data generation for machine learning-based intrusion detection systems in in-vehicle networks. *Vehicular Communications*, 58:100998, 2026.

- [21] Charlie Miller and Chris Valasek. Remote exploitation of an unaltered passenger vehicle. Black Hat USA, 2015.
- [22] Michael Müter and Naim Asaj. Entropy-based anomaly detection for in-vehicle networks. In *2011 IEEE Intelligent Vehicles Symposium (IV)*, pages 1110–1115, 2011.
- [23] Sampath Rajapaksha, Harsha Kalutarage, M. Omar Al-Kadri, Andrei Petrovski, Garikayi Madzudzo, and Madeline Cheah. AI-based intrusion detection systems for in-vehicle networks: A survey. *ACM Computing Surveys*, 55(11):237:1–237:40, 2023.
- [24] Markus Ring, Sarah Wunderlich, Deniz Scheuring, Dieter Landes, and Andreas Hotho. A survey of network-based intrusion detection data sets. *Computers & Security*, 86:147–167, 2019.
- [25] Eunbi Seo, Hyun Min Song, and Huy Kang Kim. GIDS: GAN-based intrusion detection system for in-vehicle network. In *Proceedings of the 16th Annual Conference on Privacy, Security and Trust*, pages 1–6, 2018.
- [26] Hyun Min Song, Ha Rang Kim, and Huy Kang Kim. Intrusion detection system based on the analysis of time intervals of CAN messages for in-vehicle network. In *2016 International Conference on Information Networking (ICOIN)*, pages 63–68, 2016.
- [27] Hyun Min Song, Jiyoung Woo, and Huy Kang Kim. In-vehicle network intrusion detection using deep convolutional neural network. *Vehicular Communications*, 21:100198, 2020.
- [28] Frida Sundfeldt, Bianca Widstam, Mahshid Helali Moghadam, Kuo-Yun Liang, and Anders Vesterberg. Alleviating attack data scarcity: SCANIA’s experience towards enhancing in-vehicle cyber security measures. In *Proceedings of the 2025 28th Euromicro Conference on Digital System Design*, pages 497–506, 2025.
- [29] Adrian Taylor, Nathalie Japkowicz, and Sylvain Leblanc. Frequency-based anomaly detection for the automotive CAN bus. In *Proceedings of the 2015 World Congress on Industrial Control Systems Security*, pages 45–49, 2015.
- [30] Adrian Taylor, Sylvain Leblanc, and Nathalie Japkowicz. Anomaly detection in automobile control network data with long short-term memory networks. In *Proceedings of the 2016 IEEE International Conference on Data Science and Advanced Analytics*, pages 130–139, 2016.
- [31] Arash Vahidi, Thomas Rosenstatter, and Nishat I. Mowla. Systematic evaluation of automotive intrusion detection datasets. In *Proceedings of the 6th ACM Computer Science in Cars Symposium*, pages 6:1–6:12, 2022.
- [32] Boris van Breugel, Zhaozhi Qian, and Mihaela van der Schaar. Synthetic data, real errors: How (not) to publish and use synthetic data. In *Proceedings of the 40th International Conference on Machine Learning (ICML)*, volume 202 of *Proceedings of Machine Learning Research*, pages 34793–34808, 2023.
- [33] Miki E. Verma, Robert A. Bridges, Michael D. Iannaccone, Samuel C. Hollifield, Pablo Moriano, Steven C. Hespeler, Bill Kay, and Frank L. Combs. A comprehensive guide to CAN IDS data and introduction of the ROAD dataset. *PLOS ONE*, 19(1):e0296879, 2024.
- [34] Xiang Wang, Jian Zhao, Pengbo Liu, Nianmin Yao, and Zheng Xu. CAN bus intrusion detection based on deep learning with data augmentation for connected autonomous vehicles. *IEEE Transactions on Vehicular Technology*, 75(2):2253–2266, 2026.
- [35] Qingling Zhao, Mingqiang Chen, Zonghua Gu, Siyu Luan, Haibo Zeng, and Samarjit Chakraborty. CAN bus intrusion detection based on auxiliary classifier GAN and out-of-distribution detection. *ACM Transactions on Embedded Computing Systems*, 21(4):1–30, 2022.