

# 합성 CAN 공격 데이터 증강의 신뢰성 검증

단계적 평가 프레임워크 Shift Ladder의  
설계 및 구현

2026 전기 졸업과제

46 · InfoSec | 장현진

부산대학교 정보컴퓨터공학부  
지도교수 김호원



# CONTENTS

합성 CAN 공격 데이터 증강의 신뢰성 검증



## I 연구 배경

1. CAN 통신과 침입탐지
2. 합성 데이터 증강과 평가의 공백

## II 제안 방법

1. Shift Ladder 평가 프레임워크
2. 비교군과 평가 지표
3. 시스템 구현

## III 실험 결과

1. 동일 학습량에서의 증강 효과
2. 평가 단계별 결과

## IV 원인 분석

1. 생성 요인 교차 실험
2. 맞춤 대조군 설계
3. 관계 활용도와 탐지 효용

## V 결론

1. 연구 결과와 기여
2. 산출물 및 학술 성과

## 1.1 CAN 통신과 침입탐지

### ▶ CAN은 송신자 인증이 없어 메시지 주입 공격에 취약하다

- 침입탐지 모델(IDS)은 메시지의 ID, 데이터 값, 전송 간격을 학습해 정상 통신과 공격을 구분

#### 차량 내부 통신망 (CAN 버스)



#### CAN 메시지

| CAN ID | DLC | DATA 0 - 7 (8바이트) | Δt |
|--------|-----|-------------------|----|
|--------|-----|-------------------|----|

연속 128개 메시지 × 11채널을 하나의 입력 구간으로 사용

#### 공격 유형 · Car-Hacking 데이터셋

**DoS** 최우선 ID 메시지를 대량 주입

**Fuzzy** 무작위 ID와 값을 주입

**Gear** 기어 상태 메시지를 위조


**RPM** 엔진 회전수 메시지를 위조

실제 차량에서 다양한 공격 자료를 반복 수집하기 어려워 학습 자료의 부족이 성능의 제약이 된다

## 1.2 ▶ 합성 데이터 증강과 평가의 공백

### ▶ 합성 증강의 효과는 증강 전후 점수 비교만으로 설명되지 않는다

- 합성 데이터 증강: 관측한 공격의 규칙으로 새 표본을 만들어 부족한 공격 학습 자료를 보충



### 점수 비교에서 구분해야 할 세 가지

#### 1 학습량과 표본 내용

자료가 늘어 더 많이 학습한 효과와  
합성 표본의 내용이 만든 효과가 섞여  
있음

→ 학습량을 맞춘 대조 실험

#### 2 공격 탐지와 유형 식별

공격의 존재를 찾아내는 성능과 공격  
유형까지 맞히는 성능은 서로 다른  
능력

→ 지표를 분리한 측정

#### 3 학습 환경과 새 환경

학습과 시험이 같은 생성 규칙을  
공유하면 규칙이나 차량이 바뀐  
조건을 성능을 알 수 없음

→ 조건을 바꾼 단계적 평가

연구 목표 합성 증강의 탐지 효과와 그 효과가 유지되는 조건을 함께 평가하는 시스템의 설계와 구현

## 2.1 Shift Ladder 평가 프레임워크

### ▶ 평가 조건을 학습 환경에서 단계적으로 멀어지게 하며 증강 효과를 측정

- 생성 문법: CAN ID, 페이로드, 시간 간격, 주입 배치를 정하는 합성 공격의 생성 규칙



모든 단계에서 공격 탐지율 · 유형 재현율 · 정상 오탐률을 분리해 측정

## 2.2 ▶ 비교군과 평가 지표

## ▶ 학습량을 맞춘 세 학습군으로 합성 표본 내용의 기여를 분리

- 세 학습군 모두 같은 1D-CNN 구조, 같은 7,992회 갱신, 학습 시드 5개로 반복

## 학습 자료의 구성

실제 자료만

실제 학습 자료

공격 복제 +30%

실제 학습 자료

실제 공격  
복제

합성 증강 +30%

실제 학습 자료

합성 공격

추가 표본 수는 두 학습군 모두 실제 학습 자료의 30%

## 분리해 측정하는 지표

1

## 공격 탐지율

공격 구간을 공격으로 판정한 비율

2

## 유형 재현율

공격 유형까지 정확히 맞힌 비율

3

## 정상 오탐률

정상 구간을 공격으로 오인한 비율

## 탐지기

1D-CNN (주 분석)  
Random Forest (비교)

## 반복 단위

학습 시드 5개  
생성 반복 최대 100개

## 통계 분석

대응 차이와 신뢰구간  
Holm 보정, 동등성 검정  
(TOST)

## 2.3 시스템 구현

## ▶ 데이터 분리부터 통계 분석까지 여섯 모듈을 하나의 파이프라인으로 구현

- 설정 파일 기반 Python CLI로 반복 실험을 자동 실행하고 입력, 모델, 결과를 해시로 연결

**학습 데이터 Car-Hacking**  
학습 · 검증 · 시험으로 시간 순 분할

**외부 데이터 OTIDS · ROAD · can-train-and-test**  
학습과 분리한 평가 전용



## 1D-CNN (주 분석 탐지기)

입력 11채널 × 128메시지  
합성곱 3층 (64 → 128 → 128)  
출력 5클래스 (정상과 공격 4종)

## Random Forest (비교 모델)

채널별 요약 통계 55차원  
결정 트리 160개  
관계 특징을 추가한 83차원 확장


## 실험 자동화

실행 계획에 시드와 학습량 기록  
지표와 그림 생성에 자동 검사 적용  
저장된 결과에서 표와 그림 재생성

## 3.1 ▶ 동일 학습량에서의 증강 효과

## ▶ 학습량을 맞춘 비교에서도 합성 증강 모델의 탐지율이 가장 높았다

- 실제 공격을 같은 수만큼 복제한 학습군보다 높아, 합성 표본의 내용이 탐지에 기여함을 확인



고정 변형 탐지율

**+50.25 %p**

49.75 % → 99.99 %

결합 변형 탐지율

**+16.90 %p**

55.10 % → 72.00 %


1D-CNN · 학습 5회의 평균과 표준편차 · 세 학습군 모두 7,992회 갱신

- ✅ 다섯 번의 학습 반복 모두 같은 방향의 차이
- ✅ 원시 메시지가 겹치지 않는 평가에서도 이득 유지

## 3.2 ▶ 평가 단계별 결과

## ▶ 단계별 평가는 평균 점수에 가려진 성능 차이를 드러낸다

- 합성 증강 +30% CNN의 단계별 공격 탐지율과 유형 재현율 (학습 5회 평균)



## 생성 규칙 밖 변형 (L4)

- 공격 탐지율 **99.8 %** 유지
- 유형 재현율은 **8.93 %**
- 탐지와 식별의 격차 증가 +0.909
- 학습 5회 모두 같은 방향

## 외부 차량 데이터 (L5)


- OTIDS, ROAD, can-train-and-test 3종
- 탐지율과 함께 정상 오탐률도 **약 100 %**
- 점수 순위(AUROC)는 약 0.50

세 지표를 분리해 측정해야 증강 효과가 유지되는 범위를 판단할 수 있다

## 4.1 ▶ 생성 요인 교차 실험

## ▶ 생성 요인을 교차한 실험에서 값의 위치가 가장 큰 영향을 보였다

- 세 요인을  $2 \times 2 \times 2$ 로 교차하고 새 생성 반복 4개에서 효과를 추정 (Holm 보정  $p \leq 0.039$ )



## 교차한 세 가지 생성 요인

- P 값의 위치**  
공격 값이 놓이는 페이로드 바이트
- S 주입 배치**  
입력 구간 안 공격 메시지의 배치
- D 값 변화 규칙**  
시간에 따른 값의 변화 양상

**P = -0.892**95 % 신뢰구간  
-0.943 ~ -0.842

위치에 대한 의존이 값 사이의 관계를 학습한 결과인지 대조 실험으로 확인


## 4.2 ▶ 맞춤 대조군 설계

## ▶ 값 사이의 관계만 다른 대조 자료로 생성 관계의 기여를 분리

- 주입 위치와 개수, 바이트별 값 분포는 같게 두고 두 값의 대응만 재배열한 맞춤 대조군(Placebo)

## 관계를 유지한 자료와 맞춤 대조 자료

## Rule 자료 (관계 유지)



같은 정상 배경, 같은 주입 조건, 같은 값 분포  
달라진 것은 두 값 사이의 대응 관계

## 같은 조건에서 두 모델을 평가

Rule 자료로  
학습한 모델Placebo 자료로  
학습한 모델

공통 평가: 관계 유지 조건 / 관계 변경 조건

L

## 관계 활용도

관계를 바꿨을 때 나타나는  
성능 변화의 두 모델 간 차이

U

## 탐지 효용


관계가 유지된 평가에서  
두 모델의 유형 재현율 차이

모델이 관계에 반응하는 정도와 관계가 성능에 기여하는 정도를 나누어 측정

## 4.3 ▶ 관계 활용도와 탐지 효용

## ▶ 모델의 관계 활용을 확인했고, 평가 절차는 유용한 관계의 효과를 검출했다

- 새 생성 반복 100개, CNN 학습 1,000회 · 입력 구간의 공격 메시지가 8개인 조건



위치 이동 반응의 분해 (생성 반복 20개)

대조군에서도 재현된 성분 99.3 %

전체  $-0.8811 = \text{대조군 성분 } -0.8752 + \text{관계에 따른 차이 } -0.0059$

## 양성 대조: 평가 절차의 검출력 검증

관계가 분류에 유용하도록 설계한 자료로 같은 절차를 적용해 효용이 회복되는지 확인

1D-CNN **+35.90 %p**

RF (관계 특징 추가) **+35.70 %p**

생성 반복 20개 모두에서 효용이 양수

관계 활용도 **+2.64 %p**는 신뢰구간 전체가 0보다 큼 · 탐지 효용은 **+0.11 %p**로 별도 추정

## 5.1 연구 결과와 기여

## ▶ 합성 증강의 성능 향상을 원인과 유지 범위까지 검증하는 평가 체계를 구현

01

**Shift Ladder 평가 프레임워크**

L0 - L6 단계와 데이터 역할 분리로 학습 도메인, 공격 변형, 외부 환경의 평가를 하나의 절차로 연결

02

**공정한 조건에서 증강 효과 확인**

같은 갱신 횟수와 공격 복제 대조에서 고정 변형 +50.25 %p, 결합 변형 +16.90 %p의 탐지 이득

03

**평가 지표의 분리 기준 제시**

공격 탐지율, 유형 재현율, 정상 오탐률을 나누어 측정해 증강 효과가 유지되는 범위를 단계별로 규명

04

**생성 요소의 기여 분해**

요인 교차와 맞춤 대조군으로 관계 활용도(+2.64 %p)와 탐지 효용을 구분하고 양성 대조로 절차를 검증

합성 데이터로 얻은 성능 향상의 원인과 적용 범위를 대조 실험으로 검증하는 절차 제시

## 5.2 ▶ 산출물 및 학술 성과

## ▶ 평가 시스템을 모듈별 산출물로 구현하고 연구 결과를 학술 논문으로 정리

## 학술 성과

## WISA 2026 · Oral 발표

### The Shift Ladder: Locating the Gains and Failures of Rule-Based Synthetic CAN Attack Augmentation

Shift Ladder 평가 체계와 동일 학습량 대조 결과

## Vehicular Communications 투고 준비

요인 교차 실험, 맞춤 대조군,  
관계 활용도와 탐지 효용 분석으로 확장

후속 연구 결과를 저널 원고로 정리

## 시스템 산출물

- 1 **데이터 처리 모듈**  
시간 구간 분할과 공통 11채널 입력 구성
- 2 **규칙 기반 생성기**  
공격 유형 4종의 합성 자료와 맞춤 대조군
- 3 **탐지기 학습 모듈**  
CNN, RF 학습과 동일 학습량 비교
- 4 **Shift Ladder 평가기**  
L0 - L6 단계별 결과표와 운영점 산출
- 5 **요인·관계 분석기**  
요인 효과, 관계 활용도와 효용 추정
- 6 **확장 검증 자료**  
양성 대조와 새 생성 반복 100개의 재현 결과

# 감사합니다

46 · InfoSec | 장현진

